UNIVERSITÉ DE DOUALA

THE UNIVERSITY OF DOUALA

* * *

ÉCOLE NATIONALE SUPÉRIEURE POLYTECHNIQUE DE DOUALA

(ENSPD)

* * *

DÉPARTEMENT DE GÉNIE INFORMATIQUE

MÉMOIRE DE MASTER

Master of Science en Data Science et Intelligence Artificielle (SDIA)

COMPARAISON ENTRE L'ALGORITHME EM CLASSIQUE ET L'EM VARIATIONNEL

(Avantages, inconvénients et applications)

Dressé et présenté par :

KANA TIODONG ICARE BRICHEL

Mémoire co-encadré par :

Prof. Dr. habil. P. NJIONOU SADJANG

Professeur Associé, École Nationale Supérieure Polytechnique de Douala

Prof. Patrice TAKAM SOH

Professeur Associé, Université de Yaoundé 1

Année Académique 2025 – 2026

Table des matières

Liste des abréviations et sigles **1**

Introduction générale **3**

I REVUE DE LA LITTÉRATURE : FONDEMENTS ET ÉTAT DE L'ART **6**

1 FONDEMENTS THÉORIQUES ET ALGORITHMES EM **7**

1.1 Modèles à variables latentes 7
1.1.1 Définition formelle 7
1.1.2 Taxonomie des variables latentes 8
1.1.3 Exemples fondamentaux 8
1.2 Vraisemblance et estimation 9
1.2.1 Vraisemblance complète et vraisemblance incomplète 9
1.2.2 L'inégalité de Jensen et le principe de la borne inférieure 9
1.2.3 Identifiabilité et unicité 10
1.3 Modèles de mélanges gaussiens (GMM) 10
1.3.1 La distribution gaussienne univariée 10
1.3.2 La distribution gaussienne multivariée 11
1.3.3 Le modèle de mélange gaussien 11
1.3.4 Relation entre GMM et k-means 12
1.3.5 Exemple numérique : évaluation de la densité d'un GMM 12
1.4 Introduction au cadre bayésien 12
1.4.1 La philosophie bayésienne 12
1.4.2 Le théorème de Bayes et ses composantes 13
1.4.3 Distributions conjuguées 13
1.4.4 Exemple numérique illustratif : conjugaison Dirichlet–Catégorielle 14
1.5 La divergence de Kullback-Leibler 15
1.5.1 Définition et propriétés 15
1.5.2 Interprétation informationnelle 15
1.5.3 KL et ELBO : la décomposition fondamentale 15
1.5.4 KL directe et KL inverse : le phénomène de zero-forcing 16
1.6 L'algorithme EM classique 17
1.6.1 Historique et contexte 17

1.6.2 Formulation mathématique complète 18
1.6.3 Propriétés théoriques 21
1.6.4 Application au mélange gaussien : exemple numérique détaillé . 24
1.6.5 Variantes de l'EM classique 25
1.6.6 Extension aux données séquentielles : l'algorithme de Baum-Welch 26
1.6.7 Avantages de l'EM classique 28
1.6.8 Inconvénients et limites de l'EM classique 29
1.7 L'algorithme EM variationnel 30
1.7.1 Motivation et cadre général 30
1.7.2 Inférence variationnelle 30
1.7.3 Formulation de l'EM variationnel 32
1.7.4 Sélection automatique du nombre de composantes 35
1.7.5 Exemple numérique illustratif 37
1.7.6 Calcul de l'ELBO et critère de convergence 38
1.7.7 Variantes avancées de l'EM variationnel 38
1.7.8 Avantages de l'EM variationnel 40
1.7.9 Inconvénients et limites de l'EM variationnel 41
1.8 Conclusion du chapitre 1 43

II MÉTHODOLOGIE 45

2 MÉTHODOLOGIE DE LA CONFRONTATION 46
2.1 Comparaison théorique 46
2.1.1 De l'énergie libre de Neal et Hinton au cas limite de Dirac . . . 48
2.1.2 Trois niveaux d'inférence : MLE, MAP et Bayes complet 49
2.1.3 Le MAP-EM : isoler l'effet du prior 50
2.2 Comparaison algorithmique 51
2.2.1 Complexité computationnelle 51
2.2.2 Comportement numérique et stabilité 52
2.2.3 Critères de sélection de modèle 53
2.3 Hypothèses de recherche et plan des tests 54
2.4 Données et préparation 57
2.4.1 Jeu synthétique de référence 57
2.4.2 Scénarios synthétiques S1 à S10 59
2.4.3 Iris 60
2.4.4 Prix alimentaires des marchés du Cameroun (cas pratique) . . . 61
2.4.5 Corpus de texte (pLSA contre LDA) 63
2.5 Protocole de comparaison 65
2.5.1 Bras comparés et critère d'arrêt commun 65

2.5.2 Métriques 66
2.5.3 Tests statistiques et règle de décision 66
2.6 Calibrage des paramètres 68
2.7 Implémentation et ingénierie du code 69
2.7.1 EM classique 69
2.7.2 EM variationnel 70
2.7.3 Orchestration reprenable et production des résultats 72
2.8 Menaces à la validité et écarts au protocole 72

III RÉSULTATS ET DISCUSSION 74

3 RÉSULTATS ET DISCUSSION 75
3.1 Validation numérique et illustrations exploratoires 75
3.1.1 Sélection externe de K par BIC et AIC 75
3.1.2 Résultats de l'EM classique (K = 6 imposé) 76
3.1.3 Résultats de l'EM variationnel (Kmax = 6) 77
3.1.4 Comparaison visuelle et qualité de partition 78
3.1.5 Sensibilité au choix du prior de Dirichlet (α_0) 79
3.1.6 Étude de la scalabilité computationnelle 79
3.1.7 Cas de référence : nombre de composantes correctement spécifié (K = 3) 80
3.1.8 Convergence de l'ELBO 81
3.1.9 Robustesse à l'initialisation 82
3.1.10 Sensibilité au type de covariance 82
3.1.11 Validation sur un jeu de données réel (Iris) 83
3.1.12 Sensibilité aux valeurs aberrantes 84
3.1.13 Grille de α_0 autour du seuil $d/2$ (S8, descriptif) 85
3.2 Scénarios confirmatoires S1 à S10 85
3.2.1 Chevauchement, déséquilibre et sous-estimation de K (S1 à S3) 86
3.2.2 Queues épaisses, dimension et petit effectif (S4 à S6) 86
3.2.3 Aberrations (S7) 86
3.2.4 Décisions et lecture 86
3.2.5 Plan factoriel sur les priors et seuil d'activité (S9 et S10, descriptifs) 87
3.2.6 Coût de la sélection de K en temps total 87
3.3 Cas pratique : régimes de tension des prix alimentaires au Cameroun . 88
3.4 Comparaison pLSA contre LDA 89
3.5 Bilan des hypothèses de recherche 90
3.6 Portée : domaines non testés 92
3.6.1 Vision et bio-informatique (revue de la littérature) 92

3.6.2 Systèmes de recommandation (revue de la littérature) 93
3.7 Recommandations pratiques 93
3.8 Conclusion du chapitre 3 94

Conclusion générale **95**
Synthèse des contributions 95
Limites du travail 96
Perspectives 96

Bibliographie **97**

Annexes **102**
Annexe A : Code source 102
Annexe B : Détail du calcul de l'ELBO pour le GMM bayésien 105
Annexe C : Table de correspondance des symboles mathématiques 106
Annexe D : Environnement logiciel et reproductibilité 106
Annexe F : Registre des paramètres 107
Annexe E : Rappels mathématiques utilisés dans les dérivations 114

Liste des figures

1.1 Premier effet de la KL inverse : sur un posterior multimodal, le q qui minimise $\mathrm{KL}[q \,\|\, p]$ se concentre sur un mode (tirets), alors que la KL directe $\mathrm{KL}[p \,\|\, q]$ étale q sur les modes (pointillés). Schéma illustratif, les hauteurs des courbes ne sont pas normalisées. 17
1.2 Évolution de la log-vraisemblance au fil des itérations (exemple numérique de la section 1.6.4). La courbe est croissante puis stationnaire dès la troisième itération, ce qui illustre la garantie de monotonie établie à la section 1.6.2.f. 25
1.3 Mécanisme d'élagage : $\psi(\alpha_k) \approx -1/\alpha_k$ tend vers $-\infty$ quand $\alpha_k \to 0$. Dans l'étape E, $\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi(\sum_j \alpha_j)$ pénalise une composante dont α_k reste proche de α_0. Courbe tracée par l'approximation asymptotique de la fonction digamma décalée de 2. 36

2.1 Trois niveaux d'inférence selon la nature de θ et l'approximation de $q(Z)$. Cases pleines : algorithmes comparés (EM classique, MAP-EM, VB pour le GMM ; EM variationnel à θ ponctuel pour la LDA du chapitre 3). Cases en pointillés : non traitées. 51
2.2 Jeu de données synthétique utilisé pour l'étude expérimentale : trois groupes gaussiens réels de 100 observations chacun (N = 300 au total). 59
2.3 Marchés suivis : couleur et symbole par région, taille selon le nombre d'observations retenues (apprentissage et test). Source : PAM, base de prix du Cameroun (HDX, CC BY-IGO). 62
2.4 Modèles graphiques du pLSA et de la LDA utilisée ici. La différence testée est le prior de Dirichlet sur θ_d (LDA) contre un θ_d ponctuel sans prior (pLSA). Dans les deux cas les distributions de mots par thème sont ponctuelles : la LDA du code est un EM variationnel à β ponctuel, non un VB complet. 64
2.5 Protocole « 5 EM + VB » : tous les bras partagent le critère d'arrêt, les graines et les mesures ; chaque comparaison est appariée par réplication. 65
2.6 Critère d'arrêt commun à l'EM, au MAP-EM, à l'EM variationnel et au pLSA. Le critère c est la log-vraisemblance totale (EM) ou l'ELBO total (VB, covariance pleine), évalué après chaque étape E et avant l'étape M. Tolérance relative 10^{-6} et plafond commun de 500 étapes M ; n_M est le nombre d'itérations rapporté. 66

3.1 Critères BIC et AIC de l'EM classique en fonction du nombre de composantes K, sur le jeu de données à trois groupes réels. 76
3.2 Partition obtenue avec six composantes : une couleur par composante, ellipses de covariance à deux écarts-types, croix aux centres. À gauche, l'EM classique conserve ses six composantes ; à droite, l'EM variationnel n'en retient que trois (les composantes élaguées figurent en gris dans la légende). 77
3.3 Poids de mélange π_k finaux pour les six composantes : EM classique et EM variationnel. Le contraste traduit le mécanisme d'élagage bayésien décrit à la section 1.7.4. 78
3.4 Nombre de composantes actives en fonction de la concentration α_0 du prior de Dirichlet (échelle logarithmique), pour les deux jeux de priors. Le mécanisme d'élagage disparaît lorsque α_0 devient grand. 79
3.5 Temps d'exécution des deux algorithmes en fonction du nombre d'observations N (à gauche, échelles logarithmiques) et de la dimension D (à droite). Les étiquettes donnent le rapport du temps variationnel au temps classique. 80
3.6 Évolution de l'ELBO (EM variationnel, à gauche) et de la log-vraisemblance (EM classique, à droite) en fonction du nombre d'itérations. Les deux courbes sont croissantes, conformément aux garanties théoriques des sections 1.6.2.f et 1.7.6. 81
3.7 Répartition du nombre de composantes actives selon l'algorithme et la stratégie d'initialisation (20 exécutions chacune, une initialisation par exécution). 82
3.8 Indice de Rand ajusté selon la contrainte imposée sur la covariance (K = 6 imposé). 83
3.9 Indice de Rand ajusté et silhouette sur le jeu Iris, selon l'algorithme et le nombre de composantes. 84
3.10 Décisions de la famille des scénarios : différence moyenne appariée (VB moins EM) et intervalle bootstrap à 95 %, marge d'équivalence en gris. 87
3.11 Sélection du nombre de régimes sur toute la période d'apprentissage : BIC de l'EM selon K (gauche) et poids des composantes du VB à priors empiriques avec $K_{\max} = 8$ (droite). 88
3.12 Trois marchés les plus suivis pendant la période de test. En haut : écart du prix du maïs à son niveau des douze mois précédents. En bas : probabilité du régime de tension selon EM-BIC (bande : bootstrap à 90 %) et selon le VB à priors empiriques (bande : crédibilité à 90 %). Trait pointillé vertical : fin de l'apprentissage. 88

3.13 Part mensuelle des observations dont la probabilité de tension dépasse 0,5, tous marchés confondus, selon EM-BIC et le VB à priors empiriques. 88
3.14 Décisions de la famille « prix » : différence moyenne appariée (VB moins EM) et intervalle bootstrap à 95 % ; bande grise : marge d'équivalence. 88

Liste des tableaux

1.1 Exemples fondamentaux de modèles à variables latentes 8
1.2 Convergence de l'algorithme EM sur l'exemple numérique à $K = 2$ composantes (8 observations) 24
1.3 Principales variantes de l'algorithme EM classique 25
1.4 Calcul détaillé des quantités forward, backward et a posteriori pour $O =$ (NPa, Pa, Pa) 27
1.5 Résultat de l'EM variationnel sur l'exemple à 8 observations ($K_{\max} = 3$) selon l'initialisation et la graine 37

2.1 Comparaison théorique entre l'EM classique et l'EM variationnel 47
2.2 Les trois niveaux d'inférence statistique pour les modèles à variables latentes 50
2.3 Complexité algorithmique comparée (par itération) 52
2.4 Hypothèses de recherche issues de la thèse et tests qui les mettent à l'épreuve 54
2.5 Plan des tests déclarés (familles de Holm : scénarios, prix, prévision, texte) 55
2.6 Paramètres du protocole expérimental 58
2.7 Plans des scénarios synthétiques 60

3.1 Grille « axe × preuve » : chaque affirmation renvoie à un théorème, une expérience ou la mention « non testé » 90
3.2 Statut de la preuve par domaine d'application 93
3.3 Guide de décision avec niveau de preuve (aucune ligne n'est une recommandation absolue) 94
3.4 Correspondance entre fonctions du code, sections et équations 102
3.5 Registre des paramètres 108

Liste des abréviations et sigles

EM Espérance-Maximisation (Expectation-Maximization)

GMM Modèle de Mélange Gaussien (Gaussian Mixture Model)

ELBO Borne Inférieure de l'Évidence (Evidence Lower Bound)

KL Divergence de Kullback-Leibler

VI Inférence Variationnelle (Variational Inference)

SVI Inférence Variationnelle Stochastique (Stochastic Variational Inference)

VAE Auto-encodeur Variationnel (Variational Autoencoder)

AEVB Bayes Variationnel Auto-Encodant (Auto-Encoding Variational Bayes)

SGVB Estimateur Variationnel Bayésien par Gradient Stochastique (Stochastic Gradient Variational Bayes)

CAVI Montée par Coordonnées pour l'Inférence Variationnelle (Coordinate Ascent Variational Inference)

MAP Maximum A Posteriori

MLE Estimateur du Maximum de Vraisemblance (Maximum Likelihood Estimator)

HMM Modèle de Markov Caché (Hidden Markov Model)

PPCA Analyse en Composantes Principales Probabiliste

LDA Allocation de Dirichlet Latente (Latent Dirichlet Allocation)

BIC Critère d'Information Bayésien (Bayesian Information Criterion)

AIC Critère d'Information d'Akaike (Akaike Information Criterion)

ICL Critère de Vraisemblance Classifiante Intégrée

SEM EM Stochastique (Stochastic EM)

GEM EM Généralisé (Generalized EM)

MCAR Données Manquantes Complètement Aléatoires (Missing Completely At Random)

MAR Données Manquantes Aléatoires (Missing At Random)

NLP Traitement Automatique du Langage Naturel (Natural Language Processing)

Introduction générale

Contexte et problématique

Les modèles à variables latentes, au premier rang desquels les mélanges gaussiens, sont ajustés depuis plus de quarante ans par l'algorithme Espérance-Maximisation (EM) de Dempster, Laird et Rubin (1977). L'EM fournit un estimateur ponctuel du maximum de vraisemblance, exige que le nombre de composantes K soit fixé à l'avance et peut converger vers des solutions dégénérées. L'EM variationnel, dans sa forme bayésienne (Attias, 2000 ; Bishop, 2006), place des lois a priori sur les paramètres, approche leur loi a posteriori par un champ moyen et élague les composantes superflues. La question traitée est la suivante : *que gagne-t-on, et que perd-on, en passant de l'EM classique à l'EM variationnel, et sur quelles preuves ces gains et ces pertes reposent-ils ?*

La littérature présente volontiers l'EM variationnel comme un progrès. Ce mémoire adopte la position inverse du soupçon méthodique : chaque avantage (sélection automatique de K, incertitude, robustesse aux singularités, économie de calcul) et chaque inconvénient (coût, sensibilité aux priors, biais d'approximation, irréversibilité de l'élagage, dépendance à $K_{\max}$) est relié à une preuve : un théorème, une expérience répliquée, une expérience unique, ou la mention « non testé ».

Trois niveaux d'inférence

La comparaison n'a de sens que si l'on distingue trois niveaux, rassemblés à la figure 2.1 (chapitre 2). (1) L'*EM classique* estime θ par un point (maximum de vraisemblance) avec $q(Z) = p(Z \mid X, \theta)$ exact. (2) L'*EM variationnel à θ ponctuel* (Neal et Hinton, 1998 ; la LDA de Blei, Ng et Jordan, 2003) approche $q(Z)$ mais garde θ ponctuel. (3) Le *Bayes variationnel* (VB) rend θ aléatoire et approche $q(\theta)$. Un comparateur intermédiaire, le *MAP-EM*, ajoute les priors du VB à l'EM sans distribution sur θ : il isole l'effet de la régularisation de celui de l'inférence bayésienne complète.

Thèse défendue

Le VB ne « bat » pas l'EM. Il déplace la sélection de K vers le choix des hyperparamètres (et de $K_{\max}$), apporte une incertitude approchée, au prix d'un coût et d'une sensibilité aux priors. Les termes « supériorité », « changement de paradigme » et « dérivation originale » sont bannis de ce mémoire : l'équivalence de Neal et Hinton y

est reprise comme une re-démonstration rigoureuse, non comme une contribution.

Hypothèses et critères

Les hypothèses sont déclarées dans le code (`hypotheses.py`), avec un seul test par hypothèse, avant l'exécution confirmatoire. Celles des scénarios ont été formalisées après une première exécution exploratoire, ce qui est déclaré comme un écart au protocole ; celles du cas pratique l'ont été avant tout ajustement de modèle sur ses données. Au chapitre 2, dix scénarios synthétiques (S1 à S10) testent le chevauchement, le déséquilibre des poids, la sous-estimation de K, les queues épaisses, la dimension, le petit effectif, les aberrations, la grille de α_0 autour du seuil $d/2$ de Rousseau et Mengersen (2011), un plan factoriel sur les priors et la sensibilité au seuil d'activité, chacun avec un nombre de réplications fixé par un calcul de puissance et un test apparié déclaré (équivalence ou différence). Elle est décomposée en cinq hypothèses de recherche (RH1 absence de supériorité générale, RH2 déplacement de la sélection de K, RH3 incertitude approchée, RH4 régularisation par les priors, RH5 coût), mises à l'épreuve par les tests des scénarios, du cas pratique (HP1 à HP7, et six comparaisons de prévision) et du corpus de texte (tableau 2.5). La correction de Holm s'applique au sein de chaque famille d'hypothèses, et l'équivalence est une issue légitime.

Méthode et reproductibilité

Tous les algorithmes sont écrits en PyTorch à partir des équations, avec un *critère d'arrêt commun* (tolérance relative sur le critère total et plafond d'étapes M, fixés par une étude de calibrage et consignés dans le registre des paramètres en annexe ; figure 2.6) : aucune comparaison n'est faite avec des critères d'arrêt différents. Les tableaux et les figures sont produits par le code avec des graines fixées ; aucun nombre des tableaux n'est saisi à la main, et le dépôt est archivé (annexe A).

Périmètre

Le mémoire porte sur les mélanges gaussiens (et de Student pour la robustesse), le modèle de Markov caché et la LDA. Le cas pratique porte sur un problème réel de la sous-région : repérer les régimes de tension des prix des denrées de base (maïs, riz importé, niébé) sur les marchés du Cameroun, à partir des données publiques du Programme alimentaire mondial, pour l'alerte précoce sur la sécurité alimentaire ; une comparaison pLSA contre LDA porte sur un corpus réel. La vision, la bio-informatique et la recommandation font l'objet d'une revue de la littérature, sans expérience. Les

mélanges de Dirichlet infinis, les méthodes MCMC et les familles variationnelles structurées sont hors périmètre.

Plan

Le mémoire compte trois parties. La première (chapitre 1) pose les fondements : variables latentes, ELBO, KL, EM et EM variationnel, en distinguant les trois niveaux d'inférence. La deuxième (chapitre 2) expose la méthodologie, sans résultat : comparaison théorique et algorithmique, hypothèses de recherche et plan des tests, données et leur préparation (jeu synthétique, scénarios, Iris, prix alimentaires du Cameroun, corpus de texte), protocole et règles de décision, calibrage des paramètres et implémentation. La troisième (chapitre 3) présente et interprète tous les résultats : illustrations exploratoires, scénarios confirmatoires, cas pratique des prix alimentaires, comparaison pLSA contre LDA, bilan des hypothèses de recherche, grille « axe × preuve » (tableau 3.1) et guide de décision avec niveaux de preuve. La conclusion générale dresse le bilan et les limites.

Partie I

REVUE DE LA LITTÉRATURE : FONDEMENTS ET ÉTAT DE L'ART

Chapitre 1

FONDEMENTS THÉORIQUES ET ALGORITHMES EM

Ce premier chapitre pose l'ensemble des bases théoriques nécessaires à la compréhension du reste de ce mémoire, puis présente en détail les deux algorithmes qui en constituent l'objet central : l'algorithme Espérance-Maximisation (EM) classique et sa généralisation bayésienne, l'EM variationnel. Nous commençons par définir la notion de modèle à variables latentes, avant d'introduire les outils mathématiques indispensables la vraisemblance et sa maximisation, les distributions gaussiennes et le modèle de mélange gaussien, le cadre bayésien, l'inégalité de Jensen et la divergence de Kullback-Leibler. Ces éléments théoriques permettent ensuite de dérouler, de façon rigoureuse et progressive, la formulation mathématique complète de l'EM classique puis de l'EM variationnel, en insistant à chaque étape sur les propriétés de convergence, les variantes existantes, ainsi que les avantages et les limites de chacune des deux approches.

1.1 Modèles à variables latentes

1.1.1 Définition formelle

Un modèle probabiliste à variables latentes est défini par la donnée d'un espace d'observations et d'un espace de variables cachées, reliés par une loi jointe. Intuitivement, on peut se représenter une variable latente comme une cause non observée qui explique la structure des données observées : par exemple, la note obtenue par un étudiant à un examen (observée) dépend de son niveau réel de maîtrise de la matière (non observé directement). Formellement, pour une observation x_i, on écrit :

$$p(x_i|\theta) = \int_{\mathcal{Z}} p(x_i,z_i|\theta)dz_i \tag{1.1}$$

L'objectif de l'inférence est d'estimer le paramètre θ à partir des seules observations $\{x_i\}$, les variables latentes z_i n'étant jamais directement observées. La loi jointe se factorise selon le processus génératif du modèle :

$$p(X,Z|\theta) = p(Z|\theta) \times p(X|Z,\theta) = \prod_i p(z_i|\theta)p(x_i|z_i,\theta) \tag{1.2}$$

Cette factorisation traduit le processus génératif du modèle : on tire d'abord les variables latentes selon leur loi a priori, puis les observations conditionnellement à ces variables latentes.

1.1.2 Taxonomie des variables latentes

Les variables latentes se présentent sous différentes formes selon la nature du modèle considéré. On distingue en particulier :

- les variables latentes discrètes, comme les indicateurs d'appartenance à un groupe dans les modèles de mélange ;
- les variables latentes continues, comme les coordonnées dans un espace de représentation réduit, dans les modèles factoriels ;
- les variables latentes structurées, comme les séquences d'états cachés dans les modèles de Markov cachés.

La nature des variables latentes influence directement la traçabilité du calcul de la vraisemblance marginale et, par conséquent, la forme de l'algorithme EM applicable au modèle considéré.

1.1.3 Exemples fondamentaux

Les modèles à variables latentes sont omniprésents dans les applications de l'apprentissage automatique. Le tableau 1.1 présente les exemples les plus représentatifs, qui seront pour certains repris au chapitre 3 dans le cadre des applications pratiques.

Modèle	**Variables latentes**	**Paramètres**	**Application**
Mélange gaussien (GMM)	Appartenance à une composante $z_i \in \{1..K\}$	π, μ_k, Σ_k	Clustering, estimation de densité
Modèle de Markov caché (HMM)	Séquence d'états discrets	A, B, π_0	Reconnaissance vocale
ACP probabiliste (PPCA)	Coordonnées latentes $z_i \in \mathbb{R}^L$	W, σ^2	Réduction de dimension
Analyse factorielle	Facteurs latents	Λ, Ψ	Psychologie, économie
LDA	Topics par document, mots par topic	α, β	Modélisation de sujets textuels
VAE	Code latent $z_i \in \mathbb{R}^L$	θenc, θdec	Génération d'images
IRT	Niveau de compétence θ_i	a_j, b_j	Tests psychométriques

Tableau 1.1: Exemples fondamentaux de modèles à variables latentes

1.2 Vraisemblance et estimation

1.2.1 Vraisemblance complète et vraisemblance incomplète

La distinction entre vraisemblance complète et vraisemblance incomplète est au cœur de la compréhension de l'algorithme EM. La log-vraisemblance complète est définie sur l'espace des données complètes, c'est-à-dire en incluant les variables latentes :

$$\ell c(\theta) = \log p(X,Z|\theta) = \Sigma_i \log p(x_i,z_i|\theta) \tag{1.3}$$

Cette quantité est généralement facile à optimiser, car p(X, Z | θ) se factorise de manière simple, conduisant souvent à des expressions analytiques fermées pour les estimateurs du maximum de vraisemblance. En revanche, la log-vraisemblance incomplète, définie sur les seules observations, s'écrit :

$$\ell(\theta) = \log p(X|\theta) = \Sigma_i \log \int p(x_i,z_i|\theta)dz_i = \Sigma_i \log \Sigma_k p(x_i,z_i = k|\theta) \tag{1.4}$$

L'opération de logarithme d'une somme (ou d'une intégrale) détruit la structure factorielle favorable de la vraisemblance complète, rendant l'optimisation directe de $\ell(\theta)$ généralement intractable sur le plan analytique. C'est précisément cette difficulté que l'algorithme EM contourne de manière élégante, en s'appuyant sur une borne inférieure de la vraisemblance incomplète l'ELBO que nous introduisons dès à présent.

1.2.2 L'inégalité de Jensen et le principe de la borne inférieure

L'inégalité de Jensen est un résultat fondamental de l'analyse convexe qui sous-tend directement la construction de l'algorithme EM. Elle énonce que pour toute fonction concave f et toute variable aléatoire X, on a :

$$f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)] \tag{1.5}$$

avec égalité si et seulement si X est constante presque sûrement, ou si f est linéaire. Appliquée à la fonction logarithme, qui est concave, avec q(Z) comme distribution de pondération, cette inégalité fournit, pour tout θ et toute distribution q(Z) :

$$\ell(\theta) = \log p(X|\theta) \geq \mathbb{E}_q[\log p(X,Z|\theta)] - \mathbb{E}_q[\log q(Z)] =: ELBO(q,\theta) \tag{1.6}$$

Cette borne inférieure, appelée ELBO (Evidence Lower BOund), est l'idée clé qui fonde l'algorithme EM sous ses deux variantes : au lieu d'optimiser directement la log-vraisemblance incomplète $\ell(\theta)$, on optimise alternativement cette borne inférieure par rapport à q (étape E) et par rapport à θ (étape M), ce qui garantit que la log-vraisemblance marginale ne diminue jamais au cours des itérations. L'égalité dans

l'inégalité de Jensen est atteinte lorsque q(Z) = p(Z | X, θ), c'est-à-dire lorsque la distribution variationnelle coïncide exactement avec la distribution a posteriori des variables latentes : c'est exactement ce que réalise l'étape E de l'algorithme EM classique.

1.2.3 Identifiabilité et unicité

Une question importante en théorie de l'estimation concerne l'identifiabilité du modèle : peut-on distinguer deux valeurs de paramètres différentes $\theta \neq \theta'$ uniquement sur la base de la distribution des observations ? Un modèle est identifiable si p(X | θ) = p(X | θ') implique $\theta = \theta'$. Les modèles de mélanges souffrent typiquement d'une non-identifiabilité partielle : les K! permutations des étiquettes de composantes donnent toutes la même distribution marginale, créant ainsi K! optima globaux équivalents. Cette propriété, appelée label switching, n'affecte pas la qualité de la solution trouvée par l'EM, mais complique l'interprétation et la comparaison des résultats entre plusieurs lancements de l'algorithme.

Une seconde forme de non-identifiabilité, distincte du label switching, est propre aux mélanges sur-paramétrés, c'est-à-dire ajustés avec plus de composantes que la loi génératrice n'en contient. Si un poids π_k est nul, les paramètres (μ_k, Σ_k) de la composante correspondante n'interviennent plus dans la densité : ils sont arbitraires. Si deux composantes ont la même moyenne et la même covariance, seule la somme $\pi_j + \pi_k$ est identifiée. Dans ces deux cas, l'ensemble des paramètres qui donnent la même densité n'est plus un ensemble fini de $K!$ permutations mais une sous-variété de l'espace des paramètres : la vraisemblance est plate dans certaines directions et la matrice d'information de Fisher est singulière (Rousseau et Mengersen, 2011). Cette propriété a deux conséquences utilisées plus loin. Elle rend fausses, pour un mélange sur-paramétré, les hypothèses de régularité des théorèmes asymptotiques usuels. Elle est aussi le phénomène que l'élagage de l'EM variationnel met à profit (section 1.7.4), dont l'effet sur le champ moyen reste, en l'état, une hypothèse à tester et non un résultat établi.

1.3 Modèles de mélanges gaussiens (GMM)

1.3.1 La distribution gaussienne univariée

La distribution gaussienne (ou normale) $\mathcal{N}(\mu, \sigma^2)$ est une distribution de probabilité continue définie sur $\mathbb{R}$, entièrement caractérisée par sa moyenne $\mu \in \mathbb{R}$ et sa variance $\sigma^2 > 0$. Sa densité de probabilité est donnée par :

$$p(x|\mu,\sigma^2) = 1/\sqrt{2\pi\sigma^2} \cdot \exp[-(x-\mu)^2/(2\sigma^2)] \tag{1.7}$$

La gaussienne jouit de plusieurs propriétés remarquables qui expliquent sa place centrale en statistiques : elle est stable par combinaison linéaire (si X $\sim \mathcal{N}(\mu, \sigma^2)$, alors aX + b $\sim \mathcal{N}(a\mu$+b, $a^2\sigma^2)$) ; elle est la loi limite des sommes normalisées de variables indépendantes, conformément au théorème central limite ; elle maximise l'entropie parmi toutes les distributions de variance fixée ; enfin, elle est sa propre distribution a priori conjuguée pour l'estimation de la moyenne.

1.3.2 La distribution gaussienne multivariée

En dimension D, la distribution gaussienne multivariée $\mathcal{N}(\mu, \Sigma)$ est paramétrée par un vecteur moyenne $\mu \in \mathbb{R}^D$ et une matrice de covariance $\Sigma \in \mathbb{R}^{DxD}$, symétrique définie positive. Sa densité s'écrit :

$$p(x|\mu,\Sigma) = (2\pi)^{-D/2}|\Sigma|^{-1/2} \exp[-\tfrac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)] \tag{1.8}$$

La matrice de covariance Σ encode les variances individuelles sur sa diagonale et les corrélations entre dimensions hors de la diagonale. Plusieurs cas particuliers sont couramment utilisés : la gaussienne sphérique ($\Sigma = \sigma^2 I$), la gaussienne diagonale ($\Sigma =$ diag($\sigma_1^2, \ldots, \sigma^{D2}$)), et la gaussienne générale (Σ quelconque), ces trois cas correspondant à des niveaux de complexité croissants dans les modèles de mélanges gaussiens.

1.3.3 Le modèle de mélange gaussien

Un mélange de K gaussiennes est le modèle probabiliste central de ce mémoire. Il suppose que chaque observation x_i est générée selon le processus suivant : on tire d'abord un indicateur $z_i \in \{1, \ldots, \mathrm{K}\}$ selon une distribution catégorielle de paramètres $(\pi_1, \ldots, \pi K)$, puis on tire x_i selon la gaussienne de la composante sélectionnée. La densité marginale du mélange s'écrit :

$$p(x|\theta) = \Sigma_{k=1}^{K} \pi_k \mathcal{N}(x|\mu_k,\Sigma_k) \tag{1.9}$$

où les poids de mélange π_k satisfont $\pi_k \geq 0$ et $\Sigma_k\ \pi_k = 1$, et où $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^{K}$ désigne l'ensemble des paramètres du modèle. Le GMM est un approximateur universel de densités continues : pour K suffisamment grand, un GMM peut approcher arbitrairement bien n'importe quelle densité de probabilité continue, ce qui explique son utilisation massive comme modèle de densité générique. En tant que méthode de clustering, le GMM offre des partitions souples (soft clustering), où chaque point appartient simultanément à plusieurs clusters avec des probabilités différentes, contrairement au clustering dur (hard clustering) réalisé par l'algorithme k-means.

1.3.4 Relation entre GMM et k-means

Le célèbre algorithme k-means peut être vu comme un cas limite dégénéré du GMM. Lorsque toutes les matrices de covariance sont contraintes à $\Sigma_k = \sigma^2 I$ et que $\sigma^2 \to 0$, les responsabilités de l'EM convergent vers des affectations dures : chaque point est assigné entièrement à la composante dont le centre est le plus proche, et les mises à jour des centres correspondent exactement aux mises à jour des centroïdes de k-means. Cette connexion illustre que l'EM pour GMM est une généralisation probabiliste de k-means, offrant davantage de flexibilité et de richesse modélisatrice, au prix d'un coût computationnel légèrement supérieur.

1.3.5 Exemple numérique : évaluation de la densité d'un GMM

Afin de rendre pleinement concrète l'équation (1.8) avant son utilisation intensive dans la suite de ce chapitre, évaluons-la numériquement en reprenant le modèle à deux composantes convergé à la section 1.6.4 (π_1=π_2=0,5 ; μ_1=1,125, σ_1=0,466 ; μ_2=7,725, σ_2=0,460), et calculons la densité prédite p(x|θ) pour une nouvelle observation x = 2,0, non présente dans l'échantillon original.

$$p(2{,}0|\theta) = 0{,}5 \times \mathcal{N}(2{,}0|1{,}125; 0{,}466^2) + 0{,}5 \times \mathcal{N}(2{,}0|7{,}725; 0{,}460^2) \tag{1.10}$$

Le premier terme, associé à la composante centrée en 1,125, vaut $0{,}5 \times 0{,}1468 \approx 0{,}0734$, la valeur x = 2,0 n'étant qu'à 1,9 écart-type environ du centre de cette composante. Le second terme, associé à la composante centrée en 7,725, vaut quant à lui environ 10^{-34} : la valeur x = 2,0 se trouve à plus de douze écarts-types du centre de cette seconde composante, ce qui rend sa contribution totalement négligeable en comparaison de la première, un exemple numérique direct du phénomène d'underflow évoqué à la section 1.6.2.e, qui justifie le recours systématique au calcul en log-espace. La densité totale vaut donc p(2,0|θ) $\approx$ 0,0734, et la responsabilité de la première composante pour cette observation, calculée par l'équation (1.15), vaut $r_1 = 0{,}0734/0{,}0734 \approx 1{,}000$: le modèle attribue, sans la moindre ambiguïté, l'observation x = 2,0 à la composante centrée en 1,125, ce qui correspond parfaitement à l'intuition géométrique.

1.4 Introduction au cadre bayésien

1.4.1 La philosophie bayésienne

Le cadre bayésien repose sur une vision fondamentalement différente de celle des statistiques fréquentistes classiques. Là où le fréquentiste considère les paramètres comme

des constantes inconnues et définit la probabilité comme une fréquence limite d'événements répétables, le bayésien traite les paramètres comme des variables aléatoires et interprète la probabilité comme un degré de croyance subjectif, pouvant s'appliquer à tout événement incertain, qu'il soit répétable ou non.

Cette différence philosophique a des conséquences pratiques importantes : un bayésien peut exprimer ses connaissances préalables sur les paramètres sous forme d'une distribution a priori, peut quantifier son incertitude résiduelle après observation des données sous forme d'une distribution a posteriori, et peut naturellement intégrer de nouvelles données en utilisant la distribution a posteriori courante comme nouveau prior. C'est cette dernière propriété qui rend le cadre bayésien particulièrement adapté à l'EM variationnel, présenté à la section 1.7.

1.4.2 Le théorème de Bayes et ses composantes

Le théorème de Bayes est le pivot de toute l'inférence bayésienne. Pour un modèle avec paramètres θ et observations X, il s'écrit :

$$p(\theta|X) = p(X|\theta)p(\theta)/p(X) \tag{1.11}$$

Chaque terme de cette équation joue un rôle précis : la distribution a priori p(θ) encode les connaissances préalables sur θ, avant toute observation ; la vraisemblance p(X | θ) mesure la compatibilité des données observées avec chaque valeur possible de θ ; la distribution a posteriori p(θ | X) représente les croyances mises à jour sur θ après observation de X ; enfin, la vraisemblance marginale, ou évidence, p(X) = $\int$ p(X | θ) p(θ) $d\theta$, est une constante de normalisation indépendante de θ, mais qui joue un rôle central dans la sélection de modèles bayésiens.

En pratique, pour un GMM bayésien, on place des distributions a priori conjuguées sur les paramètres : les poids de mélange reçoivent un prior de Dirichlet, $\pi \sim \mathrm{Dir}(\alpha_0, \ldots, \alpha_0)$, et les paramètres des composantes reçoivent un prior Normal-Wishart, $(\mu_k, \Lambda_k) \sim \mathcal{NW}(m_0, \beta_0, W_0, \nu_0)$, où $\Lambda_k = \Sigma_k^{-1}$ désigne la matrice de précision. Ces priors conjugués garantissent que les distributions a posteriori appartiennent à la même famille que les priors, ce qui permet des mises à jour analytiques lors des étapes variationnelles présentées à la section 1.7.

1.4.3 Distributions conjuguées

Le concept de conjugaison est fondamental en inférence bayésienne. On dit qu'un prior p(θ) est conjugué à la vraisemblance p(X | θ) si la distribution a posteriori p(θ | X) appartient à la même famille paramétrique que le prior. La conjugaison garantit des formes analytiques fermées pour les mises à jour bayésiennes, ce qui est particuliè-

rement précieux pour l'EM variationnel. Les couples conjugués les plus importants pour notre étude sont : Gaussienne–Gaussienne (pour la moyenne d'une gaussienne de variance connue), Dirichlet–Catégorielle (pour les paramètres d'une distribution catégorielle), et Normal-Wishart–Gaussienne multivariée (pour les paramètres complets d'une gaussienne multivariée).

1.4.4 Exemple numérique illustratif : conjugaison Dirichlet–Catégorielle

Afin d'ancrer concrètement la notion de conjugaison avant son utilisation intensive à la section 1.7, illustrons-la sur le cas le plus simple rencontré dans ce mémoire : la mise à jour d'un prior de Dirichlet sur les poids d'un mélange à partir d'observations catégorielles. Considérons un mélange à K = 3 composantes, muni d'un prior a priori peu informatif Dir(α_0, α_0, α_0) avec $\alpha_0 = 1$ (ce qui correspond à une distribution uniforme sur le simplexe des poids π). Supposons que l'étape E d'une itération donnée attribue, sur un petit jeu de N = 12 observations, les responsabilités suivantes, cumulées par composante : $N_1 = 7$, $N_2 = 4$, $N_3 = 1$ (soit $\Sigma_k\, N_k = 12$, conformément à la contrainte $\Sigma_k\, r_{ik} = 1$ pour chaque observation).

La règle de mise à jour bayésienne pour le couple conjugué Dirichlet–Catégorielle, appliquée à la section 1.7.3.c, donne directement le paramètre a posteriori $\alpha_k = \alpha_0 + N_k$, soit ici :

$$\alpha_1 = 1 + 7 = 8, \alpha_2 = 1 + 4 = 5, \alpha_3 = 1 + 1 = 2 \tag{1.12}$$

La distribution a posteriori sur les poids de mélange est donc Dir(8, 5, 2), dont la moyenne l'estimation ponctuelle bayésienne des poids vaut $\mathbb{E}[\pi_k] = \alpha_k \,/\, \Sigma_j\, \alpha_j$, soit $\mathbb{E}[\pi_1] = 8/15 \approx 0{,}533$, $\mathbb{E}[\pi_2] = 5/15 \approx 0{,}333$ et $\mathbb{E}[\pi_3] = 2/15 \approx 0{,}133$. On notera que ces valeurs moyennes sont très proches, mais non identiques, des fréquences empiriques $N_k/\mathrm{N} = 7/12 \approx 0{,}583$; $4/12 \approx 0{,}333$; $1/12 \approx 0{,}083$ qu'aurait directement utilisées l'EM classique à l'équation (1.16) : l'écart entre les deux, plus marqué pour la composante la moins représentée (0,133 contre 0,083 pour π_3), illustre précisément l'effet de régularisation du prior décrit à la section 1.7.8 le prior « tire » les estimations vers l'uniformité a priori (1/3 pour chaque composante), d'autant plus fortement que le nombre d'observations disponibles pour cette composante est faible. Cet exemple, volontairement simplifié à une seule mise à jour, préfigure directement le mécanisme itératif complet de l'EM variationnel détaillé à la section 1.7.3, dans lequel cette même règle de mise à jour est appliquée de façon répétée, conjointement à la mise à jour des paramètres Normal-Wishart, jusqu'à convergence de l'ELBO. Ce calcul porte sur $\mathbb{E}[\pi_k]$; il ne doit pas être confondu avec le mécanisme d'élagage, qui repose sur $\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi(\sum_j \alpha_j)$ (section 1.7.4).

1.5 La divergence de Kullback-Leibler

1.5.1 Définition et propriétés

La divergence de Kullback-Leibler (KL) entre deux distributions de probabilité q et p est définie par :

$$KL[q\|p] = \mathbb{E}_q[\log q(z) - \log p(z)] = \int q(z) \log[q(z)/p(z)]dz \tag{1.13}$$

Cette divergence possède plusieurs propriétés importantes : elle est toujours non négative, KL[q ‖ p] ≥ 0, avec égalité si et seulement si q = p presque partout, ce résultat étant connu sous le nom d'inégalité de Gibbs ; elle est asymétrique, c'est-à-dire que KL[q ‖ p] ≠ KL[p ‖ q] en général ; elle n'est pas une distance au sens mathématique du terme, car elle ne satisfait pas l'inégalité triangulaire ; enfin, elle est étroitement liée à l'information de Fisher et joue un rôle central en théorie de l'information.

1.5.2 Interprétation informationnelle

La divergence KL[q ‖ p] peut être interprétée comme le coût moyen, exprimé en nats (ou en bits si le logarithme est en base 2), d'encoder des données générées par q en utilisant un code optimal conçu pour p. Plus q et p sont similaires, plus ce coût est faible. Dans le contexte de l'inférence variationnelle, minimiser KL[q ‖ p], où p = p(θ, Z | X) désigne la vraie distribution a posteriori, revient à rechercher, au sein d'une famille variationnelle donnée, la distribution q la plus proche possible de la véritable distribution a posteriori.

1.5.3 KL et ELBO : la décomposition fondamentale

La relation entre la divergence KL, l'ELBO et la log-vraisemblance marginale est établie par la décomposition fondamentale suivante :

$$\log p(X) = ELBO(q) + KL[q(Z,\theta)\|p(Z,\theta|X)] \tag{1.14}$$

Cette décomposition est fondamentale, car elle montre que maximiser l'ELBO par rapport à q est équivalent à minimiser KL[q ‖ p(· | X)], puisque log p(X) est une constante par rapport à q. Elle montre également que l'ELBO sous-estime toujours la log-vraisemblance marginale, puisque la divergence KL est non négative, et que l'écart entre les deux est exactement la divergence KL entre l'approximation variationnelle et la vraie distribution a posteriori. Cette relation constitue le socle mathématique commun sur lequel reposent à la fois l'EM classique, présenté à la section 1.6, et l'EM variationnel, présenté à la section 1.7.

1.5.4 KL directe et KL inverse : le phénomène de zero-forcing

Un point souvent source de confusion, mais dont la compréhension éclaire directement l'une des limites de l'EM variationnel signalées à la section 1.7.9, concerne le choix particulier de la divergence KL minimisée par l'inférence variationnelle. La décomposition de la section précédente minimise KL[q ‖ p], c'est-à-dire la divergence dite « inverse » (reverse KL), et non KL[p ‖ q], la divergence « directe » (forward KL) qui serait utilisée, par exemple, dans l'estimation du maximum de vraisemblance d'un modèle paramétrique ajusté à des données. Ce choix n'est pas arbitraire : il est dicté par la tractabilité, puisque KL[q ‖ p] = $\mathbb{E}$_q[log q - log p] ne requiert que des espérances sous q, la distribution que l'on contrôle, alors que KL[p ‖ q] nécessiterait des espérances sous la véritable distribution a posteriori p, précisément celle que l'on cherche à approximer et que l'on ne sait pas calculer.

Ce choix a toutefois deux conséquences distinctes, qu'il faut nommer séparément car leurs remèdes diffèrent.

Premier effet : le mode-seeking, dû à la divergence KL inverse. La divergence KL inverse pénalise très fortement les régions où $q(z) > 0$ mais $p(z) \approx 0$, et tolère les régions où $q(z) \approx 0$ mais $p(z) > 0$. Lorsque la loi a posteriori p est multimodale, q se concentre donc sur un seul mode plutôt que de couvrir tous les modes (mode-seeking ou zero-forcing). Le posterior d'un GMM à K composantes est multimodal : il possède $K!$ modes symétriques par permutation des étiquettes, dont q n'en capture qu'un. Le remède relève du choix de la divergence (KL directe, divergences α) ou de la famille variationnelle.

Second effet : la sous-estimation de la variance, due à la factorisation. Même pour un posterior unimodal, l'hypothèse de champ moyen $q(Z, \theta) = q(Z)q(\theta)$ ignore la corrélation entre variables latentes et paramètres. La variance de q est alors mécaniquement inférieure à celle du posterior marginal, comme pour une gaussienne bivariée corrélée approchée par un produit de lois marginales. Ce second effet n'est pas lié à la multimodalité, et le remède relève d'une famille variationnelle plus riche (structurée, flux normalisants) plutôt que d'un changement de divergence.

La figure 1.1 illustre le premier effet. Les deux effets conduisent à des intervalles de crédibilité plus étroits que ceux d'une caractérisation exacte, un biais optimiste dont le praticien doit tenir compte. Leur importance quantitative dans le GMM n'est pas établie par ce chapitre : elle est mesurée par la couverture empirique de l'hypothèse HP6 (section 2.5.3).

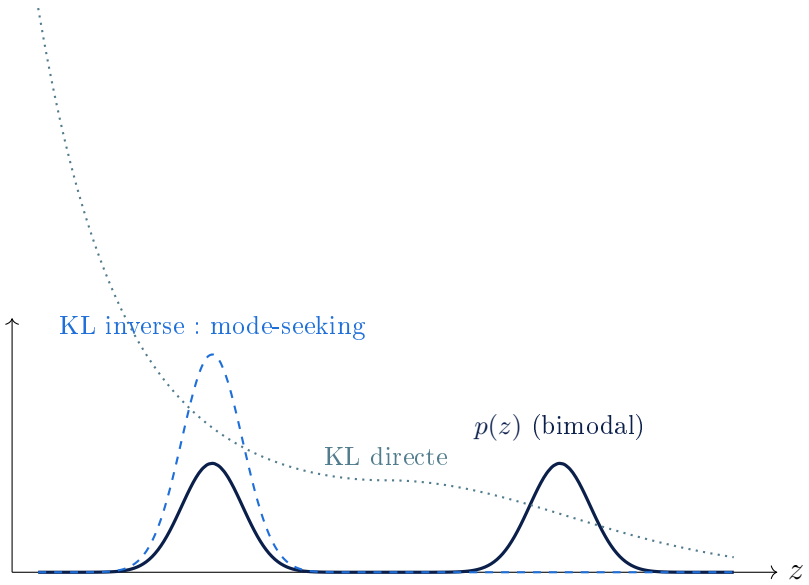


Figure 1.1: Premier effet de la KL inverse : sur un posterior multimodal, le q qui minimise $\mathrm{KL}[q \,\|\, p]$ se concentre sur un mode (tirets), alors que la KL directe $\mathrm{KL}[p \,\|\, q]$ étale q sur les modes (pointillés). Schéma illustratif, les hauteurs des courbes ne sont pas normalisées.

1.6 L'algorithme EM classique

1.6.1 Historique et contexte

L'algorithme Espérance-Maximisation a une histoire riche qui précède sa formalisation par Dempster, Laird et Rubin. Des idées similaires apparaissent dans les travaux de Hartley (1958) sur les tableaux de contingence, de Baum et al. (1970) dans le contexte des modèles de Markov cachés l'algorithme de Baum-Welch , et d'Orchard et Woodbury (1972) sur le traitement des données manquantes. C'est toutefois l'article de 1977 de Dempster, Laird et Rubin qui a unifié ces approches disparates sous un cadre théorique commun, démontré les propriétés générales de convergence, et fourni le langage étapes E et M devenu standard.

L'article original de Dempster, Laird et Rubin est remarquable par sa généralité : il ne se restreint pas à une classe particulière de modèles, mais formule l'algorithme dans le cadre général de la famille exponentielle, couvrant ainsi une large classe de modèles statistiques courants. Depuis 1977, l'EM a fait l'objet de milliers de publications, donnant lieu à de nombreuses extensions EM stochastique, EM online, EM généralisé, entre autres et à des applications dans presque tous les domaines des sciences des données.

Il est intéressant de noter que la démonstration originale de convergence proposée par Dempster, Laird et Rubin en 1977 comportait une lacune technique, corrigée seulement six ans plus tard par Wu (1983), qui établit les conditions précises sous lesquelles la suite des paramètres $\{\theta^t\}$ converge effectivement vers un point stationnaire de la vraisemblance, et non simplement la suite des valeurs de vraisemblance $\{\ell(\theta^t)\}$ une distinc-

tion subtile mais importante, puisqu'une suite de valeurs de vraisemblance convergente n'implique pas nécessairement, en toute généralité mathématique, la convergence de la suite des paramètres eux-mêmes. Cet épisode illustre un trait caractéristique du développement de l'algorithme EM : la simplicité de son principe opérationnel alterner deux étapes de calcul relativement élémentaires a longtemps contrasté avec la subtilité des conditions mathématiques précises garantissant son bon comportement, subtilité qui n'a été pleinement clarifiée que par les travaux théoriques ultérieurs de Wu (1983) et de Boyles (1983), puis, pour le versant bayésien de l'algorithme qui nous occupe à la section 1.7 de ce chapitre, par les travaux fondateurs de Jordan et al. (1999) évoqués à la section 1.7.1.

1.6.2 Formulation mathématique complète

a) L'algorithme en pseudocode

L'algorithme EM classique peut être formulé de manière concise. Il prend en entrée un jeu de données X = $\{x_1, \ldots,$ x_N$\}$, un nombre de composantes K et un critère d'arrêt ε, et retourne les paramètres estimés $\hat{\theta}$. Les grandes étapes en sont les suivantes : initialisation aléatoire ou par k-means des paramètres $\theta^0 = \{\pi_k^0, \mu_k^0, \Sigma_k^0\}_{k=1}^K$; puis, à chaque itération t, calcul des responsabilités à l'étape E, mise à jour des paramètres à l'étape M, et évaluation de la log-vraisemblance jusqu'à convergence, soit $|\ell(\theta^t) - \ell(\theta^{t-1})| < \varepsilon$, soit atteinte d'un nombre maximal d'itérations.

b) L'étape E en détail

L'étape E calcule la distribution conditionnelle q(Z) = p(Z | X, θ^t) des variables latentes sachant les observations et les paramètres courants. Cette distribution est représentée par les responsabilités r_{ik}, qui constituent les probabilités a posteriori d'appartenance :

$$r_{ik} = p(z_i = k|x_i,\theta^t) = \pi_k^t \mathcal{N}(x_i|\mu_k^t,\Sigma_k^t) / \Sigma_j \pi_j^t \mathcal{N}(x_i|\mu_j^t,\Sigma_j^t) \tag{1.15}$$

Ces responsabilités satisfont $r_{ik} \geq 0$ et $\Sigma_k\ r_{ik} = 1$ pour tout i. Elles peuvent être interprétées comme des affectations souples : plutôt que d'assigner chaque point à une seule composante, on lui attribue un poids continu pour chaque composante. Cette représentation souple capture naturellement l'incertitude sur l'appartenance dans les régions de chevauchement entre composantes.

Le calcul des responsabilités peut poser des problèmes numériques lorsque les densités gaussiennes sont très petites, ce qui conduit à un phénomène d'underflow. En pratique, on travaille en log-espace et on utilise l'astuce dite du log-sum-exp pour stabiliser les calculs.

c) L'étape M en détail

L'étape M maximise la fonction $Q(\theta \mid \theta^t) = \mathbb{E}_\{p(Z|X,\theta^t)\}[\log p(X, Z \mid \theta)]$ par rapport à θ. Pour le GMM, cette maximisation admet des solutions analytiques fermées. En différentiant Q par rapport à π_k, μ_k et Σ_k, et en annulant les gradients la contrainte $\Sigma_k\ \pi_k = 1$ étant traitée par un multiplicateur de Lagrange , on obtient les mises à jour :

$$\pi_k = N_k/N, \mu_k = (1/N_k)\Sigma_i r_{ik} x_i, \Sigma_k = (1/N_k)\Sigma_i r_{ik}(x_i - \mu_k)(x_i - \mu_k)^T \tag{1.16}$$

où $N_k = \Sigma_i\ r_{ik}$ désigne le nombre effectif de points assignés à la composante k une quantité réelle, pas nécessairement entière. Ces formules ont une interprétation intuitive claire : la nouvelle moyenne μ_k est la moyenne pondérée des données, avec des poids proportionnels aux responsabilités ; la nouvelle covariance Σ_k est la covariance empirique pondérée autour de cette nouvelle moyenne ; et le nouveau poids π_k est la fraction effective de données assignées à la composante k. La dérivation complète de ces trois formules, par annulation des gradients de la fonction Q, est détaillée ci-après, dans un souci de complétude mathématique.

d) Dérivation complète des mises à jour de l'étape M

Cette section détaille la dérivation des formules de mise à jour de l'étape M annoncées ci-dessus, à partir de l'expression explicite de la fonction Q pour le modèle de mélange gaussien. En développant la log-vraisemblance complète pour le GMM, on obtient :

$$Q(\theta|\theta^t) = \Sigma_i \Sigma_k r_{ik}[\log \pi_k + \log \mathcal{N}(x_i|\mu_k, \Sigma_k)] \tag{1.17}$$

Mise à jour de π_k. Le terme de Q qui dépend de π s'écrit $\Sigma_i\ \Sigma_k\ r_{ik}\ \log\ \pi_k$, sous la contrainte $\Sigma_k\ \pi_k = 1$. On introduit le lagrangien $L(\pi, \lambda) = \Sigma_i\ \Sigma_k\ r_{ik}\ log\ \pi_k + \lambda(1 - \Sigma_k\ \pi_k)$. En annulant la dérivée partielle par rapport à π_k, on obtient $\partial L/\partial \pi_k = \Sigma_i\ r_{ik}\ /\ \pi_k - \lambda = 0$, soit $\pi_k = N_k/\lambda$, où $N_k = \Sigma_i\ r_{ik}$. En sommant cette relation sur k et en utilisant la contrainte $\Sigma_k\ \pi_k = 1$, il vient $\Sigma_k\ N_k/\lambda = 1$, soit $\lambda = \Sigma_k\ N_k = N$ (le nombre total d'observations, puisque $\Sigma_k\ r_{ik} = 1$ pour chaque i). On en déduit immédiatement $\pi_k = N_k/N$, ce qui établit la première formule de mise à jour.

Mise à jour de μ_k. Le terme de Q qui dépend de μ_k s'écrit, à une constante additive près, $-\frac{1}{2}\ \Sigma_i\ r_{ik}\ (x_i-\mu_k)^T\ \Sigma_k^{-1}\ (x_i-\mu_k)$. En annulant le gradient par rapport à μ_k, on obtient $\partial Q/\partial \mu_k = \Sigma_i\ r_{ik}\ \Sigma_k^{-1}\ (x_i-\mu_k) = 0$. Comme Σ_k^{-1} est inversible, cette égalité équivaut à $\Sigma_i\ r_{ik}\ (x_i-\mu_k) = 0$, c'est-à-dire $\Sigma_i\ r_{ik}\ x_i = \mu_k\ \Sigma_i\ r_{ik} = \mu_k\ N_k$, d'où l'on tire directement $\mu_k = (1/N_k)\ \Sigma_i\ r_{ik}\ x_i$, ce qui établit la deuxième formule de mise à jour : la nouvelle moyenne est la moyenne empirique pondérée par les responsabilités.

Mise à jour de Σ_k. En substituant la nouvelle valeur de μ_k et en différentiant Q par rapport à Σ_k^{-1} (il est d'usage, pour cette dérivation, de différentier par rapport à la matrice de précision plutôt qu'à la covariance elle-même, ce qui simplifie les calculs matriciels), on utilise les deux identités classiques du calcul matriciel $\partial/\partial A \log|\mathrm{A}| = (A^T)^{-1}$ et $\partial/\partial A\ (x^T A x) = x x^T$. On obtient alors $\partial Q/\partial \Sigma_k^{-1} = \frac{1}{2}\ \Sigma_i\ r_{ik}\ [\Sigma_k$ - $(x_i$-$\mu_k)(x_i$-$\mu_k)^T] = 0$, ce qui conduit à $\Sigma_k\ \Sigma_i\ r_{ik} = \Sigma_i\ r_{ik}\ (x_i$-$\mu_k)(x_i$-$\mu_k)^T$, soit finalement $\Sigma_k = (1/N_k)\ \Sigma_i\ r_{ik}\ (x_i$-$\mu_k)(x_i$-$\mu_k)^T$, ce qui établit la troisième et dernière formule de mise à jour.

Cette dérivation complète met en évidence un point important : chacune des trois mises à jour de l'étape M résulte d'une simple annulation de gradient sur une fonction Q qui, conditionnellement aux responsabilités r_{ik} fixées à l'étape E, est concave séparément en π (à contrainte de somme fixée), en μ et en la matrice de *précision* $\Lambda = \Sigma^{-1}$ (et non en Σ elle-même). C'est précisément cette séparabilité qui rend l'étape M analytiquement soluble pour le GMM, alors que la log-vraisemblance incomplète $\ell(\theta)$, elle, ne l'est pas.

e) L'astuce du log-sum-exp

La stabilisation numérique du calcul des responsabilités, mentionnée à la section précédente, mérite d'être détaillée, car elle est systématiquement employée dans les implémentations pratiques de l'EM, qu'il s'agisse de l'EM classique ou de l'EM variationnel. Le problème se pose ainsi : on souhaite calculer $\log \Sigma_k \exp(a_k)$, où les $a_k = \log \pi_k + \log \mathcal{N}(x_i \mid \mu_k, \Sigma_k)$ peuvent être des nombres très négatifs (par exemple -500 ou moins), de sorte que $\exp(a_k)$ peut sous-déborder vers zéro. Le seuil dépend de la précision : en double précision (float64) $\exp(a)$ s'annule pour $a \lesssim -745$, donc -500 ne pose pas de problème ; en simple précision (float32) le seuil est d'environ -88 et -500 provoquerait une division par zéro lors du calcul des responsabilités. L'astuce du log-sum-exp reste indispensable dès que les log-densités sont très négatives (grande dimension, composantes éloignées).

L'astuce consiste à factoriser par le maximum des a_k avant d'exponentier :

$$\log \Sigma_k \exp(a_k) = a_{max} + \log \Sigma_k \exp(a_k - a_{max}),\ \text{où}\ a_{max} = \max_k a_k \tag{1.18}$$

Cette identité est mathématiquement triviale il suffit de factoriser exp(a_max) dans la somme puis de repasser au logarithme , mais elle change radicalement le comportement numérique du calcul : après soustraction de a_max, le terme correspondant au maximum vaut $\exp(0) = 1$, et tous les autres termes valent $\exp(a_k$ - a_max$) \leq 1$, ce qui élimine tout risque de dépassement de capacité (overflow) ou de perte de précision par underflow. C'est cette identité qui est utilisée, sous une forme ou une autre, dans les

deux implémentations from scratch présentées au chapitre 3 (sections 2.7.1 et 3.3.1).

f) La fonction Q et la garantie de croissance

La propriété de croissance monotone de l'EM repose sur la décomposition $\ell(\theta) = \mathrm{Q}(\theta \mid \theta^t)$ - $\mathbb{E}_\{\mathrm{p}(\mathrm{Z}|\mathrm{X},\theta^t)\}[\log \mathrm{p}(\mathrm{Z} \mid \mathrm{X}, \theta)]$ + constante. Comme l'étape M assure $\mathrm{Q}(\theta^{t+1} \mid \theta^t) \geq \mathrm{Q}(\theta^t \mid \theta^t)$, et que le terme soustractif ne diminue pas quand θ passe de θ^t à θ^{t+1} par la non-négativité de la divergence KL établie à la section 1.5 , on conclut que $\ell(\theta^{t+1}) \geq \ell(\theta^t)$: la log-vraisemblance ne peut donc que croître ou rester constante à chaque itération de l'algorithme.

1.6.3 Propriétés théoriques

a) Convergence : théorème principal

Le théorème de convergence de l'EM, établi par Dempster et al. (1977) et renforcé par Wu (1983), stipule que, sous des conditions de régularité standard (modèle lisse, espace des paramètres compact), la suite $\{\theta^t\}$ générée par l'algorithme EM satisfait les propriétés suivantes : la log-vraisemblance $\{\ell(\theta^t)\}$ est une suite croissante et bornée, donc convergente ; tout point d'accumulation de la suite $\{\theta^t\}$ est un point stationnaire de $\ell(\theta)$; la suite $\{\theta^t\}$ converge vers un point stationnaire si ℓ est unimodale, ou si la suite elle-même est convergente.

Il est important de noter que l'EM n'est pas garanti de converger vers le maximum global de la vraisemblance. Dans les modèles de mélanges, la surface de vraisemblance est typiquement multimodale, et l'algorithme converge vers le maximum local le plus proche du point de départ, ce qui justifie la pratique courante consistant à relancer l'algorithme depuis plusieurs initialisations différentes.

Limite du théorème pour le GMM. Les résultats de Wu (1983) supposent une vraisemblance continue et un ensemble de niveau compact. Le GMM à covariances libres ne les vérifie pas : sa vraisemblance est non bornée (si une composante s'effondre sur une observation, $\det \Sigma_k \to 0$ et $\ell \to +\infty$, section 1.6.8). Le théorème ne s'applique donc pas tel quel. Deux issues sont possibles : borner inférieurement les valeurs propres de Σ_k, ou parler de maximum local *restreint*. Le code utilise la première : chaque covariance reçoit $+\varepsilon I$ avec $\varepsilon = 10^{-6}$ (constante `REG_EM`, section 2.7.1). Les points stationnaires obtenus sont alors ceux de la vraisemblance régularisée, non ceux de la vraisemblance d'origine.

b) Vitesse de convergence linéaire

La vitesse de convergence locale de l'algorithme EM est linéaire, avec un taux de convergence donné par la valeur propre maximale de la matrice d'information manquante :

$$r = \lambda max(I_{comp}^{-1} I_{man}) \in [0,1) \tag{1.19}$$

où I_comp désigne la matrice d'information complète (information de Fisher qu'on aurait si les variables latentes étaient observées) et I_man la matrice d'information manquante, de sorte que I_obs = I_comp - I_man. La matrice I_comp^{-1} I_man = I - I_comp^{-1} I_obs est la matrice de taux établie par Dempster, Laird et Rubin (1977, section 3). Plus r est proche de 1 c'est-à-dire lorsque la proportion d'information manquante est élevée , plus la convergence est lente ; plus r est proche de 0, plus la convergence est rapide. Ce résultat explique pourquoi l'EM peut se révéler très lent dans certains problèmes comportant un grand nombre de variables latentes ou de fortes ambiguïtés d'appartenance.

c) Erreurs standard et information de Fisher

Bien que l'EM classique ne fournisse pas directement d'estimations d'incertitude, des intervalles de confiance asymptotiques peuvent être obtenus a posteriori en utilisant la matrice d'information de Fisher observée, calculée à la solution $\hat{\theta}$. La formule de Louis (1982) permet de calculer cette matrice d'information observée à partir des quantités calculées lors des itérations EM, selon I_obs($\hat{\theta}$) = I_comp($\hat{\theta}$) - I_man($\hat{\theta}$), où I_comp désigne la matrice d'information complète. Cette formule, bien que théoriquement fondée, est rarement utilisée en pratique en raison de sa complexité computationnelle, ce qui constitue l'une des limitations pratiques de l'EM classique pour la quantification de l'incertitude. Il existe des remèdes : le bootstrap (utilisé à la section 3.3), l'EM stochastique, l'EM supplémenté de Meng et Rubin (1991). L'EM variationnel ne « lève » pas cette limitation : les deux approches ne répondent pas à la même question. Un intervalle de confiance décrit la variabilité de l'estimateur sur des échantillons répétés ; un intervalle de crédibilité décrit la loi de θ sachant les données sous un prior donné, et celui du champ moyen n'est de plus qu'approché (section 1.5.4).

d) Garanties non asymptotiques sous mauvaise spécification

Les résultats précédents (Dempster et al., 1977 ; Wu, 1983) sont asymptotiques en nombre d'itérations et supposent le modèle bien spécifié. Une série de travaux récents donne des bornes non asymptotiques, en nombre d'observations n et en dimension d, sur la distance entre les itérés de l'EM et le paramètre visé. Ils distinguent l'EM *de population* (l'opérateur EM calculé sous la vraie loi, comme si $n = \infty$) et l'EM *empirique* (calculé sur l'échantillon) ; le cadre général de ce passage de la population à l'échantillon est dû à Balakrishnan, Wainwright et Yu (2017), cités par Dwivedi et al. (2020), article non consulté directement ici. Deux situations intéressent directement ce travail, car l'EM-$K_{\max}$ du chapitre 2 ajuste plus de composantes qu'il n'en existe, et

les données réelles du chapitre 3 (prix alimentaires) ne sont pas des mélanges gaussiens exacts.

Sur-spécification (Dwivedi, Ho, Khamaru, Wainwright, Jordan et Yu, 2020). Les données suivent une loi $\mathcal{N}(0, \sigma^2 I_d)$ et l'on ajuste, par l'EM, le mélange symétrique $\pi\,\mathcal{N}(\theta, \sigma^2 I_d) + (1-\pi)\,\mathcal{N}(-\theta, \sigma^2 I_d)$, à poids π et variance σ^2 *connus* : le vrai paramètre est $\theta^* = 0$, et le modèle a une composante de trop. Les auteurs établissent une rupture nette entre deux cas.

- *Cas déséquilibré* ($\pi \neq 1/2$, théorème 1) : l'EM de population converge géométriquement vers θ^*, et l'EM empirique atteint, en $O(\log(n/d))$ itérations, une boule de rayon $O((d/n)^{1/2})$ autour de θ^*, le taux paramétrique usuel.

- *Cas équilibré* ($\pi = 1/2$, théorèmes 2 et 3) : le coefficient de contraction de l'EM de population tend vers 1 quand l'itéré approche θ^*, de sorte que la convergence devient « exponentiellement plus lente » (termes des auteurs) : il faut de l'ordre de $\log(1/\varepsilon)/\varepsilon^2$ itérations pour une précision ε, contre $O(\log(1/\varepsilon))$ dans le cas déséquilibré. L'EM empirique atteint, après $O((n/d)^{1/2})$ itérations, une boule de rayon de l'ordre de $(d/n)^{1/4}$ (à un facteur logarithmique près), qui coïncide avec le taux $n^{-1/4}$ établi par Chen (1995) pour le maximum de vraisemblance global des mélanges sur-spécifiés.

Les auteurs relient cette différence à la singularité de la matrice d'information de Fisher au point $\theta^* = 0$ dans le cas équilibré (annexe D de l'article, présentée comme une justification heuristique, non comme une preuve). Deux précisions limitent la portée de ces résultats pour ce travail. D'une part, les théorèmes portent sur un modèle très contraint (moyennes symétriques, poids et variance connus) ; avec des poids inconnus (section 5.1 de l'article), la convergence est rapide seulement si l'initialisation est fortement déséquilibrée, et lente sinon. D'autre part, la persistance du taux lent pour des mélanges plus généraux (plus de deux composantes, covariances libres) n'est étayée que par des expériences numériques (section 5.3), sans démonstration. Ces résultats ne prouvent donc rien sur l'EM-$K_{\max}$ à covariances libres du chapitre 2 ; ils indiquent seulement qu'un nombre élevé d'itérations et une estimation imprécise des paramètres des composantes superflues sont attendus en sur-spécification, ce qui n'est pas une défaillance de l'implémentation. Aucune expérience de ce travail ne mesure la pente de l'erreur en fonction de n : c'est une piste ouverte.

Sous-spécification et projection de Kullback-Leibler (Dwivedi, Ho, Khamaru, Wainwright et Jordan, 2018). Lorsque le modèle ajusté ne contient pas la vraie loi P, la cible de l'EM n'est plus un « vrai » paramètre mais la projection de P sur la famille ajustée,

$$\theta^\dagger = \arg\min_{\theta} \mathrm{KL}(P \,\|\, P_\theta).$$

Les auteurs étudient deux classes univariées à variance connue : un mélange vrai à trois composantes ajusté par un mélange symétrique à deux composantes, et un mélange à deux composantes dont les poids ou les variances sont mal spécifiés. Ils caractérisent le biais $|\theta^\dagger - \theta^*|$ dû à la mauvaise spécification, montrent que l'EM de population converge géométriquement vers $\theta^\dagger$ sous une initialisation convenable (et, dans la seconde classe, depuis une initialisation quelconque), et en déduisent que l'EM empirique atteint une boule de rayon $O(n^{-1/2})$ autour de $\theta^\dagger$. Pour ce travail, la conséquence est d'ordre interprétatif : sur des données à queues épaisses (scénario S4) ou réelles (chapitre 3), les paramètres estimés par l'EM approchent la meilleure approximation gaussienne au sens de la divergence KL, non des « groupes vrais » ; un écart d'ARI à une partition de référence mesure donc aussi l'écart entre cette projection et la référence. Le VB à priors conjugués optimise une autre fonction objectif, et ces résultats ne s'y transposent pas sans démonstration.

1.6.4 Application au mélange gaussien : exemple numérique détaillé

Afin d'illustrer concrètement le fonctionnement de l'algorithme EM classique, considérons N = 8 observations scalaires : X = {0,5 ; 1,0 ; 1,2 ; 1,8 ; 7,1 ; 7,5 ; 8,0 ; 8,3}. Nous supposons K = 2 composantes gaussiennes, avec pour initialisation $\mu_1^0 = 2$, $\mu_2^0 = 6$, $\sigma_1^0 = \sigma_2^0 = 2$, $\pi_1^0 = \pi_2^0 = 0{,}5$. Le tableau 1.2 retrace l'évolution des paramètres au fil des itérations ; la log-vraisemblance indiquée est celle des paramètres obtenus à l'issue de l'étape M de l'itération considérée.

Tableau 1.2: Convergence de l'algorithme EM sur l'exemple numérique à $K = 2$ composantes (8 observations)

Itération	μ_1	μ_2	σ_1	σ_2	π_1	π_2	**Log-vraisemblance**
0	2,000	6,000	2,000	2,000	0,500	0,500	non rapportée
1	1,284	7,368	1,134	1,549	0,484	0,516	-15,814
2	1,125	7,722	0,466	0,479	0,500	0,500	-10,742
3	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
4	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
5	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
6	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
7	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
8	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
9	1,125	7,725	0,466	0,460	0,500	0,500	-10,736
10	1,125	7,725	0,466	0,460	0,500	0,500	-10,736

La convergence est très rapide : le point fixe est atteint en trois itérations, la variation de la log-vraisemblance devenant inférieure à 10^{-3} dès l'itération suivante. La log-vraisemblance croît de -15,814 à -10,736 sans jamais diminuer, conformément à la

garantie théorique établie précédemment. La solution finale identifie correctement les deux groupes : le premier est centré sur 1,125 (moyenne empirique des observations 0,5 ; 1,0 ; 1,2 et 1,8) avec un écart-type de 0,466, le second sur 7,725 (moyenne empirique de 7,1 ; 7,5 ; 8,0 et 8,3) avec un écart-type de 0,460. Les deux groupes étant très éloignés l'un de l'autre, les responsabilités valent 1 ou 0 à la précision de la machine et les paramètres estimés coïncident avec les statistiques empiriques de chaque groupe.

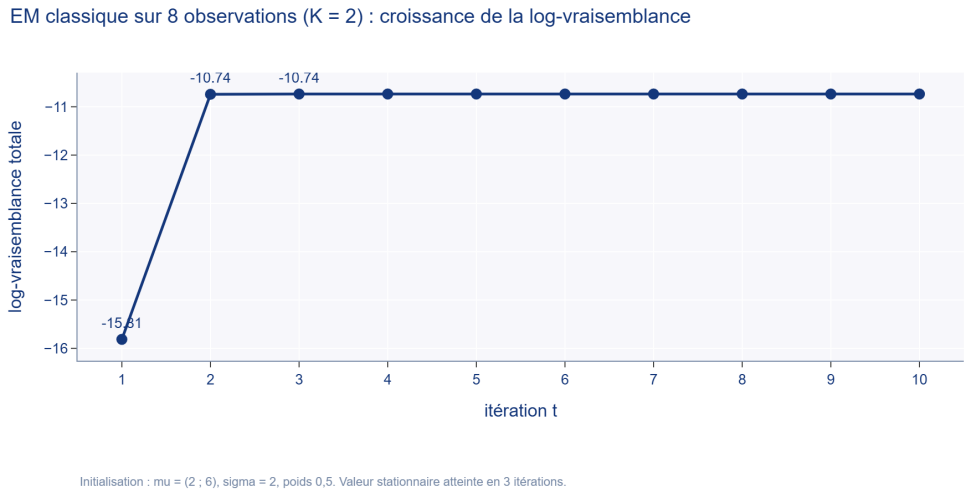


Figure 1.2: Évolution de la log-vraisemblance au fil des itérations (exemple numérique de la section 1.6.4). La courbe est croissante puis stationnaire dès la troisième itération, ce qui illustre la garantie de monotonie établie à la section 1.6.2.f.

1.6.5 Variantes de l'EM classique

Variante	**Modification**	**Avantage**	**Inconvénient**
EM standard	Aucune	Simple, convergence garantie	Lent sur grandes données
EM stochastique (SEM)	Étape E : tirage aléatoire	Évite certains optima locaux	Pas de monotonie
EM online	Mise à jour incrémentale	Scalable	Choix du taux d'apprentissage
EM généralisé (GEM)	Étape M approchée	Flexible	Convergence plus lente
EM accéléré (ECME)	Étape CM-E alternée	Convergence plus rapide	Complexité accrue

Tableau 1.3: Principales variantes de l'algorithme EM classique

L'EM stochastique, proposé par Celeux et Diebolt (1985), modifie l'étape E en remplaçant le calcul des responsabilités par un tirage aléatoire : chaque observation est assignée à une seule composante selon la distribution définie par les responsabilités. Cette introduction de stochasticité permet d'éviter certains optima locaux, de calculer des estimations d'incertitude empiriques, et d'explorer plus largement l'espace des paramètres, au prix de la perte de la propriété de monotonie de la vraisemblance.

Pour les grandes bases de données, l'EM standard, dit « batch », traite l'ensemble des données à chaque itération, ce qui peut se révéler prohibitif. L'EM online, proposé par Sato et Ishii (2000) puis par Cappé et Moulines (2009), met à jour les paramètres après chaque observation ou mini-lot, réduisant drastiquement le coût par itération, et converge dans les mêmes conditions que l'EM standard sous des conditions de type Robbins-Monro sur le taux d'apprentissage.

L'EM généralisé remplace l'étape M exacte par une étape qui améliore, sans nécessairement maximiser, la fonction Q : on requiert seulement $\mathrm{Q}(\theta^{t+1} \mid \theta^t) \geq \mathrm{Q}(\theta^t \mid \theta^t)$, au lieu d'une maximisation exacte. La propriété de croissance monotone de la vraisemblance est préservée sous cette condition plus faible, ce qui rend le GEM utile lorsque l'étape M exacte est coûteuse ou n'admet pas de solution analytique.

Enfin, l'application originale ayant motivé l'article de Dempster et al. était précisément le traitement des données manquantes. Lorsque certaines composantes de x_i sont manquantes, on peut traiter les valeurs manquantes comme des variables latentes supplémentaires, et l'algorithme EM impute naturellement ces valeurs en calculant leur espérance conditionnelle à l'étape E. Cette approche est asymptotiquement plus efficace que l'imputation simple et produit des estimateurs cohérents sous l'hypothèse MCAR ou MAR.

1.6.6 Extension aux données séquentielles : l'algorithme de Baum-Welch

Une application particulièrement importante de l'algorithme EM, mentionnée à plusieurs reprises dans ce mémoire (tableau 1.1, section 1.6.1 et section 3.6), concerne les modèles de Markov cachés (HMM), utilisés notamment en bio-informatique et en finance. Contrairement au GMM, où les observations sont supposées indépendantes conditionnellement à leur variable latente, un HMM suppose que la séquence des variables latentes (z_1, …, z_T) forme elle-même une chaîne de Markov : z_t dépend de z_{t-1} selon une matrice de transition A, et chaque observation x_t dépend de l'état caché courant z_t selon une matrice d'émission B. Cette structure séquentielle empêche le calcul direct des responsabilités comme à l'équation (1.15), puisque les variables latentes ne sont plus indépendantes entre elles : l'étape E doit être remplacée par l'algorithme forward-backward, qui exploite la structure de chaîne pour calculer efficacement, par

programmation dynamique, les probabilités a posteriori nécessaires. L'algorithme résultant, connu sous le nom d'algorithme de Baum-Welch (Baum et al., 1970), est historiquement antérieur à la formalisation générale de Dempster, Laird et Rubin, mais en constitue, comme le notent ces derniers dans leur article de 1977, un cas particulier.

Illustration numérique. Considérons un HMM discret à deux états cachés (« Beau temps » = B, « Pluvieux » = P), avec une matrice de transition A = [[0,7 ; 0,3], [0,4 ; 0,6]] (A_{ij} = P(z_{t+1}=j | z_t=i)), et une matrice d'émission B qui associe à chaque état une probabilité d'observer « Parapluie » (Pa) ou « Pas de parapluie » (NPa) : B(B) = [0,1 ; 0,9] et B(P) = [0,8 ; 0,2]. Étant donné une courte séquence observée O = (NPa, Pa, Pa), l'étape E (forward-backward) calcule, pour chaque instant t et chaque état i, la probabilité a posteriori γ_t(i) = p(z_t=i | O), de la même manière que r_{ik} à l'équation (1.15) pour le GMM, mais en tenant compte de la dépendance séquentielle via les récursions forward α_t(i) = [Σ_j α_{t-1}(j) A_{ji}] $B_i(o_t)$ et backward β_t(i) = Σ_j A_{ij} $B_j(o_{t+1})$ β_{t+1}(j).

Une fois les quantités γ_t(i) calculées, l'étape M du Baum-Welch réestime les matrices A et B par des formules directement analogues à l'équation (1.16) du GMM, en remplaçant les responsabilités r_{ik} par les quantités γ_t(i) et ξ_t(i,j) = p(z_t=i, z_{t+1}=j | O) : $\hat{A}_{ij}$ = Σ_t ξ_t(i,j) / Σ_t γ_t(i), et $\hat{B}_i$(v) = Σ_{t : o_t=v} γ_t(i) / Σ_t γ_t(i). Cette correspondance formelle entre les mises à jour du Baum-Welch et celles du GMM illustre concrètement l'affirmation, faite à la section 1.6.1, selon laquelle l'EM constitue un cadre général unifiant des algorithmes historiquement développés de façon indépendante : le Baum-Welch n'est rien d'autre qu'un EM classique dans lequel l'étape E est rendue efficace, par programmation dynamique, pour tenir compte de la dépendance séquentielle entre variables latentes successives une adaptation que l'on retrouve, sous une forme analogue, dans les extensions séquentielles de l'EM variationnel évoquées à la section 1.7.7.

Calcul numérique complet de l'étape E. Pour rendre entièrement concret le mécanisme décrit ci-dessus, calculons explicitement les quantités forward α_t(i), backward β_t(i) et les probabilités a posteriori γ_t(i) pour la séquence observée O = (NPa, Pa, Pa), avec les matrices A et B et la distribution initiale π_0 = (0,6 ; 0,4) données ci-dessus. Le tableau 1.4 présente le détail de ce calcul.

Tableau 1.4: Calcul détaillé des quantités forward, backward et a posteriori pour O = (NPa, Pa, Pa)

t	**Observation** o_t	α_t**(B)**	α_t**(P)**	β_t**(B)**	β_t**(P)**	γ_t**(B)**	γ_t**(P)**
1	NPa	0,540	0,080	0,147	0,262	0,791	0,209
2	Pa	0,041	0,168	0,310	0,520	0,127	0,873
3	Pa	0,010	0,090	1,000	1,000	0,096	0,904

La dernière colonne du tableau se lit comme suit : après observation de la séquence

complète (NPa, Pa, Pa), la probabilité a posteriori que le temps ait été « Beau » (B) au premier instant est de 0,791 (malgré l'absence de parapluie ce jour-là, cohérent avec un temps beau), tandis qu'elle chute à 0,127 au deuxième instant et à 0,096 au troisième, la présence du parapluie aux instants 2 et 3 rendant l'état « Pluvieux » (P) très majoritairement probable a posteriori (γ_2(P) = 0,873 et γ_3(P) = 0,904). On notera que Σ_i γ_t(i) = 1 à chaque instant t, exactement comme Σ_k r_{ik} = 1 pour les responsabilités du GMM à l'équation (1.15) les quantités γ_t(i) jouant, pour le HMM, exactement le rôle que jouent les responsabilités r_{ik} pour le GMM. La probabilité totale de la séquence observée, obtenue en sommant α_t(i) sur i au dernier instant, vaut p(O | A, B, π_0) = α_3(B) + α_3(P) = 0,010 + 0,091 = 0,100.

1.6.7 Avantages de l'EM classique

- **Simplicité et transparence :** l'algorithme EM est conceptuellement clair et facile à comprendre. Les deux étapes E et M ont des interprétations directes, et les mises à jour sont souvent analytiques, ce qui facilite l'implémentation, le débogage et l'adaptation à de nouveaux modèles.

- **Garantie de convergence monotone :** la log-vraisemblance ne peut que croître ou rester constante à chaque itération. Cette propriété offre une sécurité précieuse : l'algorithme ne peut pas « se dégrader » au fil des itérations, et la log-vraisemblance constitue un critère de convergence naturel.

- **Efficacité computationnelle par itération :** chaque itération de l'EM a un coût fixe en O(NKD^2), aisément vectorisable. Pour des problèmes de taille modérée, l'EM est extrêmement rapide et se parallélise bien.

- **Applicabilité universelle :** l'EM s'applique à n'importe quel modèle probabiliste pour lequel p(Z | X, θ) est calculable et $\mathbb{E}$[log p(X, Z | θ)] est maximisable, ce qui couvre une immense variété de modèles en pratique.

- **Gestion naturelle des données incomplètes :** par construction, l'EM intègre sur les valeurs manquantes, produisant des estimateurs asymptotiquement efficaces sans recourir à des heuristiques d'imputation.

- **Convergence rapide loin de l'optimum :** bien que la convergence soit linéaire asymptotiquement, l'EM converge souvent très rapidement lors des premières itérations, permettant d'obtenir de bonnes solutions en peu d'itérations.

Renvois à la grille du tableau 3.1 : garantie de croissance → ligne « Monotonie du critère » (théorème, tests unitaires) ; efficacité par itération et convergence rapide loin de l'optimum → « Coût de calcul » ; simplicité, applicabilité universelle et données

incomplètes → affirmations qualitatives ou théoriques sans ligne expérimentale (« non testé » dans ce mémoire).

1.6.8 Inconvénients et limites de l'EM classique

- **Convergence vers des optima locaux :** l'EM converge vers un point stationnaire de la vraisemblance, généralement un maximum local. Sur les problèmes multimodaux, comme les GMM à composantes proches, la solution trouvée peut être significativement sous-optimale par rapport au maximum global.

- **Nécessité de spécifier K a priori :** le nombre de composantes K doit être fixé avant l'exécution de l'algorithme. Une mauvaise spécification de K conduit inévitablement à des résultats sous-optimaux : la sous-estimation entraîne des composantes trop larges fusionnant des groupes distincts, tandis que la surestimation entraîne des composantes redondantes ou dégénérées. C'est précisément cette limite que nous illustrerons expérimentalement au chapitre 2, à travers un cas où K est volontairement surestimé.

- **Incertitude non native :** l'EM classique fournit une estimation ponctuelle $\hat{\theta}$; une incertitude s'obtient a posteriori (formule de Louis, 1982, bootstrap, EM supplémenté de Meng et Rubin, 1991, EM stochastique), au prix de calculs supplémentaires. Ces intervalles sont de confiance, non de crédibilité (section 1.6.3.c).

- **Singularités et dégénérescences :** un problème bien connu du GMM est la possibilité de convergence vers des solutions singulières, une composante pouvant s'effondrer sur un seul point de données, sa variance tendant vers zéro, ce qui provoque une divergence de la log-vraisemblance vers l'infini. Des stratégies ad hoc, telles que la régularisation de la covariance, sont nécessaires pour éviter ce problème.

- **Lenteur de convergence :** le taux de convergence linéaire peut rendre l'algorithme très lent dans les régions proches de l'optimum, en particulier lorsque les composantes se chevauchent fortement. Ce défaut n'est pas propre à l'EM classique : l'EM variationnel batch a le même ordre de coût par itération (section 2.2.1) ; la comparaison du nombre d'itérations exige un critère d'arrêt commun (sections 2.4.1 et 3.1.8).

- **Scalabilité limitée :** la version batch standard nécessite de traiter toutes les données à chaque itération, ce qui devient prohibitif pour des bases de plusieurs millions d'observations, sans recourir aux variantes online ou mini-batch. La même limite vaut pour la version batch de l'EM variationnel ; les variantes online (EM online) et stochastique (SVI) existent pour les deux (sections 1.6.5 et 1.7.7).

Renvois à la grille du tableau 3.1 : optima locaux → « Initialisation » (expérience unique) ; K à fixer → « Sélection de K », « Sous-estimation de K » ; incertitude non native → « Incertitude » ; singularités → « Singularités, petit N » et « Convergence de l'EM pour le GMM » ; lenteur et scalabilité → « Coût de calcul ».

1.7 L'algorithme EM variationnel

1.7.1 Motivation et cadre général

Les limitations identifiées à la section 1.6.8 motivent naturellement le développement d'une approche plus riche. L'EM variationnel émerge à la confluence de deux courants : l'inférence bayésienne, qui traite les paramètres comme des variables aléatoires et vise à caractériser leur distribution a posteriori complète, et l'optimisation variationnelle, qui transforme le problème d'inférence généralement intractable en un problème d'optimisation sur un espace de distributions plus simples.

Le cadre variationnel trouve ses racines dans les travaux de Hinton et van Camp (1993) sur les réseaux de neurones bayésiens, de Peterson et Anderson (1987) sur les champs moyens pour les réseaux de Boltzmann, et a été synthétisé et généralisé par Jordan, Ghahramani, Jaakkola et Saul (1999) dans leur article fondateur sur les méthodes variationnelles pour les modèles graphiques. Depuis lors, l'inférence variationnelle est devenue l'une des méthodes d'inférence approchée les plus utilisées en apprentissage automatique probabiliste. Pour le mélange gaussien, le traitement variationnel à priors conjugués est généralement rattaché à Attias (2000) et il est exposé en détail par Bishop (2006, section 10.2), dont ce travail suit les équations. Corduneanu et Bishop (2001) en donnent une variante distincte : les poids de mélange π n'y reçoivent pas de prior de Dirichlet, ils sont traités comme des paramètres ponctuels et estimés par maximisation de la borne inférieure (maximum de vraisemblance de type II), tandis que (μ_k, Λ_k) restent aléatoires (section 1.7.4). L'article d'Attias n'a pas été consulté dans le texte original ; il n'est cité que pour l'historique.

1.7.2 Inférence variationnelle

a) Le problème d'inférence bayésienne

Dans le cadre bayésien complet, on cherche à calculer la distribution a posteriori jointe sur les paramètres et les variables latentes, $\mathrm{p}(\theta, \mathrm{Z} \mid \mathrm{X}) = \mathrm{p}(\mathrm{X} \mid \mathrm{Z}, \theta)\ \mathrm{p}(\mathrm{Z} \mid \theta)\ \mathrm{p}(\theta)\ /\ \mathrm{p}(\mathrm{X})$. Le dénominateur, $\mathrm{p}(\mathrm{X}) = \int\int \mathrm{p}(\mathrm{X} \mid \mathrm{Z}, \theta)\ \mathrm{p}(\mathrm{Z} \mid \theta)\ \mathrm{p}(\theta)\ \mathrm{dZ}\ d\theta$, est la vraisemblance marginale, ou évidence. Son calcul nécessite une intégrale de haute dimension, généralement intractable analytiquement pour des modèles non triviaux. Sans ce dénominateur, on ne peut pas normaliser la distribution a posteriori. L'inférence variationnelle

contourne ce problème en remplaçant le calcul exact de p(θ, Z | X) par l'optimisation d'une approximation.

b) La famille variationnelle et le problème d'optimisation

L'inférence variationnelle introduit une famille de distributions $\mathcal{Q} = \{q(\theta, Z \mid \lambda), \lambda \in \Lambda\}$, paramétrée par des paramètres variationnels λ. L'objectif est de trouver le membre de cette famille le plus proche de la vraie distribution a posteriori, au sens de la divergence de Kullback-Leibler :

$$q*(\theta,Z) = \underset{q\in\mathcal{Q}}{\operatorname{argmin}}\, KL[q(\theta,Z)\|p(\theta,Z|X)] \tag{1.20}$$

Cette divergence ne peut pas être calculée directement, car elle fait intervenir p(X) dans sa normalisation. On montre cependant que minimiser cette divergence est équivalent à maximiser l'ELBO, qui lui est calculable :

$$ELBO(q) = \mathbb{E}_q[\log p(X,Z,\theta)] - \mathbb{E}_q[\log q(\theta,Z)] \tag{1.21}$$

Cette reformulation est la clé de l'inférence variationnelle : un problème d'inférence, à savoir le calcul d'une distribution, est transformé en un problème d'optimisation, à savoir la maximisation d'une fonctionnelle de q, qui peut être traité par des algorithmes d'optimisation standard.

c) L'ELBO comme objectif d'apprentissage

L'ELBO peut être décomposé de deux manières complémentaires, chacune offrant une interprétation différente. La première décomposition montre l'ELBO comme la différence entre la vraisemblance attendue et la complexité du modèle :

$$ELBO(q) = \mathbb{E}_q[\log p(X|Z,\theta)] - KL[q(\theta,Z)\|p(\theta,Z)] \tag{1.22}$$

Le premier terme, la log-vraisemblance attendue sous q, mesure la qualité de l'ajustement aux données ; le second terme, la divergence KL entre la distribution variationnelle et le prior joint, pénalise les distributions q qui s'écartent trop du prior, réalisant ainsi une forme de régularisation bayésienne automatique. La maximisation de l'ELBO réalise donc un compromis naturel entre ajustement aux données et fidélité au prior.

La seconde décomposition, déjà introduite à la section 1.5.3, montre l'ELBO comme une borne inférieure de la log-évidence : log p(X) = ELBO(q) + KL[q(θ, Z) ‖ p(θ, Z | X)] $\geq$ ELBO(q). Cette décomposition éclaire l'usage de l'ELBO en sélection de modèle bayésien, mais en borne aussi la portée : l'ELBO n'est qu'une borne inférieure de la log-évidence, et l'écart KL qui les sépare dépend du modèle et de la famille variationnelle. Un ELBO plus élevé à la convergence ne garantit donc pas une évidence plus grande

; comparer deux modèles par leur ELBO revient à comparer deux bornes, ce qui n'est justifié que si leurs écarts KL sont du même ordre (point repris dans la discussion des limites du VB).

1.7.3 Formulation de l'EM variationnel

a) L'hypothèse du champ moyen

L'hypothèse la plus courante pour définir la famille variationnelle $\mathcal{Q}$ est l'hypothèse du champ moyen, qui suppose une factorisation complète de la distribution variationnelle sur les différentes variables :

$$q(\theta,Z) = q(\theta)\prod_i q(z_i) = q(\pi)\prod_k q(\mu_k,\Lambda_k)\prod_i q(z_i) \tag{1.23}$$

Cette hypothèse ignore les corrélations a posteriori entre les paramètres θ et les variables latentes Z, ainsi qu'entre les variables latentes de différentes observations. Si cette indépendance est rarement exacte dans la vraie distribution a posteriori, elle simplifie considérablement le problème d'optimisation en le rendant décomposable en sous-problèmes indépendants, tout en restant une approximation raisonnable dans de nombreuses applications.

b) Les mises à jour variationnelles optimales

Sous l'hypothèse du champ moyen, la solution variationnelle optimale pour chaque facteur $q_j(z_j)$ est donnée par la formule du champ moyen variationnel :

$$\log q*_j\,(z_j) = \mathbb{E}_{q(z\setminus z_j)}[\log p(X,Z,\theta)] + constante \tag{1.24}$$

Cette mise à jour prend l'espérance de la log-distribution jointe par rapport à tous les autres facteurs, en maintenant z_j fixe, la constante additive assurant la normalisation. Cette formule est générale et s'applique à n'importe quel facteur, qu'il s'agisse d'une variable latente ou d'un paramètre. Dans le cas des modèles conjugués, cette espérance peut être calculée analytiquement et conduit à une distribution de la même famille que le prior correspondant.

c) Dérivation détaillée pour le mélange gaussien bayésien

Cette section applique explicitement la formule générale du champ moyen variationnel, énoncée ci-dessus, au cas particulier du mélange gaussien bayésien, afin de montrer comment les formes de Dirichlet et de Normal-Wishart, utilisées dans l'algorithme de la section 1.7.3.d, se déduisent directement de cette formule générale plutôt que d'être postulées arbitrairement.

Facteur q(π). En isolant, dans le logarithme de la distribution jointe complète log p(X, Z, π, μ, Λ), les seuls termes qui dépendent de π, on obtient log p(Z | π) + log p(π) = Σ_i Σ_k z_{ik} log π_k + Σ_k (α_0-1) log π_k + constante, où z_{ik} désigne l'indicatrice z_i = k. En appliquant la formule du champ moyen, on prend l'espérance de cette expression par rapport à q(Z), ce qui revient à remplacer z_{ik} par son espérance $r_{ik} = \mathbb{E}_q[z_{ik}]$:

$$\log q*(\pi) = \Sigma_k(\alpha_0 - 1 + N_k)\log \pi_k + \text{constante, où } N_k = \Sigma_i r_{ik} \tag{1.25}$$

Cette expression est, à une constante de normalisation près, exactement le logarithme de la densité d'une distribution de Dirichlet de paramètres $\alpha_k = \alpha_0 + N_k$. On retrouve ainsi directement, par simple application de la formule générale, la mise à jour α_k = α_0 + N_k utilisée à la section 1.7.3.d, sans qu'il soit nécessaire de la postuler : elle découle mécaniquement de la conjugaison entre le prior de Dirichlet et la vraisemblance catégorielle.

Facteur q(μ_k, Λ_k). De façon similaire, en isolant les termes qui dépendent de (μ_k, Λ_k) dans log p(X, Z, π, μ, Λ), on obtient une contribution de la vraisemblance gaussienne, Σ_i r_{ik} log $\mathcal{N}(x_i \mid \mu_k, \Lambda_k^{-1})$, à laquelle s'ajoute le logarithme du prior Normal-Wishart log p(μ_k, Λ_k). Cette somme, une fois réorganisée en complétant le carré sur μ_k une manipulation algébrique standard pour les formes quadratiques gaussiennes , se réécrit comme le logarithme d'une densité Normal-Wishart de paramètres mis à jour :

$$\beta_k = \beta_0 + N_k, m_k = (\beta_0 m_0 + N_k \bar{x}_k)/\beta_k, \nu_k = \nu_0 + N_k, W_k^{-1} = W_0^{-1} + N_k S_k + [\beta_0 N_k/(\beta_0 + N_k)](\bar{x}_k - m_0)(\bar{x}_k - m_0)^T \tag{1.26}$$

où $\bar{x}_k$ et S_k désignent respectivement la moyenne et la covariance empiriques pondérées par les responsabilités, telles que définies à la section 1.7.3.d. Le terme β_k s'interprète comme une « taille d'échantillon effective augmentée » (la taille d'échantillon effective N_k à laquelle s'ajoute la pseudo-taille d'échantillon β_0 du prior), tandis que le dernier terme correctif dans la mise à jour de W_k^{-1} traduit l'incertitude supplémentaire due à l'écart entre la moyenne empirique du cluster $\bar{x}_k$ et la moyenne a priori m_0 : plus cet écart est grand par rapport à la confiance relative accordée au prior (mesurée par le rapport $\beta_0 N_k/(\beta_0 + N_k)$), plus l'inverse W_k^{-1} de la matrice d'échelle de la loi de Wishart augmente. La précision attendue $\mathbb{E}[\Lambda_k] = \nu_k W_k$ diminue alors, ce qui élargit la covariance attendue de la composante et, par $\mu_k \mid \Lambda_k \sim \mathcal{N}(m_k, (\beta_k \Lambda_k)^{-1})$, la distribution a posteriori sur μ_k.

Cette dérivation confirme, de façon rigoureuse, que les formules de mise à jour utilisées à la section 1.7.3.d ne sont pas de simples analogues heuristiques de l'étape M classique : elles sont la conséquence mathématique directe et nécessaire de l'application de la formule générale du champ moyen variationnel au choix spécifique de priors conjugués effectué à la section 1.4.2. Ce même schéma de dérivation isoler les termes per-

tinents dans la log-distribution jointe, prendre leur espérance sous les autres facteurs, puis reconnaître la forme conjuguée résultante se généralise sans difficulté conceptuelle à tout modèle à variables latentes construit à partir de distributions conjuguées, ce qui explique la popularité de l'hypothèse du champ moyen dans la pratique de l'inférence variationnelle.

d) L'algorithme EM variationnel

L'algorithme EM variationnel alterne entre deux étapes, analogues aux étapes E et M de l'EM classique, mais opérant sur des distributions plutôt que sur des estimations ponctuelles. L'algorithme prend en entrée les observations X, un nombre maximal de composantes Kmax, les hyperparamètres du prior $\{\alpha_0, m_0, \beta_0, W_0, \nu_0\}$, ainsi qu'un critère d'arrêt ε.

Initialisation. Les paramètres variationnels sont initialisés : $\alpha_k = \alpha_0 + \mathrm{N/K}$, $N_k = \mathrm{N/K}$, $m_k = m_0 +$ perturbation aléatoire, $\beta_k = \beta_0 + N_k$, $\nu_k = \nu_0 + N_k$, $W_k = W_0$.

Étape E variationnelle. Pour chaque observation i et chaque composante k, on calcule :

$$\log \rho_{ik} = \mathbb{E}[\log \pi_k] + \tfrac{1}{2}\mathbb{E}[\log |\Lambda_k|] - (D/2)\log(2\pi) - \tfrac{1}{2}\mathbb{E}[(x_i - \mu_k)^T \Lambda_k (x_i - \mu_k)] \quad (1.27)$$

puis on normalise pour obtenir les responsabilités : $r_{ik} = \exp(\log \rho_{ik}) \,/\, \Sigma_j \exp(\log \rho_{ij})$.

Étape M variationnelle. Pour chaque composante k, on calcule $N_k = \Sigma_i\, r_{ik}$, $\bar{x}_k = (1/N_k)\ \Sigma_i\, r_{ik}\ x_i$, et $S_k = (1/N_k)\ \Sigma_i\, r_{ik}\ (x_i\text{-}\bar{x}_k)(x_i\text{-}\bar{x}_k)^T$, avant de mettre à jour les paramètres des lois de Dirichlet et Normal-Wishart :

$$\alpha_k = \alpha_0 + N_k, \beta_k = \beta_0 + N_k, m_k = (\beta_0 m_0 + N_k \bar{x}_k)/\beta_k, \nu_k = \nu_0 + N_k \quad (1.28)$$

ainsi que la mise à jour de la matrice d'échelle $W_k^{-1} = W_0^{-1} + N_k S_k + [\beta_0 N_k/(\beta_0{+}N_k)]$ $(\bar{x}_k\text{-}m_0)(\bar{x}_k\text{-}m_0)^T$. L'ELBO est ensuite calculé, et les composantes telles que $\alpha_k \approx \alpha_0$ sont élaguées, selon le mécanisme détaillé à la section 1.7.4. Ces deux étapes sont répétées jusqu'à convergence de l'ELBO, l'algorithme retournant alors la distribution $q^*(\theta)$ ainsi que le nombre effectif de composantes actives, K_effectif.

e) Calcul des espérances nécessaires

L'étape E variationnelle requiert le calcul de plusieurs espérances par rapport aux distributions variationnelles courantes, espérances qui admettent des formes analytiques pour les distributions conjuguées utilisées. Pour la distribution de Dirichlet $q(\pi) = \mathrm{Dir}(\alpha_1, \ldots, \alpha K)$, l'espérance du logarithme du poids est donnée par :

$$\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi(\Sigma_j \alpha_j) \tag{1.29}$$

où ψ désigne la fonction digamma. Pour la distribution de Wishart $q(\Lambda_k) = \mathcal{W}(W_k, \nu_k)$, on obtient $\mathbb{E}[\log|\Lambda_k|] = \Sigma_{j=1}^{D}\ \psi[(\nu_k+1\text{-j})/2] + D \log 2 + \log|W_k|$. Enfin, pour la distribution normale $q(\mu_k|\Lambda_k) = \mathcal{N}(m_k, (\beta_k\Lambda_k)^{-1})$, l'espérance de la forme quadratique vaut :

$$\mathbb{E}[(x-\mu_k)^T\Lambda_k(x-\mu_k)] = D/\beta_k + \nu_k(x-m_k)^T W_k(x-m_k) \tag{1.30}$$

1.7.4 Sélection automatique du nombre de composantes

L'une des propriétés les plus remarquables et pratiquement importantes de l'EM variationnel est sa capacité à déterminer automatiquement le nombre effectif de composantes dans un mélange gaussien bayésien. Ce mécanisme, qui constitue l'un des apports majeurs de l'EM variationnel par rapport à l'EM classique, mérite une explication détaillée, car il sera au cœur de l'étude expérimentale présentée au chapitre 2.

La clé de ce mécanisme réside dans le prior de Dirichlet $\mathrm{Dir}(\alpha_0, \ldots, \alpha_0)$ placé sur les poids de mélange. Lorsque α_0 est petit typiquement $\alpha_0 = 1/\mathrm{Kmax}$ ou $\alpha_0 = 10^{-3}$, ce prior favorise fortement les solutions parcimonieuses, où la plupart des poids sont proches de zéro, c'est-à-dire les solutions n'utilisant qu'un petit nombre de composantes actives.

Lors de l'optimisation variationnelle, l'élagage ne provient pas de l'espérance $\mathbb{E}[\pi_k] = (\alpha_0 + N_k)/(K\alpha_0 + N)$: celle-ci est tirée vers la valeur uniforme $1/K$ pour tout α_0 (section 1.4.4) et ne s'annule jamais. Il provient de l'espérance du logarithme du poids, qui intervient dans l'étape E (équation 1.29) :

$$\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi\Big(\sum_j \alpha_j\Big), \qquad \alpha_k = \alpha_0 + N_k.$$

Pour $\alpha_k < 1$, on a $\psi(\alpha_k) = \psi(\alpha_k + 1) - 1/\alpha_k \approx -1/\alpha_k$, qui tend vers $-\infty$ quand $\alpha_k \to 0$. Une composante qui capte peu d'observations a donc un α_k proche de α_0, un $\mathbb{E}[\log \pi_k]$ très négatif et des responsabilités r_{ik} qui s'effondrent : N_k diminue, ce qui accentue encore l'effet (rétroaction positive). La figure 1.3 illustre ce mécanisme. Il est difficilement réversible : une composante dont α_k est tombé près de α_0 ne reçoit plus de responsabilité et ne peut plus être réactivée par les itérations suivantes.

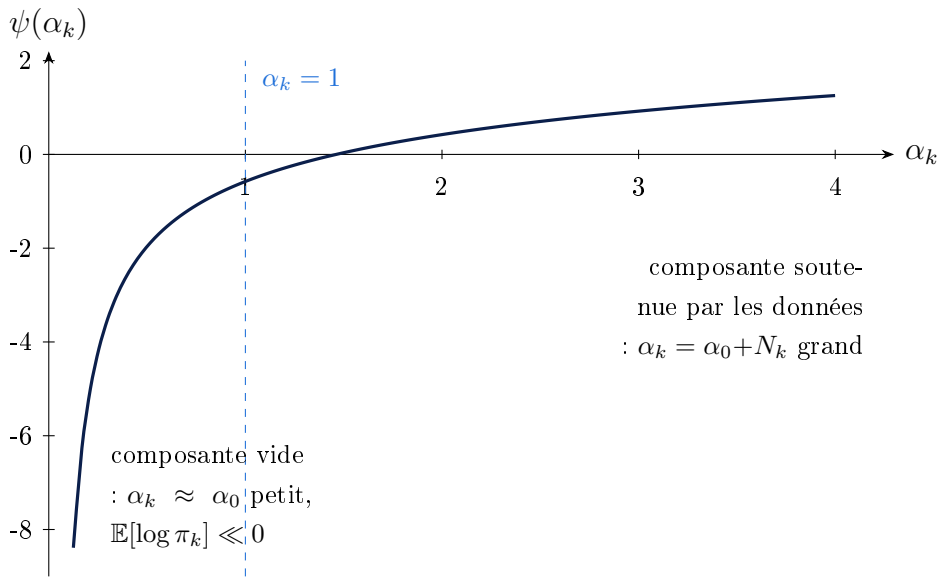


Figure 1.3: Mécanisme d'élagage : $\psi(\alpha_k) \approx -1/\alpha_k$ tend vers $-\infty$ quand $\alpha_k \to 0$. Dans l'étape E, $\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi(\sum_j \alpha_j)$ pénalise une composante dont α_k reste proche de α_0. Courbe tracée par l'approximation asymptotique de la fonction digamma décalée de 2.

Le seuil en deçà duquel l'élagage opère n'est pas $\alpha_0 = 1$. Pour un mélange surparamétré, la théorie de Rousseau et Mengersen (2011) établit que la loi a posteriori exacte vide les composantes superflues lorsque $\alpha_0 < d/2$, où d est le nombre de paramètres libres d'une composante ($d = 5$ pour une covariance pleine en dimension 2, soit un seuil de 2,5 ; $d = 4$ pour une covariance diagonale, seuil de 2 ; $d = 3$ pour une covariance sphérique, seuil de 1,5). Ce résultat concerne le posterior exact, non l'approximation de champ moyen. Son transfert à l'EM variationnel est donc une *hypothèse à tester*, et non un fait acquis : l'expérience S8 (section 3.1.13) mesure le nombre de composantes actives sur une grille de α_0 de 1 à 10 autour de ces seuils.

Ce mécanisme d'élagage automatique constitue une forme de rasoir d'Occam bayésien : le modèle utilise spontanément le nombre minimal de composantes nécessaires pour expliquer les données, sans sur-ajustement. En initialisant avec un Kmax suffisamment grand par exemple Kmax = 20 pour un problème où l'on attend entre 3 et 5 groupes , l'algorithme converge naturellement vers une solution utilisant uniquement le nombre approprié de composantes actives, sans qu'il soit nécessaire d'exécuter l'algorithme séparément pour chaque valeur candidate de K, comme l'exigerait l'EM classique.

Ce rasoir d'Occam a un coût que le texte précédent ne doit pas masquer : le résultat dépend de $K_{\max}$ (il ne peut pas retrouver plus de composantes que $K_{\max}$), des hyperparamètres $(\alpha_0, \beta_0, \nu_0, W_0)$ qui déplacent la sensibilité de l'initialisation vers les priors, et du seuil d'activité choisi pour décréter qu'une composante est éteinte (le seuil $N_k \geq 1$ est une convention, dont la sensibilité est mesurée par l'expérience S10).

Deux mécanismes d'élagage à ne pas confondre. Le mécanisme décrit ci-

dessus, par $\mathbb{E}[\log \pi_k]$, est celui du modèle entièrement bayésien de Bishop (2006, section 10.2), où π suit un Dirichlet ; c'est celui que ce travail implémente. Corduneanu et Bishop (2001) obtiennent l'élagage autrement : π est un paramètre ponctuel, réestimé par $\pi_k = N^{-1} \sum_n r_{nk}$ (Bishop, 2006, éq. 10.83), et les composantes qui contribuent peu à expliquer les données voient leur poids conduit à zéro au cours de l'optimisation, par un effet de détermination automatique de la pertinence. Dans la typologie de la section 2.1.2, cette variante est hybride : π relève du niveau 2 (point estimé sur une borne marginale), (μ_k, Λ_k) du niveau 3. Les deux mécanismes partent d'un K initial élevé et suppriment les composantes superflues en une seule exécution, mais ils n'ont ni les mêmes hyperparamètres (pas d'α_0 chez Corduneanu et Bishop) ni la même lecture de l'incertitude sur les poids. Bishop (2006, section 10.2.4) signale en outre que, pour comparer des valeurs de K par la borne, il faut tenir compte des $K!$ modes équivalents du posterior, par exemple en ajoutant $\ln K!$ à la borne.

1.7.5 Exemple numérique illustratif

Afin de rendre plus concret le mécanisme d'élagage décrit ci-dessus, reprenons l'exemple numérique de la section 1.6.4 : les huit observations scalaires X = {0,5 ; 1,0 ; 1,2 ; 1,8 ; 7,1 ; 7,5 ; 8,0 ; 8,3}, qui forment visiblement deux groupes bien séparés. Appliquons cette fois l'EM variationnel avec Kmax = 3 composantes soit une de plus que le nombre réel de groupes , un prior de Dirichlet de concentration $\alpha_0 = 1/3$, et des priors Normal-Wishart non informatifs ($\beta_0 = 10^{-3}$, $\nu_0 = 1$, $W_0 = 1$).

L'algorithme converge en 5 à 15 itérations selon l'initialisation (critère $|\Delta\text{ELBO}| < 10^{-6}$), vers la même solution dans les dix essais réalisés (graines 0 à 4, initialisation par les hyperparamètres ou par k-means). Le tableau 1.5 présente les paramètres finaux obtenus pour chacune des trois composantes.

Tableau 1.5: Résultat de l'EM variationnel sur l'exemple à 8 observations ($K_{\max} = 3$) selon l'initialisation et la graine

Init.	Graine	Itérations	α_k	m_k	Actives
prior	0	12	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
prior	1	7	4,333 ; 4,333 ; 0,333	7,724 ; 1,126 ; 4,425	2
prior	2	12	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
prior	3	7	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
prior	4	7	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
kmeans	0	15	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
kmeans	1	5	4,333 ; 4,333 ; 0,333	7,724 ; 1,126 ; 4,425	2

Init.	Graine	Itérations	α_k	m_k	Actives
kmeans	2	15	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
kmeans	3	15	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2
kmeans	4	5	4,333 ; 4,333 ; 0,333	1,126 ; 7,724 ; 4,425	2

Ce résultat illustre de façon particulièrement nette le mécanisme théorique décrit ci-dessus. Les deux premières composantes se partagent presque également la masse de probabilité (poids 0,482 chacune), avec des moyennes de 7,724 et 1,126 qui coïncident, à 10^{-3} près, avec les moyennes empiriques des deux groupes et avec la solution de l'EM classique de la section 1.6.4 (7,725 et 1,125). La troisième composante, en revanche, voit son paramètre α_k rester exactement égal à sa valeur initiale $\alpha_0 = 1/3 = 0{,}333$, signe que $N_k = \alpha_k$ - $\alpha_0 = 0$: aucune observation, même partiellement, ne lui a été attribuée au cours de la convergence. Cette composante est donc entièrement inactive, et le modèle retient effectivement K_effectif = 2 composantes actives, exactement le nombre réel de groupes un résultat que l'EM classique, avec K fixé à l'avance, ne peut pas produire de lui-même : il faudrait, pour l'EM classique, comparer explicitement les solutions à K = 2 et K = 3 au moyen d'un critère externe tel que le BIC, alors que l'EM variationnel effectue cette sélection de façon endogène, en une seule exécution.

1.7.6 Calcul de l'ELBO et critère de convergence

Pour le mélange gaussien bayésien sous l'hypothèse du champ moyen, l'ELBO peut être calculé analytiquement à chaque itération. Il se décompose sous la forme :

$$ELBO = \mathbb{E}_q[\log p(X|Z,\theta)] + \mathbb{E}_q[\log p(Z|\pi)] + \mathbb{E}_q[\log p(\pi)] + \Sigma_k \mathbb{E}_q[\log p(\mu_k,\Lambda_k)] - \mathbb{E}_q[\log q(Z)] - \mathbb{E}_q[\log q(\pi)] - \Sigma_k \mathbb{E}_q[\log q(\mu_k,\Lambda_k)] \tag{1.31}$$

Chacun de ces termes peut être calculé analytiquement grâce aux formes conjuguées des distributions considérées ; leur expression complète est donnée par Bishop (2006, éq. 10.71 à 10.77) et implémentée à l'annexe B. L'ELBO constitue le critère de convergence naturel de l'EM variationnel : on arrête l'algorithme lorsque |ELBO(t) - ELBO(t-1)| $< \varepsilon$. Contrairement à l'EM classique, où la log-vraisemblance peut diverger vers l'infini en présence de singularités, l'ELBO de l'EM variationnel reste toujours borné, grâce à la régularisation bayésienne induite par les priors.

1.7.7 Variantes avancées de l'EM variationnel

Inférence variationnelle naturelle. L'inférence variationnelle standard utilise le gradient ordinaire de l'ELBO pour optimiser les paramètres variationnels. Une variante

plus efficace utilise le gradient naturel, qui prend en compte la géométrie de l'espace des distributions à travers la métrique de Fisher. Les mises à jour par gradient naturel sont invariantes aux reparamétrisations et convergent généralement beaucoup plus rapidement que les mises à jour utilisant le gradient ordinaire.

Les trois méthodes suivantes répondent chacune à une limite précise de l'EM variationnel batch à champ moyen : le coût d'un passage complet sur les données (SVI), le calcul analytique des espérances (VAE), la rigidité de la famille factorisée (flux normalisants). Seule la première est implémentée dans ce travail ; les deux autres sont présentées pour situer le VB conjugué dans l'état de l'art, et aucune conclusion expérimentale ne s'appuie sur elles.

Inférence variationnelle stochastique (SVI). Hoffman, Blei, Wang et Paisley (2013) considèrent les modèles à variables cachées *globales* β, partagées par toutes les observations, et *locales* z_n, propres à chaque observation et conditionnellement indépendantes des autres sachant β (section 2.1 de l'article). Le GMM bayésien entre dans ce cadre : (π, μ_k, Λ_k) sont globales, z_n est locale. Lorsque les lois conditionnelles complètes sont dans la famille exponentielle, le gradient naturel de l'ELBO par rapport au paramètre naturel global λ (gradient prémultiplié par l'inverse de l'information de Fisher de $q(\beta)$) a une forme simple : il vaut la différence entre le paramètre de la loi conditionnelle optimale et λ. La SVI tire un mini-lot, calcule les paramètres locaux optimaux, forme une estimation bruitée $\hat{\lambda}$ de ce paramètre optimal en multipliant les statistiques du lot par N/B, puis met à jour $\lambda \leftarrow (1-\rho_t)\lambda + \rho_t\hat{\lambda}$. Le pas $\rho_t = (t+\tau)^{-\kappa}$, avec un taux d'oubli $\kappa \in (0{,}5; 1]$ et un délai $\tau \geq 0$, satisfait les conditions de Robbins et Monro ($\sum_t \rho_t = \infty$, $\sum_t \rho_t^2 < \infty$). Les auteurs l'appliquent à la LDA et au processus de Dirichlet hiérarchique sur 350 000 articles de *Nature*, 1,8 million d'articles du *New York Times* et 3,8 millions d'articles de Wikipédia. La fonction `svi_gmm` applique exactement cette mise à jour aux paramètres naturels Normal-Wishart et Dirichlet du GMM (annexe A) ; elle sert de vérification et non de bras de comparaison. La SVI est l'analogue, pour le VB, de l'EM online (section 1.6.5) ; elle hérite de la même difficulté de réglage du pas.

Auto-encodeurs variationnels et inférence amortie (AEVB). Kingma et Welling (2014) traitent les modèles dont les variables latentes *continues* ont un posterior intractable et dont les espérances de l'ELBO n'ont pas de forme close. Ils réécrivent un tirage de $q_\phi(z \mid x)$ comme une transformation différentiable d'un bruit, $z = g_\phi(\varepsilon, x)$ avec $\varepsilon \sim p(\varepsilon)$ (astuce de reparamétrisation), ce qui donne un estimateur sans biais et différentiable de la borne (estimateur SGVB), optimisable par gradient stochastique. Lorsque chaque observation a ses propres variables latentes, un réseau de reconnaissance (encodeur) $q_\phi(z \mid x)$ fournit directement les paramètres variationnels de chaque observation : l'inférence est *amortie*, sans optimisation propre à chaque point. Deux limites bornent son intérêt pour ce travail. La reparamétrisation suppose z continu, alors

que l'indicateur d'appartenance du GMM est discret ; et l'optimisation par gradient stochastique ne conserve ni les mises à jour en forme close ni la croissance monotone de l'ELBO du VB conjugué.

Flux normalisants. Rezende et Mohamed (2015) enrichissent la famille variationnelle en transformant une loi initiale simple q_0 par une suite de bijections $f_1, \dots, f_K$: si $z_K = f_K \circ \cdots \circ f_1(z_0)$, alors $\ln q_K(z_K) = \ln q_0(z_0) - \sum_{k=1}^{K} \ln|\det \partial f_k / \partial z_{k-1}|$. Pour que ce terme reste calculable, ils proposent des flux *planaires*, $f(z) = z + u\, h(w^\top z + b)$, dont le déterminant jacobien vaut $|1 + u^\top h'(w^\top z + b)\, w|$ et se calcule en $O(D)$ par le lemme du déterminant matriciel, et des flux *radiaux*, qui contractent ou dilatent la densité autour d'un point de référence. Ils soutiennent que, dans le régime asymptotique d'un flux de longueur croissante, la famille obtenue peut approcher le vrai posterior, ce que le champ moyen ne permet pas. C'est le remède au second effet de la section 1.5.4 (sous-estimation de la variance par factorisation) ; il n'est pas évalué ici, et son coût est d'abandonner, là encore, les mises à jour conjuguées.

1.7.8 Avantages de l'EM variationnel

- **Quantification complète de l'incertitude :** l'EM variationnel fournit une distribution q*(θ) sur les paramètres, permettant de calculer des intervalles de crédibilité, des quantiles, et d'intégrer l'incertitude paramétrique dans les prédictions, propriété fondamentale dans les applications où la décision doit tenir compte de l'incertitude. Cette distribution est une approximation (section 1.5.4) : sa fiabilité est mesurée par la couverture empirique de l'hypothèse HP6.

- **Sélection automatique du nombre de composantes :** le mécanisme d'élagage variationnel détermine automatiquement le nombre effectif de composantes, éliminant la nécessité d'une sélection externe de K et permettant une inférence en une seule exécution plutôt qu'une série d'exécutions pour différentes valeurs de K, au prix du choix de $K_{\max}$ et des hyperparamètres. Le gain en temps n'est pas acquis : il doit être mesuré en temps total jusqu'au modèle final (hypothèse RH5, test HP4).

- **Régularisation bayésienne et robustesse :** l'intégration des distributions a priori protège naturellement contre le surapprentissage et les singularités, la divergence de Kullback-Leibler vers le prior dans l'ELBO agissant comme une régularisation qui empêche les composantes de s'effondrer sur des observations individuelles.

- **ELBO comme critère de convergence :** l'ELBO borne inférieurement la log-évidence et fournit un critère de convergence croissant. Pour comparer des modèles, l'ELBO peut servir à comparer des valeurs de K *au sein du même*

algorithme variationnel, avec les réserves de Corduneanu et Bishop (2001) : l'écart entre l'ELBO et la log-évidence (une divergence KL) varie d'un modèle à l'autre, ce qui biaise la comparaison. L'ELBO n'est pas comparable à un BIC ou à une log-vraisemblance d'EM (sections 2.2.3 et 3.1.3) : cette position est la seule retenue dans ce mémoire.

- **Cadre extensible aux modèles complexes :** le cadre variationnel s'étend naturellement aux modèles hiérarchiques complexes, aux modèles génératifs profonds tels que les VAE, ainsi qu'aux modèles comportant plusieurs niveaux de variables latentes, là où l'EM classique devient difficilement applicable.

- **Convergence monotone de l'ELBO :** comme l'EM classique, l'EM variationnel garantit que l'ELBO ne décroît jamais entre deux itérations, propriété qui assure une grande stabilité numérique et facilite le diagnostic de la convergence.

Renvois à la grille du tableau 3.1 : incertitude → « Incertitude » et « Gestion du risque » ; sélection automatique de K → « Sélection de K », « Seuil d'élagage » ; régularisation et robustesse → « Singularités, petit N », « Valeurs aberrantes » ; ELBO et monotonie → « Monotonie du critère » ; extensibilité (VAE, flux normalisants) → « Vitesse de VAE, flux normalisants, gradient naturel » (non testé).

1.7.9 Inconvénients et limites de l'EM variationnel

- **Biais d'approximation systématique :** l'hypothèse du champ moyen introduit un biais systématique dans l'approximation. La distribution variationnelle optimale q* tend généralement à sous-estimer la variance de la véritable distribution a posteriori, phénomène de zero-forcing lié à la divergence KL. Lorsque la distribution a posteriori est fortement multimodale ou présente de fortes corrélations, cette approximation peut devenir relativement grossière.

- **Complexité d'implémentation :** la dérivation des mises à jour variationnelles pour un nouveau modèle nécessite une bonne maîtrise du calcul variationnel bayésien ainsi que de la famille exponentielle. L'implémentation correcte du calcul de l'ELBO pour le suivi de la convergence est sensiblement plus complexe que celle de l'EM classique.

- **Sensibilité aux distributions a priori :** le choix des hyperparamètres des distributions a priori (α_0, m_0, β_0, W_0, ν_0) peut influencer de manière significative les résultats, particulièrement lorsque le nombre de données disponibles est limité, ce qui nécessite une expertise ou une procédure de calibration empirique.

- **Convergence vers des optima locaux de l'ELBO :** la maximisation de l'ELBO reste susceptible de converger vers des optima locaux. Bien que la régularisation bayésienne rende généralement la surface d'optimisation plus lisse que dans l'EM classique, ce problème n'est pas totalement éliminé, et plusieurs initialisations demeurent recommandées.

- **Coût computationnel par itération plus élevé :** le calcul des différentes espérances variationnelles, impliquant notamment les fonctions digamma, les déterminants et les opérations matricielles, entraîne un surcoût computationnel à chaque itération par rapport à l'EM classique. Pour des problèmes simples, ce coût supplémentaire peut ne pas être compensé par les bénéfices apportés.

- **Applicabilité restreinte aux modèles conjugués :** les mises à jour analytiques fermées de l'EM variationnel ne sont disponibles que pour les modèles utilisant des distributions conjuguées. Pour les modèles non conjugués, il est nécessaire de recourir à des méthodes d'approximation supplémentaires, telles que les gradients stochastiques, les approximations de Laplace ou les méthodes de quadrature, ce qui augmente davantage la complexité de l'algorithme.

- **Irréversibilité de l'élagage :** une composante dont le poids s'est effondré ne reçoit plus de responsabilité et ne peut plus revenir (section 1.7.4). Une mauvaise trajectoire initiale peut donc éliminer définitivement une composante utile. Cet effet n'a pas été testé directement dans ce mémoire (« non testé » dans la grille de synthèse).

- **Dépendance à $K_{\max}$:** l'élagage ne peut retrouver que $K \leq K_{\max}$ composantes ; la sélection de K est déplacée vers le choix de $K_{\max}$ et des hyperparamètres.

- **Garanties fréquentistes partielles :** aucun résultat connu de ce travail ne garantit que l'élagage du champ moyen sélectionne le bon K ; les résultats sur les mélanges sur-paramétrés (Rousseau et Mengersen, 2011) portent sur le posterior exact. Pour les paramètres, à K fixé, les garanties existent mais sont partielles. Wang et Titterington (2006), cités par la revue de Blei et al. (2017, section 5.2), montrent pour le mélange gaussien à priors conjugués et champ moyen que l'algorithme CAVI converge vers un optimum local, que la moyenne variationnelle est consistante et qu'elle s'écarte du maximum de vraisemblance d'un terme en $O(1/n)$; Wang et Titterington (2005) montrent que la covariance variationnelle asymptotique est « trop petite », inférieure à l'inverse de l'information de Fisher d'une matrice définie positive. Ces deux articles n'ont pas été consultés directement. Plus généralement, Zhang et Gao (2020) bornent le taux de contraction du posterior variationnel par la somme de deux termes : le taux ε_n^2 du posterior

exact, établi par les conditions classiques de « masse a priori et tests », et l'erreur d'approximation $\frac{1}{n}\inf_{Q\in\mathcal{S}} P_0\, D(Q \,\|\, \Pi(\cdot \mid X))$ propre à la famille $\mathcal{S}$. Pour un prior produit et la famille du champ moyen, une condition de masse a priori renforcée suffit à rendre le second terme négligeable devant le premier. Ces résultats portent sur une famille variationnelle définie sur les *paramètres* ; leur application aux mélanges (section 4.3 de l'article) concerne l'estimation de densité en distance de Hellinger, avec une famille qui ne factorise pas les poids entre eux et sans facteur $q(Z)$ sur les affectations. Ils ne s'appliquent donc pas tels quels au VB de ce travail, qui factorise $q(Z)\,q(\pi,\mu,\Lambda)$. Le résultat de type Bernstein-von Mises de Wang et Blei (2019) pour les modèles paramétriques, cité par Zhang et Gao, n'a pas été consulté. Ce résultat prédit une sous-couverture des intervalles du VB ; l'hypothèse HP6 la confronte aux données, sans constituer une vérification du théorème.

- **Double usage des données avec des priors empiriques :** fixer m_0 et W_0^{-1} à partir des données (Bayes empirique) utilise l'échantillon deux fois ; l'ELBO et les intervalles de crédibilité n'ont plus leur lecture bayésienne stricte. Un jeu de priors fixés avant les données doit être comparé (expérience S9).

Renvois à la grille du tableau 3.1 : biais d'approximation → « Biais d'approximation » et « Incertitude » (couverture) ; sensibilité aux priors → « Sensibilité aux priors », « Seuil d'élagage » ; optima locaux de l'ELBO → « Optima locaux de l'ELBO » (non testé) ; coût par itération → « Coût de calcul » ; irréversibilité de l'élagage, dépendance à $K_{\max}$, consistance, double usage des données → lignes homonymes (« non testé » ou « expérience unique ») ; complexité d'implémentation et conjugaison → affirmations qualitatives sans ligne expérimentale.

1.8 Conclusion du chapitre 1

Ce premier chapitre a permis de poser l'ensemble des fondements théoriques nécessaires à la compréhension des deux algorithmes centraux de ce mémoire. Nous avons vu que les modèles à variables latentes, et en particulier le modèle de mélange gaussien, fournissent un cadre unificateur dans lequel s'inscrivent naturellement l'EM classique et l'EM variationnel. L'inégalité de Jensen et la borne ELBO constituent le socle mathématique commun aux deux algorithmes, tandis que le cadre bayésien et la divergence de Kullback-Leibler permettent de comprendre précisément ce qui distingue l'approche variationnelle de l'approche classique.

Ce parcours théorique n'a pas été conduit de façon purement abstraite : chaque notion introduite la borne ELBO, la conjugaison Dirichlet–Catégorielle, le mécanisme d'élagage bayésien, la correspondance avec l'algorithme de Baum-Welch a été illustrée

par un exemple numérique (calculé à la main pour la densité du GMM et la conjugaison Dirichlet–Catégorielle ; produit par le code et vérifié pour les tableaux 1.2, 1.4 et 1.5), du plus simple (l'évaluation de la densité d'un GMM à deux composantes, section 1.3.5) au plus élaboré (le calcul complet des quantités forward, backward et a posteriori d'un modèle de Markov caché, section 1.6.6). Cette démarche, délibérément choisie, répond à la conviction que la compréhension approfondie d'un algorithme d'inférence statistique passe nécessairement par la capacité à en dérouler, à la main ou par le calcul, chacune des étapes sur un exemple de taille réduite, avant d'en confier l'exécution à une bibliothèque logicielle démarche qui trouve son prolongement naturel dans les implémentations from scratch présentées au chapitre 3.

L'étude détaillée de l'EM classique a mis en évidence sa simplicité, son efficacité computationnelle et la garantie de convergence monotone qui le caractérisent, mais également ses limites majeures : nécessité de fixer K a priori, absence de quantification de l'incertitude, et sensibilité aux singularités. Les résultats non asymptotiques récents (section 1.6.3.d) précisent ces limites : en sur-spécification équilibrée, l'EM converge lentement vers une estimation de précision $(d/n)^{1/4}$ seulement, et en sous-spécification il vise la projection de Kullback-Leibler de la vraie loi, non un paramètre vrai. L'étude de l'EM variationnel a montré que le cadre bayésien ne lève pas ces limites mais les déplace : la sélection de K passe du critère externe aux hyperparamètres et à $K_{\max}$, l'incertitude devient native mais approchée et vraisemblablement trop étroite (section 1.7.9), le tout au prix d'une complexité d'implémentation et d'un coût par itération plus élevés. Les extensions modernes (SVI, inférence amortie, flux normalisants, section 1.7.7) répondent chacune à l'une de ces limites, sans être évaluées ici. La dérivation détaillée du champ moyen variationnel pour le cas particulier du GMM bayésien (section 1.7.3.c) a par ailleurs montré que les formules de mise à jour de l'EM variationnel, loin d'être postulées par analogie avec l'EM classique, se déduisent rigoureusement de l'application d'un principe unique la formule générale du champ moyen à un choix spécifique de distributions conjuguées, ce qui confère à l'ensemble de l'édifice théorique une cohérence interne que l'on ne perçoit pas toujours dans les présentations plus informelles de la littérature d'introduction.

Le chapitre suivant expose la méthodologie de la confrontation : hypothèses de recherche, données et leur préparation, protocole, règles de décision et calibrage. Les résultats, qui vérifient empiriquement chacune des propriétés établies dans ce premier chapitre, sont présentés et interprétés au chapitre 3.

Partie II

MÉTHODOLOGIE

Chapitre 2

MÉTHODOLOGIE DE LA CONFRONTATION

Ce chapitre décrit la manière dont la thèse du mémoire est mise à l'épreuve ; il ne présente aucun résultat. Il pose d'abord le cadre de la comparaison, théorique (section 2.1) et algorithmique (section 2.2). Il énonce ensuite les hypothèses de recherche et les tests déclarés qui les opérationnalisent (section 2.3). Il décrit les données et leur préparation : jeu synthétique de référence, scénarios, Iris, prix alimentaires du Cameroun et corpus de texte (section 2.4). Viennent ensuite le protocole de comparaison, les métriques et les règles de décision (section 2.5), le calibrage des paramètres (section 2.6), l'implémentation et l'ingénierie du code (section 2.7), et enfin les menaces à la validité et les écarts au protocole (section 2.8). Tous les résultats sont présentés et interprétés au chapitre 3.

2.1 Comparaison théorique

Sur le plan théorique, l'EM classique et l'EM variationnel partagent un socle commun la maximisation alternée d'une borne inférieure de la vraisemblance, l'ELBO mais divergent fondamentalement sur la nature de l'objet qu'ils cherchent à estimer. L'EM classique traite les paramètres θ comme des constantes inconnues, dont on cherche l'estimateur ponctuel du maximum de vraisemblance $\hat{\theta} = \text{argmax_}\theta\ \ell(\theta)$. L'EM variationnel, en revanche, traite θ comme une variable aléatoire dont on cherche à approximer la distribution a posteriori complète $q^*(\theta)$, au moyen d'une famille variationnelle factorisée sous l'hypothèse du champ moyen.

Cette différence de nature a des conséquences directes sur l'interprétation des résultats produits par chacun des deux algorithmes. Le tableau 2.1 synthétise les principales différences théoriques entre les deux approches.

Aspect théorique	**EM classique**	**EM variationnel**
Nature des paramètres	Constantes inconnues (fréquentiste)	Variables aléatoires (bayésien)
Objet estimé	Estimation ponctuelle $\hat{\theta}$	Distribution a posteriori q*(θ)
Objectif optimisé	Vraisemblance $\ell(\theta)$, via l'ELBO à θ fixé	ELBO(q) conjointement sur q(θ) et q(Z)
Rôle du prior	Absent (ou implicite dans la régularisation)	Central : Dirichlet sur π, Normal-Wishart sur (μ, Λ)
Traitement de K	Fixé a priori, choisi par critère externe (BIC, AIC)	Sélectionné automatiquement par élagage bayésien
Nature de la borne optimisée	Égalité atteinte à l'étape E (q = p(Z|X,θ))	Approximation permanente (hypothèse du champ moyen)
Quantification de l'incertitude	Absente en natif (calcul a posteriori possible)	Native, via la distribution q*(θ)

Tableau 2.1: Comparaison théorique entre l'EM classique et l'EM variationnel

Il convient de noter que l'EM classique peut, dans une certaine mesure, être vu comme un cas particulier de l'inférence variationnelle : lorsque l'on choisit, pour la distribution variationnelle sur les paramètres, une masse de Dirac q(θ) = δ(θ - $\hat{\theta}$), l'ELBO se réduit, à une constante divergente et au terme $\log p(\hat{\theta})$ près (passage à la limite détaillé ci-dessous), à la borne $\mathbb{E}_{q(Z)}[\log p(X, Z \mid \hat{\theta})] - \mathbb{E}_{q(Z)}[\log q(Z)] \leq \ell(\hat{\theta})$, où l'égalité a lieu lorsque $q(Z)$ est la loi a posteriori des affectations ; avec un prior plat, l'algorithme obtenu coïncide avec l'EM classique. Cette lecture s'appuie sur la formulation de Neal et Hinton (1998), mais elle n'y figure pas telle quelle : Neal et Hinton gardent θ ponctuel et définissent l'énergie libre $F(\tilde{P}, \theta) = \mathbb{E}_{\tilde{P}}[\log P(y, z \mid \theta)] + H(\tilde{P}) = L(\theta) - \mathrm{KL}(\tilde{P} \,\|\, P_\theta)$, où $\tilde{P}$ est une loi sur les variables non observées y et z les données (éq. 2 et 3 de l'article). L'étape E maximise F en $\tilde{P}$, l'étape M en θ ; un maximum local de F en $(\tilde{P}^*, \theta^*)$ donne un maximum local de L en θ^*, ce qui justifie les variantes incrémentale et creuse de l'EM. La seule restriction à des masses ponctuelles que discutent les auteurs (section 6) porte sur $\tilde{P}$, c'est-à-dire sur les variables latentes : elle donne la variante « le gagnant prend tout », dont les k-moyennes sont un cas particulier. Le passage à une masse de Dirac sur θ est le raisonnement de la section 2.1.1, construit sur cette formulation. Il éclaire la relation entre les deux algorithmes : l'EM variationnel n'est pas une méthode radicalement différente de l'EM classique, mais une généralisation de celui-ci, dans laquelle la contrainte de Dirac sur θ est relâchée au profit d'une famille de distributions plus riche.

2.1.1 De l'énergie libre de Neal et Hinton au cas limite de Dirac

Cette section détaille la dérivation de la correspondance énoncée ci-dessus, qui permet de replacer l'EM classique comme un cas particulier, plutôt qu'une alternative, de l'EM variationnel. Reprenons la définition de l'ELBO donnée à la section 1.2.2, en distinguant explicitement les variables latentes Z des paramètres θ dans la distribution variationnelle jointe q(Z, θ) = q(Z) q(θ) :

$$ELBO(q(Z),q(\theta)) = \mathbb{E}_{q(Z)q(\theta)}[\log p(X,Z|\theta)] + \mathbb{E}_{q(\theta)}[\log p(\theta)] - \mathbb{E}_{q(Z)}[\log q(Z)] - \mathbb{E}_{q(\theta)}[\log q(\theta)] \tag{2.1}$$

Choisissons à présent, pour la distribution variationnelle sur les paramètres, une masse de Dirac centrée en un point $\hat{\theta}$: q(θ) = δ(θ - $\hat{\theta}$). Par définition de la mesure de Dirac, l'espérance sous q(θ) de toute fonction f(θ) se réduit simplement à l'évaluation de f au point $\hat{\theta}$, c'est-à-dire $\mathbb{E}_\{q(\theta)\}[f(\theta)] = f(\hat{\theta})$. En appliquant cette propriété à chacun des quatre termes de l'ELBO ci-dessus :

$$ELBO(q(Z),\delta_{\hat{\theta}}) = \mathbb{E}_{q(Z)}[\log p(X,Z|\hat{\theta})] + \log p(\hat{\theta}) - \mathbb{E}_{q(Z)}[\log q(Z)] - \log \delta(0) \tag{2.2}$$

Les deux derniers termes appellent une précaution : la masse de Dirac n'est pas une densité, et $\log \delta(0)$ n'a pas de sens. Il faut passer à la limite d'une famille de lois. Posons $q_\varepsilon(\theta) = \mathcal{N}(\hat{\theta}, \varepsilon I_d)$ et faisons tendre $\varepsilon \to 0$. Par continuité de $\log p(X, Z \mid \theta)$ et de $\log p(\theta)$, les deux espérances convergent vers leurs valeurs en $\hat{\theta}$. Le terme d'entropie vaut $-\mathbb{E}_{q_\varepsilon}[\log q_\varepsilon] = \frac{d}{2}\log(2\pi e\,\varepsilon)$: il diverge quand $\varepsilon \to 0$, mais il ne dépend ni de $q(Z)$ ni de $\hat{\theta}$. L'ELBO s'écrit donc

$$\mathrm{ELBO}(q(Z), q_\varepsilon) = \underbrace{\mathbb{E}_{q(Z)}[\log p(X, Z \mid \hat{\theta})] - \mathbb{E}_{q(Z)}[\log q(Z)]}_{\mathrm{ELBO}(q(Z),\,\hat{\theta})} + \log p(\hat{\theta}) + \tfrac{d}{2}\log(2\pi e\,\varepsilon) + o(1),$$

et la constante divergente n'affecte pas la localisation de l'optimum en $(q(Z), \hat{\theta})$. Reste le terme $\log p(\hat{\theta})$: avec un prior plat (impropre), il est constant et l'on obtient l'EM du maximum de vraisemblance ; *sans* prior plat, on maximise l'ELBO plus $\log p(\hat{\theta})$ et l'on obtient le MAP-EM (section 2.1.3), non le MLE-EM. L'équation (2.3) est donc exacte pour un prior plat et à $\log p(\hat{\theta})$ près sinon. Ce passage à la limite est un raisonnement élémentaire, donné à des fins pédagogiques et non comme une contribution originale : la décomposition sur laquelle il repose, $L(\theta) = F(\tilde{P}, \theta) + \mathrm{KL}(\tilde{P} \,\|\, P_\theta)$ avec EM comme montée par coordonnées, est celle de Neal et Hinton (1998, éq. 3, lemmes 1 et 2) et de Bishop (2006, section 9.4) ; l'extension à une loi sur θ est celle de l'EM variationnel (section 1.7).

$$ELBO(q(Z),\delta_{\hat{\theta}}) \approx \mathbb{E}_{q(Z)}[\log p(X,Z|\hat{\theta})] - \mathbb{E}_{q(Z)}[\log q(Z)] = ELBO(q(Z),\hat{\theta}) \quad (2.3)$$

Cette dernière expression est exactement l'ELBO à paramètres fixés $\hat{\theta}$, tel que défini à la section 1.2.2 pour l'EM classique. Sa maximisation par rapport à q(Z) donne, comme établi à la section 1.2.2, q*(Z) = p(Z | X, $\hat{\theta}$) soit exactement l'étape E de l'EM classique (section 1.6.2.b) , et sa maximisation par rapport à $\hat{\theta}$, une fois q(Z) fixée à cette valeur optimale, correspond exactement à l'étape M de l'EM classique (section 1.6.2.c), puisque $\mathbb{E}$_{q(Z)}[log p(X,Z|θ)] est alors précisément la fonction Q($\theta|\theta^t$) définie à la section 1.6.2.c. L'EM classique apparaît ainsi comme le cas particulier de l'EM variationnel obtenu en restreignant la famille variationnelle sur les paramètres θ aux seules masses de Dirac, c'est-à-dire à la famille la moins expressive possible une famille qui ne peut, par construction, représenter aucune incertitude sur θ, ce qui explique directement l'absence de quantification de l'incertitude relevée comme limite de l'EM classique à la section 1.6.8. Réciproquement, l'EM variationnel décrit à la section 1.7 s'obtient en remplaçant cette famille de Dirac par la famille, plus riche, des distributions factorisées sous l'hypothèse du champ moyen (section 1.7.3.a) : les deux algorithmes se déduisent donc d'un seul et même principe variationnel, appliqué à deux familles variationnelles emboîtées, l'une (Dirac) étant un cas particulier dégénéré de l'autre (champ moyen).

2.1.2 Trois niveaux d'inférence : MLE, MAP et Bayes complet

La dérivation de la section 2.1.1 permet de situer précisément l'EM classique et l'EM variationnel au sein d'une hiérarchie plus large de trois niveaux d'inférence statistique, qu'il est utile de distinguer explicitement, tant la confusion entre eux est fréquente dans la littérature d'introduction à l'apprentissage automatique.

Premier niveau : le maximum de vraisemblance (MLE). C'est le niveau auquel opère l'EM classique tel que présenté à la section 1.6 : on cherche $\hat{\theta}$_MLE = argmax_θ p(X|θ), sans faire intervenir de prior p(θ) du tout. C'est l'estimateur le plus simple, mais aussi le plus sujet au surapprentissage en présence de peu de données, puisque rien ne pénalise les valeurs de θ qui ajustent excessivement le bruit d'échantillonnage c'est notamment ce mécanisme qui explique la propension de l'EM classique aux singularités décrite à la section 1.6.8.

Deuxième niveau : le maximum a posteriori (MAP). Ce niveau intermédiaire introduit un prior p(θ), mais continue de ne retenir qu'une estimation ponctuelle : $\hat{\theta}$_MAP = argmax_θ p(θ|X) = argmax_θ [p(X|θ) p(θ)]. Le MAP peut se voir comme une régularisation du MLE par exemple, un prior gaussien centré en zéro sur les paramètres d'un modèle linéaire donne lieu, au MAP, à la régularisation dite de Tikhonov (ridge regression). Le MAP-EM, qui maximise à l'étape M non plus $Q(\theta|\theta^t)$ seule mais

$Q(\theta|\theta^t) + \log p(\theta)$, est développé à la section 2.1.3 ; il est implémenté (fonction `map_em`) et intégré à toutes les comparaisons, car il isole l'effet du prior de celui de l'inférence bayésienne complète.

Troisième niveau : l'inférence bayésienne complète. C'est le niveau auquel opère l'EM variationnel : on ne retient plus une estimation ponctuelle de θ, mais on caractérise sa distribution a posteriori complète p(θ|X) ou, dans le cas de l'EM variationnel, son approximation q*(θ). Ce troisième niveau seul permet la quantification de l'incertitude mise en avant à la section 1.7.8 : les deux premiers niveaux, MLE et MAP, ne produisant chacun qu'un unique point de l'espace des paramètres, ne permettent structurellement aucune caractérisation de l'incertitude associée à ce point.

Le tableau 2.2 synthétise cette hiérarchie à trois niveaux, qui complète la comparaison à deux termes (classique / variationnel) menée jusqu'ici dans ce chapitre en y insérant le niveau intermédiaire du MAP, développé et implémenté dans ce mémoire (section 2.1.3), utile à la compréhension d'ensemble du paysage des méthodes d'estimation pour les modèles à variables latentes.

Niveau	**Objectif optimisé**	**Sortie**	**Algorithme correspondant**
MLE	argmax_θ p(X|θ)	Un point $\hat{\theta}$	EM classique (chapitre 1.6)
MAP	argmax_θ p(X|θ)p(θ)	Un point $\hat{\theta}$ régularisé	MAP-EM (section 2.1.3)
Bayes complet	Caractériser p(θ|X) en entier	Une distribution q*(θ)	EM variationnel (chapitre 1.7)

Tableau 2.2: Les trois niveaux d'inférence statistique pour les modèles à variables latentes

2.1.3 Le MAP-EM : isoler l'effet du prior

Avec les priors conjugués du modèle bayésien (Dirichlet sur π, Normale-Inverse-Wishart sur (μ_k, Σ_k) de paramètres $\alpha_0, m_0, \beta_0, \Psi_0 = W_0^{-1}, \nu_0$), l'étape M du MAP-EM maximise $Q(\theta \mid \theta^t) + \log p(\theta)$ en forme close. Avec $N_k = \sum_i r_{ik}$, $\bar{x}_k$ la moyenne pondérée et $S_k = \sum_i r_{ik}(x_i - \bar{x}_k)(x_i - \bar{x}_k)^\top$:

$$\pi_k = \frac{N_k + \alpha_0 - 1}{N + K(\alpha_0 - 1)}, \qquad \mu_k = \frac{\beta_0 m_0 + N_k \bar{x}_k}{\beta_0 + N_k},$$
$$\Sigma_k = \frac{\Psi_0 + S_k + \frac{\beta_0 N_k}{\beta_0 + N_k}(\bar{x}_k - m_0)(\bar{x}_k - m_0)^\top}{\nu_0 + N_k + D + 2}.$$

Ce sont les modes conjoints en (π, μ, Σ) (la densité est prise en Σ, non en Λ) ; la formule de π_k exige $\alpha_0 \geq 1$. Un prior plat ($\alpha_0 = 1$, $\beta_0 = 0$, $\Psi_0 = 0$, $\nu_0 = -D - 2$) redonne exactement l'EM classique, ce que vérifie un test unitaire, et le log-posterior

$\ell(\theta) + \log p(\theta)$ croît à chaque itération. Le MAP-EM de ce travail porte les priors Normal-Wishart du VB, mais un Dirichlet plat ($\alpha_0 = 1$, registre `alpha0_map`) : le VB utilise $\alpha_0 = 1/K_{\max} < 1$, valeur pour laquelle le mode en π n'existe pas à l'intérieur du simplexe. Le MAP-EM ne fournit qu'un point et ne peut pas éteindre de composante par le prior de Dirichlet. Comparer EM, MAP-EM et VB permet donc d'attribuer à la régularisation des composantes ce qui lui revient, et au reste de l'approche variationnelle (distribution sur θ et élagage par le Dirichlet) ce qui lui revient ; ces deux derniers effets ne sont pas séparés. Le schéma de la figure 2.1 situe les trois algorithmes.

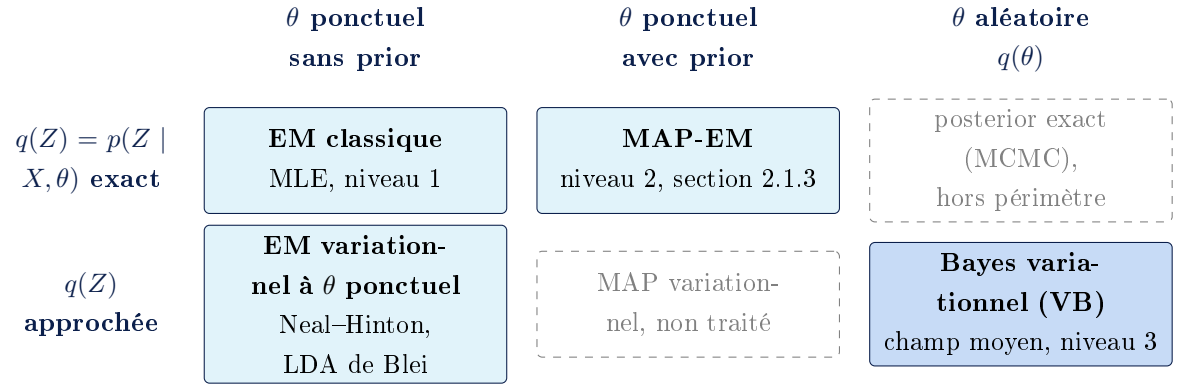


Figure 2.1: Trois niveaux d'inférence selon la nature de θ et l'approximation de $q(Z)$. Cases pleines : algorithmes comparés (EM classique, MAP-EM, VB pour le GMM ; EM variationnel à θ ponctuel pour la LDA du chapitre 3). Cases en pointillés : non traitées.

2.2 Comparaison algorithmique

2.2.1 Complexité computationnelle

Sur le plan algorithmique, les deux méthodes partagent la même structure itérative en deux étapes, mais diffèrent dans le détail du coût de chaque étape. Le tableau 2.3 détaille la complexité de chaque étape pour un mélange de K gaussiennes en dimension D, sur un jeu de données de taille N, avec covariances pleines.

Étape	**EM classique**	**EM variationnel**
Étape E	O(NKD^2) (formes quadratiques), plus O(KD^3) pour les factorisations de Cholesky	O(NKD^2), plus O(KD) évaluations de la fonction digamma
Étape M	O(NKD^2)	O(NKD^2), plus O(KD^3) pour l'inversion des W_k
Calcul du critère de convergence	O(NK) (log-vraisemblance, déjà calculée à l'étape E)	O($NK + KD^3$) (ELBO complet, statistiques déjà calculées)
Complexité totale par itération	O($NKD^2 + KD^3$)	O($NKD^2 + KD^3$)
Nombre d'itérations typique	Faible à modéré	Modéré à élevé (dépend de Kmax et des priors)

Tableau 2.3: Complexité algorithmique comparée (par itération)

Les deux algorithmes ont donc le même ordre de grandeur asymptotique par itération : le terme en KD^3, lié aux factorisations ou inversions de matrices $D \times D$, est indépendant de N et commun aux deux méthodes. Le surcoût observé de l'EM variationnel provient de facteurs constants plus élevés (fonctions digamma, déterminants, inversions explicites, calcul de l'ELBO à chaque itération) et surtout d'un nombre d'itérations plus grand, qui dépend du critère d'arrêt et des priors (sections 3.1.4 et 3.2). Les mesures de ce mémoire s'arrêtent à $D = 20$ (scénario S5, section 3.2.2) : toute affirmation sur des dimensions supérieures est *non testée*. Le surcoût doit en outre être évalué en temps total jusqu'au modèle final, et non par itération seule (section 2.2.3).

2.2.2 Comportement numérique et stabilité

Un autre axe de comparaison important concerne le comportement numérique des deux algorithmes. L'EM classique, en l'absence de régularisation, est sujet à des singularités : lorsqu'une composante s'ajuste à un très petit nombre de points, voire à un unique point, sa variance peut s'effondrer vers zéro, entraînant une divergence de la log-vraisemblance vers l'infini. Ce phénomène impose en pratique l'ajout d'une régularisation ad hoc de la covariance (par exemple $\Sigma_k \leftarrow \Sigma_k + \varepsilon I$).

L'EM variationnel est, lui, doté d'une régularisation structurelle : le prior Normal-Wishart borne inférieurement la matrice d'échelle $W_k^{-1} \succeq W_0^{-1}$, ce qui empêche Λ_k de diverger, et le prior de Dirichlet empêche π_k de s'annuler exactement. Cette protection est une propriété du modèle, non un résultat mesuré : elle n'est pas démontrée par une expérience tant que la fréquence des ajustements dégénérés n'est pas comptée. Il faut de plus noter que l'implémentation de l'EM utilisée dans ce mémoire n'est pas non régularisée : elle ajoute εI avec $\varepsilon = 10^{-6}$ à chaque covariance (constante `REG_EM`).

Comparer « EM sans protection » et « VB protégé » serait donc inexact. Le scénario S6 (petit effectif, section 3.2.2) compte, pour chaque algorithme, la part d'ajustements dégénérés, définie par une valeur propre minimale de Σ_k inférieure à 10^{-6} fois sa trace, ou un effectif $N_k < D + 1$. Le tableau 3.1 classe la robustesse aux singularités selon ce comptage.

Un second aspect du comportement numérique concerne le conditionnement des matrices de covariance. L'évaluation de la densité gaussienne par inversion explicite de Σ_k devient numériquement instable lorsque cette matrice est proche de la singularité, situation qui survient lorsqu'une composante concentre son support sur un sous-espace de dimension inférieure à D. L'implémentation présentée au chapitre 3 évalue donc les densités à partir de la factorisation de Cholesky $\Sigma_k = LL^T$: le terme quadratique $(x-\mu_k)^T\Sigma_k^{-1}(x-\mu_k)$ est obtenu par résolution d'un système triangulaire et $\log|\Sigma_k|$ vaut $2\sum_j \log L_{jj}$. Cette technique, standard dans les bibliothèques de production, améliore la stabilité et réduit le coût, sans modifier le résultat mathématique de l'algorithme.

2.2.3 Critères de sélection de modèle

Lorsque l'on utilise l'EM classique, la sélection du nombre de composantes K repose généralement sur des critères d'information calculés a posteriori, après avoir exécuté l'algorithme pour plusieurs valeurs candidates de K. Les critères les plus couramment employés sont le critère d'information bayésien (BIC), le critère d'information d'Akaike (AIC), et le critère de vraisemblance classifiante intégrée (ICL), définis respectivement par :

$$BIC(K) = -2\ell(\hat{\theta}K) + p(K)\log N \tag{2.4}$$

$$AIC(K) = -2\ell(\hat{\theta}K) + 2p(K) \tag{2.5}$$

où $p(K)$ désigne le nombre de paramètres libres du modèle à K composantes. L'ICL (Biernacki, Celeux et Govaert, 2000) ajoute au BIC deux fois l'entropie des affectations :

$$\mathrm{ICL}(K) = \mathrm{BIC}(K) + 2\,\mathrm{EN}(K), \qquad \mathrm{EN}(K) = -\sum_{i=1}^{N}\sum_{k=1}^{K} r_{ik}\log r_{ik} \geq 0, \tag{2.5b}$$

ce qui pénalise les mélanges dont les composantes se chevauchent. Ces critères pénalisent la complexité du modèle, mais exigent un ajustement EM par valeur de K candidate (et, en pratique, plusieurs initialisations par valeur). L'EM variationnel produit une solution en une exécution avec $K_{\max}$ fixé. Cette économie n'est toutefois pas acquise : une exécution variationnelle peut coûter plusieurs fois une exécution de l'EM, de sorte que le gain dépend du rapport entre le nombre d'ajustements EM d'un ba-

layage et le surcoût d'un ajustement variationnel. Il se mesure en *temps total jusqu'au modèle final*, balayage EM-BIC complet contre un ajustement variationnel (hypothèse RH5, test HP4, tableau **??**), et non par une proportion du nombre de valeurs de K.

Ces critères fixent la *baseline pertinente* de toute la confrontation : la comparaison utile n'est pas « EM avec K imposé contre VB », situation défavorable à l'EM par construction et réservée aux illustrations du mécanisme d'élagage, mais « EM avec K choisi par BIC ou ICL contre VB ». Le coût de cette baseline (un ajustement EM par valeur de K et par initialisation) est comparé au coût d'un ajustement variationnel en temps total jusqu'au modèle final, jamais en proportion du nombre de valeurs de K testées.

2.3 Hypothèses de recherche et plan des tests

La thèse défendue (« le VB ne bat pas l'EM ; il déplace la sélection de K vers les hyperparamètres et $K_{\max}$, apporte une incertitude approchée, au prix d'un coût et d'une sensibilité aux priors ») est décomposée en cinq hypothèses de recherche, notées RH1 à RH5 (tableau 2.4). Chacune découle d'un résultat du chapitre 1 : l'équivalence des deux algorithmes à la limite de Dirac (section 2.1) fonde RH1 ; le mécanisme d'élagage par α_0 et la dépendance à $K_{\max}$ (section 1.7.4) fondent RH2 ; la sous-estimation de la variance par le champ moyen (section 1.5.4) fonde RH3 ; la régularisation structurelle des priors (section 2.2.2) et le comparateur MAP-EM (section 2.1.3) fondent RH4 ; l'analyse de complexité (section 2.2.1) et le coût du balayage de K (section 2.2.3) fondent RH5.

Tableau 2.4: Hypothèses de recherche issues de la thèse et tests qui les mettent à l'épreuve

RH	Intitulé	Hypothèse de recherche	Tests rattachés
RH1	Absence de supériorité générale	Quand la structure est identifiable (groupes séparés, effectif suffisant), le VB et l'EM avec K choisi par BIC donnent des résultats équivalents ; quand ils diffèrent, le sens de l'écart dépend du contexte.	HS1, HS2, HS4, HS5, HS7, HP1, HP2, HPP1, HPP2, HPP3
RH2	Déplacement de la sélection de K	Le nombre de composantes retenu par le VB dépend de ses hyperparamètres (et de Kmax) au moins autant que celui de l'EM dépend de ses propres choix (critère d'information et initialisation).	HS3, HP5, HPP5
RH3	Incertitude approchée	Les intervalles de crédibilité du VB en champ moyen sont trop étroits : leur couverture est inférieure au niveau nominal, alors que le bootstrap de l'EM en est plus proche.	HP6, HPP4
RH4	Régularisation par les priors	À petit effectif, le VB produit moins d'ajustements dégénérés que l'EM de même capacité, et cet effet est celui des priors : le MAP-EM, qui porte les mêmes priors sans loi sur les paramètres, l'obtient aussi.	HS6, HP3, HP7, HT1, HPP6
RH5	Coût	Un ajustement VB coûte plus qu'un ajustement EM, mais le pipeline EM-BIC complet (balayage de K) coûte plus qu'un ajustement VB en temps total jusqu'au modèle final.	HP4

Une hypothèse de recherche n'est pas testée directement : elle est mise à l'épreuve

par des *tests déclarés*, écrits dans le code (`hypotheses.py`) avant l'exécution confirmatoire. Chaque test porte sur un point d'un plan d'expérience, compare deux bras A et B sur une métrique, par différences appariées réplication par réplication, et précise le résultat attendu si l'hypothèse de recherche est vraie : « équivalent » (test d'équivalence), « A $>$ B » ou « A $<$ B » (test de différence orienté), ou « non orienté » lorsque la thèse ne prédit pas le sens de l'écart. Le plan complet est au tableau 2.5. Les tests de RH1 sont principalement des tests d'équivalence : la thèse prédit l'absence de supériorité, et une équivalence démontrée est une issue confirmatoire, non un échec. Les tests rattachés à RH2, RH4 et RH5 sont orientés ; ceux de RH3 sont des décisions par intervalle sur la couverture.

Tableau 2.5: Plan des tests déclarés (familles de Holm : scénarios, prix, prévision, texte)

Test	RH	Énoncé	Bras (A - B)	Métrique	Test déclaré	Attendu si RH vraie
HS1-sep4	RH1	Groupes séparés de 4 écarts-types : ARI du VB (priors empiriques) équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS1-sep5	RH1	Groupes séparés de 5 écarts-types : ARI du VB (priors empiriques) équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS1-sep1	RH1	Groupes séparés de 1 écart(s)-type(s) : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS1-sep2	RH1	Groupes séparés de 2 écart(s)-type(s) : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS1-sep3	RH1	Groupes séparés de 3 écart(s)-type(s) : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS2	RH1	Poids 80/15/5 : le VB perd la composante minoritaire ($\hat{K} < 3$) à une fréquence différente de l'EM-BIC	VB-emp - EM-BIC	minoritaire_perdue	Wilcoxon exact	non orienté
HS3-K4	RH2	K vrai = 4, K choisi = 3 : ARI du VB à Kmax = 3 équivalent à celui de l'EM à K = 3 (aucun ne peut corriger l'erreur)	VB-Kmax=K - EM-K	ARI	TOST	équivalence
HS3-K5	RH2	K vrai = 5, K choisi = 3 : ARI du VB à Kmax = 3 équivalent à celui de l'EM à K = 3 (aucun ne peut corriger l'erreur)	VB-Kmax=K - EM-K	ARI	TOST	équivalence
HS3-K6	RH2	K vrai = 6, K choisi = 3 : ARI du VB à Kmax = 3 équivalent à celui de l'EM à K = 3 (aucun ne peut corriger l'erreur)	VB-Kmax=K - EM-K	ARI	TOST	équivalence
HS4	RH1	Composantes de Student (nu = 3) : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS5-D2	RH1	D = 2 : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS5-D5	RH1	D = 5 : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS5-D10	RH1	D = 10 : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS5-D20	RH1	D = 20 : l'ARI du VB diffère de celui de l'EM-BIC	VB-emp - EM-BIC	ARI	Wilcoxon exact	non orienté
HS6-N30	RH4	N = 30 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A $<$ B
HS6-N60	RH4	N = 60 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A $<$ B
HS6-N120	RH4	N = 120 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A $<$ B
HS6-N300	RH4	N = 300 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A $<$ B
HS6-N1000	RH4	N = 1000 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A $<$ B
HS7-p0.01-a5.0	RH1	Aberrations (proportion 0.01, amplitude 5.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.01-a10.0	RH1	Aberrations (proportion 0.01, amplitude 10.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.01-a20.0	RH1	Aberrations (proportion 0.01, amplitude 20.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.05-a5.0	RH1	Aberrations (proportion 0.05, amplitude 5.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.05-a10.0	RH1	Aberrations (proportion 0.05, amplitude 10.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.05-a20.0	RH1	Aberrations (proportion 0.05, amplitude 20.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence

Test	RH	Énoncé	Bras (A - B)	Métrique	Test déclaré	Attendu si RH vraie
HS7-p0.1-a5.0	RH1	Aberrations (proportion 0.1, amplitude 5.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.1-a10.0	RH1	Aberrations (proportion 0.1, amplitude 10.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HS7-p0.1-a20.0	RH1	Aberrations (proportion 0.1, amplitude 20.0) : ARI hors aberrations du VB équivalent à celui de l'EM-BIC	VB-emp - EM-BIC	ARI	TOST	équivalence
HP1-N30	RH1	Semi-synthétique, N = 30 : $\lvert\hat{K}$ - K_ref$\rvert$ du VB équivalent à celui de l'EM-BIC (marge d'une demi-composante)	VB-emp - EM-BIC	erreur_k	TOST	équivalence
HP1-N60	RH1	Semi-synthétique, N = 60 : $\lvert\hat{K}$ - K_ref$\rvert$ du VB équivalent à celui de l'EM-BIC (marge d'une demi-composante)	VB-emp - EM-BIC	erreur_k	TOST	équivalence
HP1-N120	RH1	Semi-synthétique, N = 120 : $\lvert\hat{K}$ - K_ref$\rvert$ du VB équivalent à celui de l'EM-BIC (marge d'une demi-composante)	VB-emp - EM-BIC	erreur_k	TOST	équivalence
HP1-N250	RH1	Semi-synthétique, N = 250 : $\lvert\hat{K}$ - K_ref$\rvert$ du VB équivalent à celui de l'EM-BIC (marge d'une demi-composante)	VB-emp - EM-BIC	erreur_k	TOST	équivalence
HP1-N500	RH1	Semi-synthétique, N = 500 : $\lvert\hat{K}$ - K_ref$\rvert$ du VB équivalent à celui de l'EM-BIC (marge d'une demi-composante)	VB-emp - EM-BIC	erreur_k	TOST	équivalence
HP2-LL	RH1	N = 250, validation temporelle (test 2024-2026) : log-vraisemblance de test du VB équivalente à celle de l'EM-BIC	VB-emp - EM-BIC	ll_test	TOST	équivalence
HP3-N30	RH4	N = 30 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A < B
HP3-N60	RH4	N = 60 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A < B
HP3-N120	RH4	N = 120 : la fréquence d'ajustements dégénérés du VB diffère de celle de l'EM à Kmax	VB-emp - EM-Kmax	degenere	Wilcoxon exact	A < B
HP5	RH2	Sur un même sous-échantillon (N = 250), la variance de $\hat{K}$ du VB entre configurations de priors plausibles diffère de la variance de $\hat{K}$ de l'EM entre ses propres choix (BIC ou ICL, trois graines)	VB-priors - EM-choix	var_k	Wilcoxon exact	A > B
HP7-N30	RH4	N = 30 : la fréquence d'ajustements dégénérés du MAP-EM (mêmes priors que le VB, sans loi sur les paramètres) diffère de celle de l'EM à Kmax	MAP-EM - EM-Kmax	degenere	Wilcoxon exact	A < B
HP7-N60	RH4	N = 60 : la fréquence d'ajustements dégénérés du MAP-EM (mêmes priors que le VB, sans loi sur les paramètres) diffère de celle de l'EM à Kmax	MAP-EM - EM-Kmax	degenere	Wilcoxon exact	A < B
HP7-N120	RH4	N = 120 : la fréquence d'ajustements dégénérés du MAP-EM (mêmes priors que le VB, sans loi sur les paramètres) diffère de celle de l'EM à Kmax	MAP-EM - EM-Kmax	degenere	Wilcoxon exact	A < B
HT1-N50	RH4	N = 50 documents : l'écart relatif de perplexité (test / apprentissage) du pLSA diffère de celui de la LDA	pLSA - LDA	ecart_relatif	Wilcoxon exact	A > B
HT1-N200	RH4	N = 200 documents : l'écart relatif de perplexité (test / apprentissage) du pLSA diffère de celui de la LDA	pLSA - LDA	ecart_relatif	Wilcoxon exact	A > B
HT1-N1000	RH4	N = 1000 documents : l'écart relatif de perplexité (test / apprentissage) du pLSA diffère de celui de la LDA	pLSA - LDA	ecart_relatif	Wilcoxon exact	A > B
HP4*	RH5	Rapport des temps médians pipeline EM-BIC / VB, IC bootstrap de la médiane			intervalle	ratio > 1
HP6-VB*	RH3	Couverture à 90 % des intervalles de crédibilité du VB, IC bootstrap par grappes			intervalle	< 90 %
HP6-bootstrap EM*	RH3	Couverture à 90 % du bootstrap de l'EM, IC bootstrap par grappes			intervalle	compatible avec 90 %
HPP1	RH1	Log-score de test, EM-BIC contre gaussienne unique (Diebold-Mariano par mois)			Diebold-Mariano	non orienté
HPP2	RH1	Log-score de test, VB-emp (prédictive) contre gaussienne unique			Diebold-Mariano	non orienté
HPP3	RH1	Log-score de test, VB-emp (prédictive) contre EM-BIC			Diebold-Mariano	non orienté
HPP4	RH3	Log-score de test, VB-emp prédictive contre VB-emp plug-in (apport de la loi sur les paramètres)			Diebold-Mariano	non orienté
HPP5	RH2	Log-score de test, VB-cal contre VB-emp (effet du choix des priors)			Diebold-Mariano	non orienté
HPP6	RH4	Log-score de test, MAP-EM contre EM-BIC (effet des priors sans loi sur les paramètres)			Diebold-Mariano	non orienté

* : décision par intervalle (pas de correction de Holm). « Non orienté » : la thèse ne prédit pas le sens de l'écart ; une différence démontrée est alors rapportée sans être comptée pour ni contre l'hypothèse.

2.4 Données et préparation

Cinq sources de données sont utilisées. Toutes sont chargées par du code écrit pour ce mémoire (`donnees.py`), sans bibliothèque d'apprentissage automatique, et les données réelles sont accompagnées de leur provenance et d'une empreinte SHA-256 vérifiée au chargement.

2.4.1 Jeu synthétique de référence

Les illustrations du chapitre 3 reposent sur un jeu de données synthétique bidimensionnel. Ce choix méthodologique permet une visualisation directe des résultats et une interprétation sans ambiguïté des mécanismes en jeu.

Le jeu de données est constitué de N = 300 observations bidimensionnelles, générées à partir de trois groupes gaussiens, de centres respectifs (0, 0), (5, 5) et (0, 5), chacun comportant 100 observations et une covariance isotrope d'écart-type 0,7 (variance 0,49). Les centres sont distants de 5 à 7,1 unités, soit de 7 à 10 écarts-types : les trois groupes sont donc bien séparés. Ce jeu de données constitue, par construction, un mélange à trois composantes gaussiennes. Il est tiré avec la graine 42 ; les scénarios S1 à S10 (section 2.4.2) répliquent et généralisent ce protocole.

L'expérience consiste à ajuster, sur ce même jeu de données, un GMM classique via l'algorithme EM classique et un GMM bayésien via l'algorithme EM variationnel, en imposant dans les deux cas un nombre de composantes délibérément surestimé, K = 6, soit le double du nombre réel de groupes. L'objectif est d'observer comment chacun des deux algorithmes gère cette surestimation. Deux jeux d'hyperparamètres sont considérés pour l'EM variationnel : des priors empiriques (centrés sur les données : $\beta_0 = 1$, W_0^{-1} égale à la covariance empirique) et des priors diffus ($\beta_0 = 10^{-3}$, $W_0 = \mathrm{I}$). Sauf mention contraire, les résultats rapportés utilisent les priors empiriques.

Paramètre	**Valeur**
Nombre d'observations (N)	300 (3 groupes de 100)
Dimension (D)	2
Nombre de composantes imposé (K)	6 (nombre réel de groupes : 3)
Covariance des groupes générateurs	Isotrope, écart-type 0,7 (variance 0,49)
Graine de génération des données	42
EM classique	Mélange gaussien, covariance pleine, initialisation par k-means
EM variationnel	GMM bayésien, covariance pleine, prior de Dirichlet fini de concentration α_0
Priors Normal-Wishart (« empiriques », Bayes empirique)	m_0 = moyenne des données, $\beta_0 = 1$, $\nu_0 = \mathrm{D}$, W_0^{-1} = covariance empirique : les données servent deux fois (priors et vraisemblance)
Concentration du prior de Dirichlet (α_0)	1 / K = 0,167
Critère d'arrêt	Identique pour tous les algorithmes : variation relative du critère total inférieure à la tolérance calibrée (log-vraisemblance pour l'EM et le MAP-EM, ELBO pour le VB en covariance pleine ; registre, section 2.6)
Nombre maximal d'itérations	Plafond d'étapes M calibré, commun à tous les algorithmes ; une exécution qui atteint le plafond est marquée « non convergée »
Nombre d'initialisations	Calibré par famille de données (meilleur critère retenu ; registre)
Composante active	$N_k/N \geq 1\,\%$ (registre `seuil_actif`), même règle pour tous les bras et tous les plans ; sensibilité au seuil mesurée au tableau **??**

Tableau 2.6: Paramètres du protocole expérimental

Source : implémentation PyTorch décrite à l'annexe A.

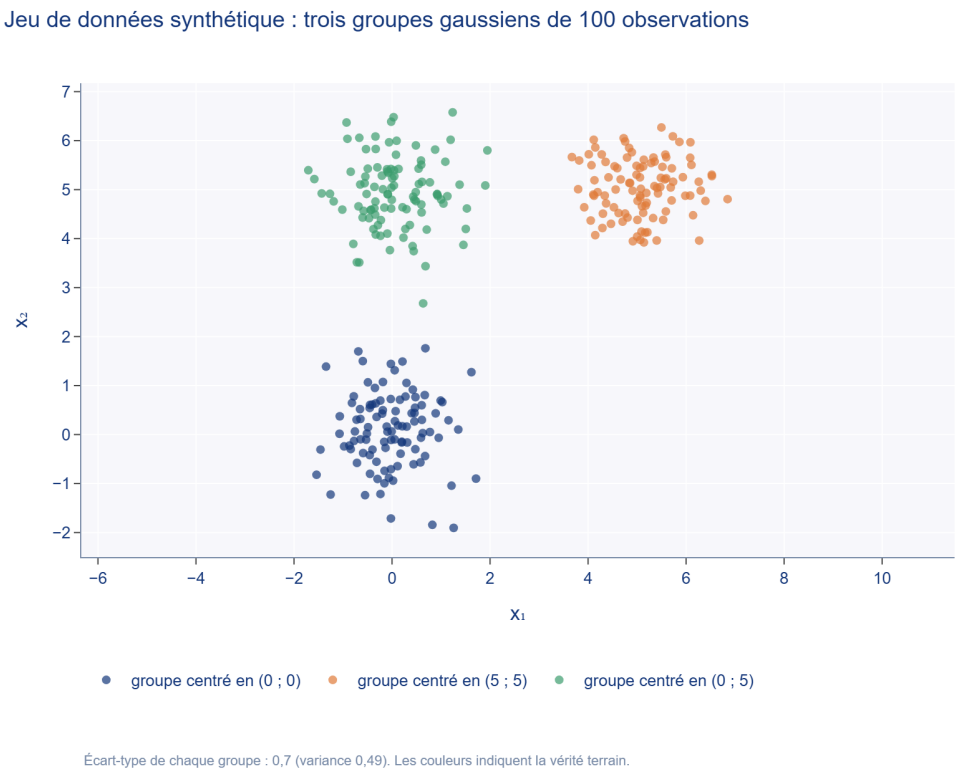


Figure 2.2: Jeu de données synthétique utilisé pour l'étude expérimentale : trois groupes gaussiens réels de 100 observations chacun (N = 300 au total).

2.4.2 Scénarios synthétiques S1 à S10

Les scénarios remplacent l'expérience unique du jeu de référence par des plans répliqués, chacun isolant un facteur que la thèse désigne comme décisif. Chaque point d'un plan est répété R fois, R étant fixé par le calcul de puissance (section 2.6) ; données d'apprentissage et de test sont tirées avec des graines dérivées du rôle de chaque tirage. Le tableau 2.7 résume les plans.

Scén.	Facteur	Génération	Mesure principale
S1	Chevauchement	3 gaussiennes de variance unité aux sommets d'un triangle, séparation de 1 à 5 écarts-types, $N = 300$	ARI, VB-emp contre EM-BIC
S2	Poids déséquilibrés	Poids 80, 15 et 5 %, séparation de 5 écarts-types	Perte de la composante minoritaire
S3	Sous-estimation de K	K vrai de 4 à 6 (centres alignés, écart 4), K choisi égal à 3	ARI, VB à $K_{\max} = 3$ contre EM à $K = 3$
S4	Queues épaisses	Composantes de Student à 3 degrés de liberté	ARI
S5	Dimension	$D \in \{2, 5, 10, 20\}$, séparation de 6 écarts-types	ARI
S6	Petit effectif	$N \in \{30, 60, 120, 300, 1\,000\}$, test de 1 000 points	Ajustements dégénérés, VB contre EM-$K_{\max}$
S7	Aberrations	Proportion de 1, 5 ou 10 % de points uniformes, amplitude de 5, 10 ou 20	ARI hors aberrations
S8	Seuil $d/2$ de α_0	$\alpha_0 \in \{1; 1{,}5; 2; 2{,}5; 3; 5; 10\}$, covariances pleine, diagonale et sphérique	Composantes actives (descriptif)
S9	Plan factoriel des priors	α_0 (4 niveaux) $\times$ β_0 (3) $\times$ $\nu_0 - D$ (2) $\times$ échelle de W_0 (3)	Part de variance de $\hat{K}$ (descriptif)
S10	Seuil d'activité	$\alpha_0 \in \{1/6; 1; 2{,}5; 10\}$, seuils $N_k \geq 1$, 0,5, 1 et 5 % de N	Composantes actives (descriptif)

Tableau 2.7: Plans des scénarios synthétiques

Le seuil théorique de S8 provient de Rousseau et Mengersen (2011) : $d/2 = 2{,}5$ (pleine), 2 (diagonale) et 1,5 (sphérique) en dimension 2. Cette théorie porte sur le posterior exact : un basculement observé ailleurs est une propriété du champ moyen, non une réfutation. Pour les covariances non pleines, le critère d'arrêt est une approximation (section 2.7.2).

2.4.3 Iris

Le jeu Iris de Fisher (1936) compte $N = 150$ fleurs de trois espèces décrites par $D = 4$ mesures en centimètres, non standardisées (fichier versionné). Il sert de première confrontation à des données réelles dont les groupes se chevauchent (versicolor et virginica) ; ses étiquettes, connues indépendamment des mesures, permettent de calculer l'ARI.

2.4.4 Prix alimentaires des marchés du Cameroun (cas pratique)

Problème réel. Le Cadre Harmonisé d'octobre 2025 estime que plus de 2,8 millions de personnes, soit 10 % de la population analysée, seront en insécurité alimentaire aiguë (phase 3 ou plus) au Cameroun entre juin et août 2026, principalement dans l'Extrême-Nord, le Nord-Ouest et le Sud-Ouest (FAO GIEWS, 2026 ; FEWS NET, 2026). Les prix des denrées de base y connaissent des chocs brusques et de sens opposés : le prix moyen du maïs blanc a augmenté de 24 % en un mois dans l'Extrême-Nord en août 2023 (PAM, 2023), alors qu'en avril 2026 le maïs et le sorgho se vendaient à Kousseri, Mokolo et Mora de 40 à 50 % moins cher qu'un an plus tôt, la demande d'exportation vers le Nigeria ayant reculé avec l'interdiction camerounaise d'exporter des céréales (FEWS NET, 2026). Le Programme alimentaire mondial (PAM) suit ces prix chaque mois et les classe, avec l'indicateur ALPS, en phases « normal », « stress », « alerte » et « crise » par comparaison à une tendance saisonnière estimée et à des seuils fixés (PAM, 2014). La question pratique est la suivante : *un mélange gaussien peut-il apprendre des régimes de prix à partir des données, sans seuils fixés à l'avance, et attacher à chaque marché et à chaque mois une probabilité d'être en régime de tension, avec une incertitude sur cette probabilité ?*

Lien avec la thèse. Ce cas met à l'épreuve, sur un problème réel, les axes du chapitre 2. (i) *Sélection de K* : le nombre de régimes n'est pas connu ; EM-BIC et le VB peuvent en retenir des nombres différents. (ii) *Petit effectif* : les séries sont courtes et trouées (quelques dizaines de mois par marché), ce qui place le cas dans le domaine où les priors du VB pèsent le plus (scénario S6). (iii) *Hyperparamètres* : la sensibilité du nombre de régimes aux priors est mesurée (HP5). (iv) *Incertitude* : la probabilité d'alerte s'accompagne d'un intervalle, de crédibilité pour le VB et bootstrap pour l'EM ; la couverture de ces intervalles est mesurée sur un jeu à vérité connue (HP6). (v) *Queues épaisses et aberrations* : les écarts de prix ont des queues plus épaisses qu'une gaussienne (scénarios S4 et S7). Les tests qui opérationnalisent ces axes sur ce cas (HP1 à HP7, HPP1 à HPP6) sont décrits au tableau 2.5 ; chacun peut être rejeté dans un sens ou dans l'autre, et l'équivalence est une issue légitime.

Données. Base de prix du PAM pour le Cameroun, diffusée sur la plateforme HDX (PAM, 2026) sous licence CC BY-IGO (redistribution autorisée avec attribution) : 77 268 relevés de janvier 2005 à août 2026, 83 marchés. L'extrait utilisé (`data/prix/wfp_cmr_panier.csv`, versionné avec le code, empreinte SHA-256 vérifiée au chargement ; script `outils/telecharger_prix_wfp.py`) retient les prix de détail en francs CFA par kilogramme de trois denrées de base : le *maïs blanc* (céréale locale), le *riz importé* (céréale importée, sensible au change et aux coûts d'importation) et le *niébé* (légumineuse, source de protéines). Ce panier a été choisi d'après la seule

couverture des séries, avant tout ajustement.

Variables. Pour la denrée j, le marché m et le mois t, la variable est l'écart du log-prix à son niveau des douze mois précédents :

$$e_j(m,t) = \ln p_j(m,t) - \frac{1}{|U|}\sum_{u\in U} \ln p_j(m,u), \qquad U = \{u \in [t{-}12,\, t{-}1] : p_j(m,u) \text{ relevé}\},$$

définie si au moins trois relevés existent dans la fenêtre. Un écart de +0,30 correspond à un prix environ 35 % au-dessus de son niveau récent. Cette variable est *causale* (aucune information postérieure à t), insensible aux mois manquants, et elle retire la dérive lente des prix (inflation) ainsi que la saisonnalité moyenne sur une année. Une observation (m,t) est retenue si les trois écarts sont définis : $x_{m,t} = (e_1, e_2, e_3) \in \mathbb{R}^3$. Les variables sont standardisées par la moyenne et l'écart-type de la seule période d'apprentissage.

Nettoyage déclaré. Un relevé est écarté s'il diffère d'un facteur au moins 3, dans le même sens, du relevé du mois précédent *et* de celui du mois suivant : c'est un pic isolé d'un mois, aller-retour, typique d'une virgule décalée (par exemple 97, puis 995, puis 97 XAF/kg pour le maïs à Doukoula en août, septembre et octobre 2023). Un triplement suivi d'un retour en un mois n'est pas plausible pour une denrée de base au détail : la plus forte hausse mensuelle citée par les bulletins du PAM pour le maïs de l'Extrême-Nord est de 24 %. La règle est fixée avant tout ajustement ; 21 relevés sont écartés, dont 14 en septembre 2023, et la liste complète figure au tableau **??**. Parce qu'elle utilise le relevé du mois suivant, cette règle convient à une analyse rétrospective mais pas, telle quelle, à une alerte en temps réel.

Validation temporelle. Apprentissage d'avril 2021 à décembre 2023 (562 observations, 50 marchés, 6 régions), test de janvier 2024 à août 2026 (493 observations, 27 marchés, 3 régions). La date de coupure a été choisie d'après le seul nombre d'observations, avant toute estimation, pour que l'évaluation porte sur des mois postérieurs à tout l'apprentissage (Roberts et al., 2017). La description des deux périodes est au tableau **??** et la carte des marchés à la figure 2.3.

Tableau « prix_descriptif » à générer : exécuter le code, puis `python tex_tables.py`.

figure à générer (`python run.py -figures`)

Figure 2.3: Marchés suivis : couleur et symbole par région, taille selon le nombre d'observations retenues (apprentissage et test). Source : PAM, base de prix du Cameroun (HDX, CC BY-IGO).

Bras. Les bras du chapitre 2, avec le même critère d'arrêt (figure 2.6), le même nombre de relances (registre, famille « prix ») et la covariance pleine : EM-$K_{\text{réf}}$, EM-$K_{\max}$, EM-BIC et EM-ICL (K de 1 à $K_{\max} = 8$), MAP-EM (priors empiriques et calibrés), VB à priors empiriques (VB-emp) et calibrés (VB-cal). $K_{\max} = 8$ est le

double des quatre phases usuelles d'alerte. Le *régime de tension* d'un ajustement est la composante active dont la moyenne des trois écarts, en unités d'origine, est la plus élevée ; la *probabilité d'alerte* d'une observation est sa responsabilité pour cette composante.

Plan. (a) *Référence* : EM-BIC sur toute la période d'apprentissage ; il fixe $K_{\text{réf}}$ et le modèle générateur du jeu semi-synthétique (tableau **??**). (b) *Sous-échantillons réels* : $N \in \{30, 60, 120, 250\}$ observations tirées dans l'apprentissage, tous les bras, évaluation sur toute la période de test. (c) *Semi-synthétique* : jeux de taille $N \in \{30, 60, 120, 250, 500\}$ tirés du modèle de référence, de sorte que K, la partition et les paramètres vrais sont connus et réalistes. (d) *Couverture* des intervalles à 90 % sur le semi-synthétique ($N \geq 120$) : intervalles de crédibilité du VB (tirages de la loi variationnelle) et bootstrap non paramétrique de l'EM à démarrage chaud, appariés aux composantes vraies par l'algorithme hongrois ; une composante vraie sans composante active appariée compte comme non couverte (couverture inconditionnelle), une indicatrice est tirée par paramètre scalaire et l'intervalle de la couverture est un bootstrap *par grappes* de réplications. (e) *Sensibilité* : $\hat{K}$ du VB sur les configurations de priors plausibles issues du calibrage, contre $\hat{K}$ de EM-BIC entre graines. (f) *Prévision* : log-score de chaque observation de test pour chaque modèle ajusté sur tout l'apprentissage. (g) *Alerte* : probabilité de tension de chaque observation, avec son intervalle à 90 %. Les nombres de réplications sont fixés par le calcul de puissance (registre, clés `prix_sous`, `prix_semi`, `prix_sensibilite`).

Les observations d'un même mois partagent les chocs communs (prix internationaux, change, saison) : pour les comparaisons de prévision, la différence de log-score est d'abord moyennée par mois, puis le test de Diebold et Mariano (1995) porte sur la série mensuelle. Le nombre de réplications écartées d'une comparaison appariée (bras en échec numérique) est rapporté dans la colonne « Exclues » des tableaux de décision.

2.4.5 Corpus de texte (pLSA contre LDA)

Niveaux d'inférence. La LDA de Blei, Ng et Jordan (2003) est présentée à tort comme un exact analogue du GMM bayésien. Au sens de la figure 2.1, la LDA du code est un *EM variationnel à θ ponctuel* : $q(\theta_d)$ est un Dirichlet (paramètres γ_d), mais les distributions de mots par thème β_k sont des paramètres ponctuels estimés à l'étape M et α est fixé. Elle n'est pas un VB complet. La correspondance avec le GMM est donc partielle : $\gamma_k \leftrightarrow \alpha_k$ vaut pour les poids de mélange (θ_d joue le rôle de π par document), mais β_k n'a pas de prior (contrairement à (μ_k, Λ_k) dans le GMM bayésien). Le comparateur « EM classique » de la LDA est le pLSA (Hofmann, 1999), qui estime θ_d et ϕ_k par maximum de vraisemblance sans prior.

Ce placement suit le texte original. Blei, Ng et Jordan (2003, section 5.3) estiment α et β par un EM variationnel de type bayes empirique : l'étape E optimise, document

par document, les paramètres variationnels γ_d de $q(\theta_d)$ et ϕ_{dn} de $q(z_{dn})$; l'étape M maximise la borne qui en résulte par rapport à α et β, qui restent ponctuels (niveau 2). Leur variante « lissée » (section 5.4) place un prior de Dirichlet de paramètre η sur chaque β_k, qui devient aléatoire et reçoit un facteur variationnel. C'est cette version que reprennent Hoffman et al. (2013) : les β_k y sont les variables *globales* et les (θ_d, z_{dn}) les variables *locales* de la section 1.7.7, et la SVI met à jour le paramètre variationnel de β par mini-lots de documents. La LDA lissée relève ainsi du niveau 3 pour toutes ses variables cachées, ses seuls points estimés étant les hyperparamètres α et η, que Blei, Ng et Jordan estiment encore par bayes empirique (section 5.4), comme le font les priors empiriques du VB de ce travail pour m_0 et W_0. La LDA du code correspond à la version non lissée, à α fixé et non estimé : la comparaison pLSA contre LDA mesure donc l'effet du prior sur θ_d seul, et non celui d'un traitement bayésien complet.

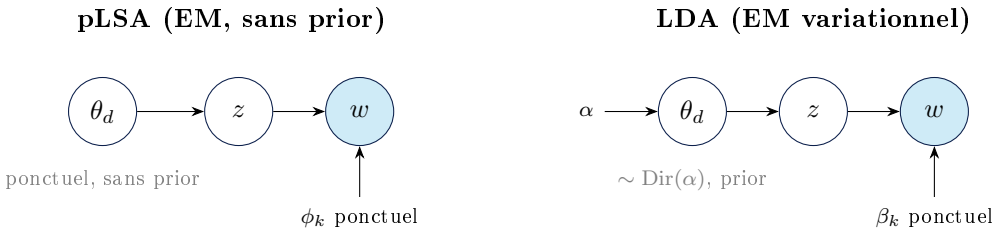


Figure 2.4: Modèles graphiques du pLSA et de la LDA utilisée ici. La différence testée est le prior de Dirichlet sur θ_d (LDA) contre un θ_d ponctuel sans prior (pLSA). Dans les deux cas les distributions de mots par thème sont ponctuelles : la LDA du code est un EM variationnel à β ponctuel, non un VB complet.

Hypothèse (HT1, rattachée à RH4). Le pLSA sur-apprend davantage que la LDA quand le nombre de documents N est petit (le prior de Dirichlet sur θ_d est la raison d'être de la LDA) ; l'écart se réduit quand N croît. Elle est testée par la différence appariée, par $N \in \{50, 200, 1\,000\}$, de l'écart relatif entre perplexité hors échantillon et perplexité sur les documents d'apprentissage.

Données et protocole. Sous-ensemble de 20 Newsgroups (quatre groupes : `sci.space`, `rec.sport.baseball`, `talk.politics.mideast`, `comp.graphics`), lu directement dans l'archive originale `20news-bydate.tar.gz`, sans bibliothèque d'apprentissage ; jeu de diffusion libre pour la recherche, sans licence explicite (à citer : Lang, 1995). Prétraitement, fixé avant l'analyse et identique pour les deux modèles : suppression des en-têtes, des lignes de citation et des signatures ; minuscules ; seules les suites de lettres sont gardées (ponctuation et chiffres écartés) ; mots d'au moins trois lettres, racinisés par l'algorithme de Porter (1980) écrit pour ce travail ; vocabulaire des 1 500 racines les plus fréquentes parmi celles présentes dans au moins cinq documents et dans au plus la moitié d'entre eux. Les mots vides sont écartés par ce seul critère de fréquence documentaire, sans liste externe ; les documents comptant moins de vingt occurrences de mots du vocabulaire sont exclus. La sensibilité des

conclusions à la taille du vocabulaire (500 et 3 000 racines) est mesurée. La perplexité hors échantillon est calculée par complétion de document (la moitié des mots d'un document sert à estimer θ_d, l'autre à l'évaluer, de façon identique pour les deux modèles) ; la cohérence des thèmes est mesurée par le NPMI des dix premiers mots ; la pureté est calculée par rapport aux étiquettes du corpus. Les deux modèles partagent le critère d'arrêt de la figure 2.6. Les probabilités sont planchées à 10^{-12} et la part de mots planchés est rapportée.

2.5 Protocole de comparaison

2.5.1 Bras comparés et critère d'arrêt commun

Tous les bras sont ajustés sur les mêmes données, avec le même critère d'arrêt, le même nombre de relances et la même graine d'ajustement : EM-K (K de référence), EM-$K_{\max}$ (même capacité que le VB), EM-BIC et EM-ICL (K choisi par balayage de 1 à $K_{\max}$), MAP-EM (priors Normal-Wishart du VB, Dirichlet plat $\alpha_0 = 1$, sans loi sur les paramètres), VB à priors empiriques (VB-emp), diffus (VB-diff) et calibrés (VB-cal). Une composante est active si N_k/N dépasse le seuil du registre, et $\hat{K}$ est le nombre de composantes actives, avec la même règle pour tous les bras. Le schéma de la figure 2.5 résume le protocole et celui de la figure 2.6 le critère d'arrêt commun.

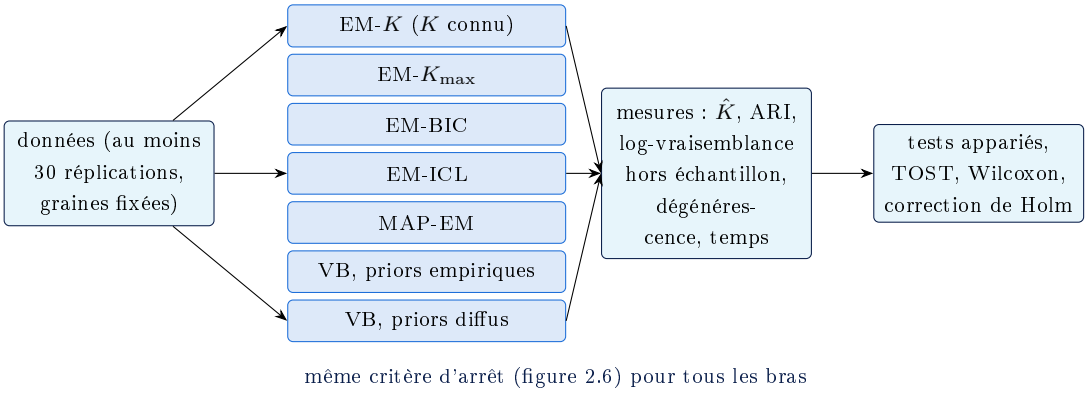


Figure 2.5: Protocole « 5 EM + VB » : tous les bras partagent le critère d'arrêt, les graines et les mesures ; chaque comparaison est appariée par réplication.

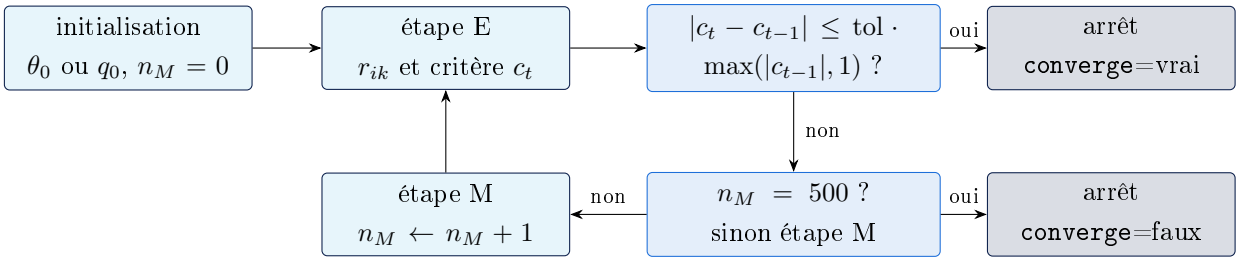


Figure 2.6: Critère d'arrêt commun à l'EM, au MAP-EM, à l'EM variationnel et au pLSA. Le critère c est la log-vraisemblance totale (EM) ou l'ELBO total (VB, covariance pleine), évalué après chaque étape E et avant l'étape M. Tolérance relative 10^{-6} et plafond commun de 500 étapes M ; n_M est le nombre d'itérations rapporté.

2.5.2 Métriques

L'ARI suppose une vérité terrain et dépend du nombre de composantes ; la silhouette n'est comparable qu'à K égal et n'est pas utilisée comme preuve. Les plans rapportent donc aussi la log-vraisemblance moyenne hors échantillon (plug-in pour tous les bras ; loi prédictive de Student en plus pour le VB, afin de séparer l'effet de la loi prédictive de celui des priors), l'erreur $|\hat{K} - K|$ lorsque K est connu, et la fréquence d'ajustements dégénérés (valeur propre minimale de Σ_k inférieure à 10^{-6} fois sa trace, ou $N_k < D+1$). Pour le cas pratique s'ajoutent la probabilité d'alerte (responsabilité du régime de tension), son intervalle à 90 % (tirages de la loi variationnelle pour le VB, bootstrap à démarrage chaud pour l'EM) et le log-score de chaque observation de la période de test. Les temps sont mesurés dans un seul processus et un seul fil, en temps total jusqu'au modèle final.

2.5.3 Tests statistiques et règle de décision

Chaque test déclaré porte sur les différences appariées $d_r = A_r - B_r$ des réplications r. Un test d'*équivalence* est un TOST (Schuirmann, 1987) à une marge fixée avant tout résultat confirmatoire : la plus petite différence d'intérêt, choisie par l'importance pratique (Lakens, 2017 ; Lakens, Scheel et Isager, 2018). Pour l'ARI, la marge vaut 0,05, soit la moitié de la largeur d'une classe de l'échelle de qualité de récupération usuelle (0,65 ; 0,80 ; 0,90 ; Steinley, 2004) : un écart inférieur ne fait pas franchir plus d'une frontière de classe. Pour la log-vraisemblance moyenne par observation, elle vaut 0,05 nat, soit environ $\log 1{,}05$: la densité prédictive d'une méthode dépasse celle de l'autre d'au plus 5 % en moyenne géométrique. Les décisions sont aussi rapportées à la moitié et au double de chaque marge, et le bruit d'optimisation (écart entre deux ajustements d'une même méthode) est mesuré pour vérifier que chaque marge le dépasse ; un test de *différence* est le test des rangs signés de Wilcoxon, calculé par sa loi exacte de permutation. La correction de Holm (1979) est appliquée au sein de chaque famille (scénarios, prix, prévision, texte), et la décision est prise sur la probabilité critique *ajus-*

tée. L'estimation rapportée est la moyenne des différences, avec son intervalle bootstrap percentile à 95 %, ainsi que l'estimateur de Hodges et Lehmann (1963), médiane des moyennes de Walsh $(d_i + d_j)/2$ pour $i \leq j$; c'est cet estimateur, cohérent avec le test de Wilcoxon, qui donne le sens d'une différence significative. Les réplications où un bras échoue numériquement sont exclues de la comparaison et leur nombre est rapporté (colonne « Exclues »). Les comparaisons de prévision du cas pratique utilisent le test de Diebold et Mariano (1995), avec la correction de Harvey, Leybourne et Newbold (1997), sur la série *mensuelle* des différences de log-score : les observations d'un même mois partagent des chocs communs et ne sont pas indépendantes.

Le verdict d'une décision au regard de son hypothèse de recherche est déclaré ainsi : *conforme* si la décision est celle qu'attend l'hypothèse ; *contraire* si elle démontre l'effet opposé ; *non tranché* si le test ne conclut pas (une équivalence non démontrée n'est pas une différence démontrée) ; une différence démontrée pour un test non orienté est rapportée sans être comptée pour ni contre l'hypothèse. Le bilan d'une hypothèse de recherche est le décompte de ces verdicts sur tous ses tests ; il n'est pas résumé par une seule probabilité.

Couverture des intervalles (HP6)

La sous-estimation de variance du champ moyen (section 1.5.4) ne peut être jugée que par la couverture empirique des intervalles à 90 % sur des jeux dont les paramètres vrais sont connus. Elle constitue une *prédiction théorique testée* : le champ moyen sous-estime la variance a posteriori (Bishop, 2006, section 10.1.2 ; Blei et al., 2017), et les intervalles qui en découlent sont trop étroits dans les mélanges (Wang et Titterington, 2005). La mesure est faite sur le jeu semi-synthétique du cas pratique (section 3.3, hypothèse HP6), pour le VB et pour le bootstrap de l'EM-BIC, qui choisit K par le BIC sur chaque jeu simulé comme le VB choisit le sien ; la comparaison porte sur la différence de couverture entre les deux, appariée par réplication. Le bootstrap de l'EM au K de référence, qui connaît K, sert de borne favorable à l'EM. Les deux bootstraps sont conditionnels au K retenu : ils ne propagent pas l'incertitude du choix de K, de même que les intervalles du VB sont conditionnels à sa structure élaguée. La couverture est *inconditionnelle* (une composante vraie sans composante active appariée compte comme non couverte) ; une indicatrice est tirée par paramètre scalaire, et l'intervalle de la couverture est un bootstrap par grappes de réplications, les indicatrices d'une même réplication n'étant pas indépendantes. Les intervalles de crédibilité et de confiance ne mesurent pas le même objet : leur couverture sur la valeur vraie est une comparaison de calibration, non de justesse bayésienne.

2.6 Calibrage des paramètres

Aucune valeur méthodologique n'est choisie à la main. Chaque paramètre est inscrit dans un registre (`parametres.py`, tableau 3.5 en annexe) avec un statut : *mathématique* (conséquence d'un résultat), *source* (valeur prescrite par une référence vérifiée), *plan* (choix de conception déclaré), ou *calibré* par une étude écrite dans le code. Tant qu'une valeur calibrée manque, l'orchestrateur refuse les étapes confirmatoires. Le calibrage s'exécute en sept vagues, chacune n'utilisant que des valeurs fixées par les vagues précédentes, et uniquement des données d'apprentissage (jamais la période de test du cas pratique) :

1. plafond des itérations de Lloyd pour l'initialisation par k-means (au plus 1 % des exécutions l'atteignent) ;

2. tolérance d'arrêt et plafond d'étapes M : plus grande tolérance dont 99 % des ajustements s'accordent avec une référence à 10^{-10} (critère et partition) ;

3. régularisation ε des covariances : rang moyen de la log-vraisemblance hors pli (blocs temporels contigus pour les prix) ;

4. nombre de relances par famille de données : probabilité au moins 0,99 qu'une relance atteigne le meilleur optimum (Biernacki et al., 2003), estimée sur 200 relances pilotes ;

5. hyperparamètres du bras VB-cal (recherche aléatoire puis divisions successives, Bergstra et Bengio, 2012 ; Jamieson et Talwalkar, 2016), hyperparamètres de la LDA et pas des variantes stochastiques, par validation croisée ;

6. contrôle des marges d'équivalence, fixées a priori (le bruit d'optimisation entre deux graines doit rester inférieur à la marge), et tailles Monte Carlo (erreur des bornes inférieure à la moitié de la dernière décimale affichée) ;

7. nombre de réplications : plus petit R donnant une puissance simulée d'au moins 0,8 au niveau de la première étape de Holm, d'après des réplications pilotes à graines disjointes ; une hypothèse sans variance pilote ne fixe pas R, et R est plafonné par un budget de temps déclaré, la puissance obtenue étant rapportée pour chaque hypothèse.

Chaque vague écrit sa valeur, sa règle et ses évaluations dans `resultats/calibrage/`, ce qui rend chaque choix traçable.

2.7 Implémentation et ingénierie du code

2.7.1 EM classique

L'EM classique est implémenté en PyTorch à partir des équations du chapitre 1, sans bibliothèque de modélisation : seules les opérations élémentaires (algèbre linéaire, factorisation de Cholesky, fonction digamma) sont utilisées, et les critères d'évaluation (BIC, AIC, indice de Rand ajusté, silhouette) sont écrits explicitement. Le code complet figure à l'annexe A ; les extraits ci-dessous montrent la correspondance avec les équations.

Étapes E et M

La densité gaussienne est évaluée par la factorisation de Cholesky de la covariance (section 2.2.2), puis l'étape E calcule les responsabilités en log-espace avec l'astuce du log-sum-exp (équations 1.15 et 1.18). L'étape M applique les mises à jour de l'équation (1.16).

```python
def logsumexp_stable(a: Tensor, dim: int = 1, keepdim: bool = True) -> Tensor:
    """Équation (1.18) : log sum exp(a_k) = a_max + log sum exp(a_k - a_max)."""
    a_max = a.max(dim=dim, keepdim=True).values
    out = a_max + torch.log(torch.exp(a - a_max).sum(dim=dim, keepdim=True))
    return out if keepdim else out.squeeze(dim)

def log_gauss(X: Tensor, mu: Tensor, cov: Tensor) -> Tensor:
    """log N(x | mu, cov) pour toutes les lignes de X, via Cholesky (section 2.2.2)."""
    D = X.shape[1]
    L = torch.linalg.cholesky(cov)
    z = torch.linalg.solve_triangular(L, (X - mu).T, upper=False)
    logdet = 2.0 * torch.log(torch.diagonal(L)).sum()
    return -0.5 * (D * LOG2PI + logdet + (z ** 2).sum(dim=0))

def _etape_e(X, pi, mu, cov):
    """Étape E (1.15) en log-espace : retourne (r, log p(x_i | theta))."""
    K = len(pi)
    log_r = torch.stack([torch.log(pi[k] + 1e-300) + log_gauss(X, mu[k], cov[k])
                         for k in range(K)], dim=1)
    log_norm = logsumexp_stable(log_r, dim=1)
    return torch.exp(log_r - log_norm), log_norm.squeeze(1)

def _etape_m(X, r, cov_type, reg):
    """Étape M (1.16) : pi_k = N_k/N, mu_k = moyenne pondérée, Sigma_k = covariance pondérée."""
    N = X.shape[0]
    Nk = r.sum(0) + 1e-10
    pi = Nk / N
    mu = (r.T @ X) / Nk[:, None]
    cov = _covariances_em(X, r, mu, Nk, cov_type, reg)
    return pi, mu, cov
```

Extrait de code : étapes E et M de l'EM classique (équations 1.15, 1.16 et 1.18)

Initialisation, relances et critère d'arrêt

Deux initialisations sont disponibles : par k-means (avec initialisation k-means++), qui donne un point de départ proche de la solution, et aléatoire (K points de données tirés au hasard et covariance globale, section 1.6.2.a). L'algorithme est relancé n_init fois et la solution de plus grande log-vraisemblance est conservée. Le critère d'arrêt est celui de la figure 2.6, commun à l'EM, au MAP-EM, au VB et au pLSA : variation relative du critère *total* inférieure à la tolérance calibrée, plafond d'étapes M calibré, la sortie rapportant `converge` (faux si le plafond est atteint : l'exécution est alors « non convergée »). Chaque covariance reçoit $+\varepsilon I$, ε étant calibré par validation croisée (registre, `reg_covariance`) : l'EM utilisé dans ce mémoire est donc régularisé, ce qui en fait un maximum local de la vraisemblance régularisée (section 1.6.3.a). Le code retourne aussi l'ICL, l'entropie des affectations et un indicateur de dégénérescence.

```
def _em_une_fois(X, K, cov_type, n_iter, tol, reg, init, graine, prior=None):
    N, D = X.shape
    pi, mu, cov = _init_em(X, K, cov_type, init, graine, reg)
    hist, converge, n_m = [], False, 0
    while True:
        r, log_norm = _etape_e(X, pi, mu, cov)
        hist.append(float(log_norm.sum()))
        if len(hist) > 1 and a_converge(hist[-2], hist[-1], tol):
            converge = True
            break
        if n_m >= n_iter:
            break
        pi, mu, cov = _etape_m(X, r, cov_type, reg)
        n_m += 1
    return {"pi": pi, "mu": mu, "cov": cov, "r": r, "loglik": hist[-1],
            "ll_hist": hist, "n_iter": n_m, "converge": converge}
```

Extrait de code : boucle de l'EM classique avec test d'arrêt

2.7.2 EM variationnel

L'EM variationnel pour le GMM bayésien est implémenté de la même façon. Les espérances nécessaires (équations 1.29 et 1.30) sont calculées avec la fonction digamma de PyTorch, les mises à jour suivent les équations (1.26) et (1.28), et l'ELBO de l'équation (1.31) est évaluée exactement à chaque itération (annexe B).

Étapes E et M variationnelles

```
def _attendus(P, D):
    """E[ln|Lambda_k|] (1.29) et E[Lambda_k] pour chaque composante."""
    if P["cov_type"] in ("full", "tied"):
        i = torch.arange(1, D + 1, dtype=torch.float64)
        Elogdet = (torch.special.digamma((P["nu"][:, None] + 1 - i) / 2).sum(-1)
                   + D * LN2 + torch.logdet(P["W"]))
```

```
        Elam = P["nu"][:, None, None] * P["W"]
    else:
        psi = torch.special.digamma(P["a"]) - torch.log(P["b"])
        Elogdet = psi.sum(-1)
        Elam = torch.diag_embed(P["a"] / P["b"])
    return Elogdet, Elam

def _etape_e_var(X, P):
    """Étape E variationnelle, équation (1.27), avec la forme quadratique (1.30)."""
    N, D = X.shape
    Elogpi = torch.special.digamma(P["alpha"]) - torch.special.digamma(P["alpha"].sum())
    Elogdet, Elam = _attendus(P, D)
    diff = X[None, :, :] - P["m"][:, None, :]
    quad = D / P["beta"][None, :] + torch.einsum("knd,kde,kne->nk", diff, Elam, diff)
    log_rho = Elogpi[None] + 0.5 * Elogdet[None] - 0.5 * D * LOG2PI - 0.5 * quad
    log_norm = logsumexp_stable(log_rho, dim=1)
    return torch.exp(log_rho - log_norm), log_norm.squeeze(1)
```

Extrait de code : étape E variationnelle (équations 1.27, 1.29 et 1.30)

```
def _etape_m_var(Nk, xbar, Sk, pr: PrioriNW, cov_type):
    """Étape M variationnelle, équations (1.26) et (1.28), plus les variantes de covariance."""
    K, D = xbar.shape
    beta = pr.beta0 + Nk
    m = (pr.beta0 * pr.m0 + Nk[:, None] * xbar) / beta[:, None]
    d0 = xbar - pr.m0
    terme_prior = (pr.beta0 * Nk / (pr.beta0 + Nk))
    sc = Nk[:, None, None] * Sk + terme_prior[:, None, None] * d0[:, :, None] * d0[:, None, :]
    P = {"alpha": pr.alpha0 + Nk, "beta": beta, "m": m, "cov_type": cov_type}
    if cov_type == "full":
        P["nu"] = pr.nu0 + Nk
        P["Winv"] = pr.W0inv[None] + sc
        P["W"] = torch.linalg.inv(P["Winv"])
    elif cov_type == "tied":
        P["nu"] = torch.full((K,), pr.nu0 + float(Nk.sum()))
        Winv = pr.W0inv + sc.sum(0)
        P["Winv"] = Winv.expand(K, D, D).clone()
        P["W"] = torch.linalg.inv(Winv).expand(K, D, D).clone()
    else:                                          # diag, spherical : priors Gamma sur les précisions
        a0 = pr.nu0 / 2.0
        b0 = 0.5 * torch.diagonal(pr.W0inv)
        sd = torch.diagonal(sc, dim1=1, dim2=2)
        if cov_type == "diag":
            P["a"] = (a0 + Nk / 2.0)[:, None].expand(K, D).clone()
            P["b"] = b0[None] + 0.5 * sd
        else:
            P["a"] = (a0 + D * Nk / 2.0)[:, None].expand(K, D).clone()
            P["b"] = (b0.mean() + 0.5 * sd.sum(1))[:, None].expand(K, D).clone()
    return P
```

Extrait de code : étape M variationnelle (équations 1.26 et 1.28 pour la covariance pleine)

Les variantes de covariance tied, diag et spherical, absentes du chapitre 1, sont obtenues avec un prior de Wishart partagé ou des priors Gamma sur les précisions.

Leur ELBO n'est ni dérivé ni implémenté : le critère d'arrêt est la somme des log-normalisations de l'étape E, c'est-à-dire l'ELBO privé du terme $\mathrm{KL}[q(\theta)\|p(\theta)]$, qui n'est pas nécessairement monotone. Ces variantes sont donc une *approximation* (clé `critere_nom` = `approximation_log_norm`) et les conclusions qui les concernent sont formulées en conséquence ; le terme D/β_k de l'étape E reste exact pour ces priors.

2.7.3 Orchestration reprenable et production des résultats

Les expériences sont organisées en étapes (calibrage, validation, illustrations, chronométrage, scénarios, prix, texte), chacune étant une liste d'unités indépendantes exécutées en parallèle. Chaque unité terminée est écrite de façon atomique dans un magasin d'artefacts ; les longs ajustements sauvegardent périodiquement l'état complet de leur boucle. Un calcul interrompu (erreur, coupure de courant, arrêt volontaire) reprend donc exactement où il s'était arrêté, sans rien recalculer, et un superviseur relance automatiquement le calcul après un arrêt non voulu. Les tableaux et les figures du chapitre 3 sont produits depuis ce magasin, sans recalcul ; les lectures factuelles qui accompagnent les décisions sont, elles aussi, écrites par le code à partir des fichiers de résultats. Aucun nombre des résultats n'est saisi à la main.

2.8 Menaces à la validité et écarts au protocole

Validité interne. Les comparaisons utilisent le même critère d'arrêt, les mêmes relances et les mêmes graines pour tous les bras ; l'EM du code est régularisé par εI, de sorte qu'aucune comparaison n'oppose un « EM non protégé » à un « VB protégé ». Les priors empiriques réutilisent les données (Bayes empirique) : le bras VB-diff et le plan factoriel S9 en mesurent l'effet. Le jeu semi-synthétique du cas pratique est tiré du modèle EM-BIC de référence, et l'erreur sur K (HP1) est mesurée par rapport au $K_{\text{réf}}$ que ce bras a choisi : la vérité est fabriquée par l'un des bras comparés, ce qui peut avantager EM-BIC par construction. Ce n'est pas une fuite d'information (les jeux simulés sont indépendants des données d'ajustement), mais les résultats semi-synthétiques se lisent sous cette réserve.

Validité externe. Les scénarios reposent sur des mélanges gaussiens (ou de Student) simples, de dimension au plus 20. Le cas pratique porte sur trois denrées, des séries courtes et trouées, et une période de test qui ne couvre que trois régions et dont la distribution diffère de l'apprentissage ; ses conclusions ne s'étendent pas d'elles-mêmes aux autres régions ou pays.

Validité de construit. L'ARI suppose une vérité terrain ; le nombre de composantes actives dépend du seuil d'activité (S10) ; un « régime de tension » est une composante du mélange, non un état observé. Les mesures sans étiquette (log-vraisemblance

et log-score hors échantillon) complètent donc l'ARI.

Validité statistique. Les observations spatiales et temporelles réelles ne sont pas indépendantes : la validation temporelle et l'agrégation mensuelle des comparaisons de prévision atténuent ce problème sans le supprimer. Les tests sont corrigés par famille, la puissance est fixée a priori, et les exclusions dues aux échecs numériques sont rapportées.

Écarts au protocole. (1) Les tests des scénarios ont été formalisés, un seul par hypothèse, après une première exécution exploratoire. (2) Les tests du cas pratique ont été déclarés le 27 octobre 2026, après la seule description de la couverture des données et avant tout ajustement de modèle ; le même jour, après un essai technique de la chaîne (deux réplications, paramètres provisoires, résultats non utilisés), le rattachement aux hypothèses de recherche a été ajouté, la sensibilité aux priors (HP5) est passée d'un constat descriptif à un test apparié, et le test HP7 a été ajouté pour isoler l'effet des priors. (3) La règle de nettoyage des relevés de prix a été fixée après l'inspection des données brutes, avant tout ajustement. (4) La réplication du jeu de référence sur trente tirages des versions antérieures est remplacée par les scénarios répliqués S1 à S10. (5) Le 4 novembre 2026, avant tout résultat confirmatoire, cinq règles ont été modifiées. Les marges d'équivalence, d'abord tirées du bruit d'optimisation (écart entre deux ajustements d'une même méthode), sont désormais fixées a priori par l'importance pratique : 0,05 pour l'ARI et 0,05 nat par observation pour la log-vraisemblance (section 2.6) ; la règle antérieure rendait l'équivalence presque impossible à démontrer, quelles que soient les méthodes, et le bruit d'optimisation sert désormais de contrôle. Une hypothèse dont les différences pilotes sont toutes identiques ne fixe plus le nombre de réplications de sa famille, et ce nombre est plafonné par un budget de temps, la puissance obtenue étant rapportée pour chaque hypothèse. La dégénérescence est comptée avec le même critère pour tous les bras (petite composante, ou valeur propre minimale inférieure à 10^{-6} fois la trace de la covariance finale), alors que le critère antérieur ne pouvait signaler un effondrement que pour l'EM. La couverture (HP6) compare le VB au bootstrap d'EM-BIC, qui choisit K comme le VB, le bootstrap à K connu servant de borne. Le sens d'une différence significative est donné par l'estimateur de Hodges-Lehmann, cohérent avec le test de Wilcoxon, et non plus par le signe de la moyenne.

Partie III

RÉSULTATS ET DISCUSSION

Chapitre 3

RÉSULTATS ET DISCUSSION

Ce chapitre présente et interprète les résultats du protocole décrit au chapitre 2. Il suit l'ordre de la preuve : validations numériques et illustrations exploratoires du mécanisme (section 3.1), scénarios confirmatoires (section 3.2), cas pratique des prix alimentaires du Cameroun (section 3.3), comparaison pLSA contre LDA (section 3.4), puis bilan des hypothèses de recherche (section 3.5), portée des conclusions (section 3.6) et recommandations (section 3.7). Tous les tableaux et les lectures factuelles des décisions sont produits par le code à partir des fichiers de résultats.

3.1 Validation numérique et illustrations exploratoires

Les expériences de cette section portent sur le jeu de référence (section 2.4.1) et sur Iris. Elles sont *exploratoires* : une seule exécution par configuration, avec K parfois imposé, de sorte qu'elles illustrent les mécanismes du chapitre 1 sans trancher aucune hypothèse de recherche ; les décisions confirmatoires sont celles des sections suivantes.

Tableau « validation_proprietes » à générer : exécuter le code, puis `python tex_tables.py`.

3.1.1 Sélection externe de K par BIC et AIC

Afin d'illustrer concrètement cette procédure de sélection externe, et de la comparer à l'approche endogène de l'EM variationnel, nous avons calculé le BIC et l'AIC de l'EM classique pour K variant de 1 à 8 sur le jeu de données à trois groupes réels utilisé tout au long de ce chapitre. La figure 3.1 présente les résultats obtenus.

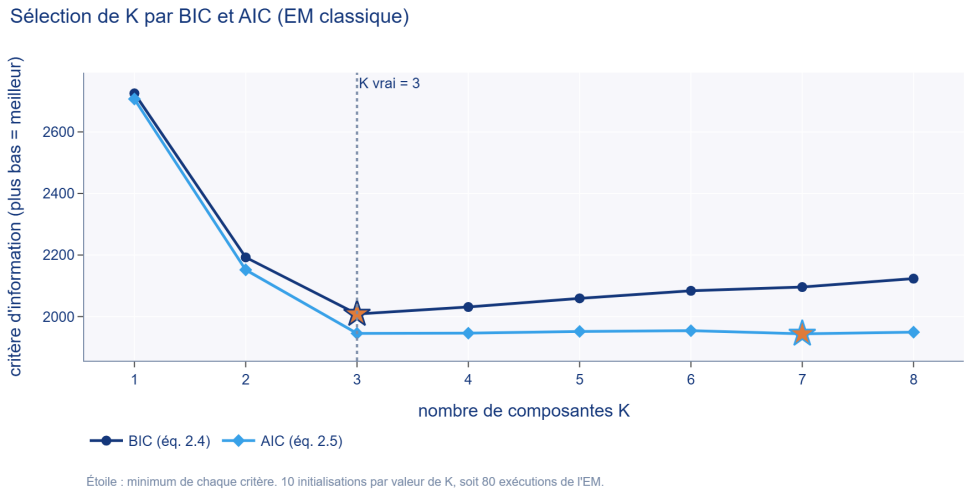


Figure 3.1: Critères BIC et AIC de l'EM classique en fonction du nombre de composantes K, sur le jeu de données à trois groupes réels.

Tableau « ill_bic_aic » à générer : exécuter le code, puis `python tex_tables.py`.

À compléter depuis les sorties de la nouvelle chaîne : valeur de K qui minimise le BIC et l'AIC sur le jeu de référence (étape illustrations).

Cette figure fixe la *baseline pertinente* pour la suite : la comparaison utile n'est pas « EM avec $K = 6$ imposé contre VB avec $K_{\max} = 6$ » (situation volontairement défavorable à l'EM, section 3.1.7), mais « EM avec K choisi par BIC ou ICL contre VB ». Le coût de cette baseline (un ajustement EM par valeur de K et par initialisation) est comparé au coût d'un ajustement variationnel en temps total, jamais en proportion du nombre de valeurs de K testées.

3.1.2 Résultats de l'EM classique (K = 6 imposé)

L'EM classique est ajusté avec $K = 6$ composantes (dix initialisations, critère d'arrêt commun) ; le nombre d'itérations, l'indicateur de convergence et l'indicateur de dégénérescence figurent au tableau **??**. Le tableau **??** présente les poids finaux obtenus pour chacune des six composantes.

À compléter depuis les sorties de la nouvelle chaîne : poids finaux de l'EM à $K = 6$, nombre de composantes actives au seuil $N_k/N \geq 1\,\%$, fragmentation éventuelle des groupes et ARI (tableau **??**, figure 3.2).

Quel que soit ce résultat, l'EM n'a aucun mécanisme interne pour reconnaître que $K = 6$ est surestimé ; un balayage de K par BIC ou ICL le fait (section 2.2.3), ce que compare la section 3.2.1.

3.1.3 Résultats de l'EM variationnel (Kmax = 6)

L'EM variationnel est ajusté avec $K_{\max} = 6$, des priors empiriques et un prior de Dirichlet de concentration $\alpha_0 = 1/K$; l'ELBO est calculée exactement selon l'équation (1.31). Sa valeur finale (figure 3.6) est inférieure à la log-vraisemblance maximale de l'EM classique, comme l'exige la chaîne d'inégalités ELBO $\leq \log p(X) \leq \max_\theta \log p(X \mid \theta)$: les deux quantités ne mesurent pas la même chose (l'ELBO intègre la pénalité de complexité due aux priors) et ne se comparent pas comme deux scores d'ajustement. Le tableau **??** présente les poids finaux obtenus.

Tableau « ill_k6 » à générer : exécuter le code, puis `python tex_tables.py`.

À compléter depuis les sorties de la nouvelle chaîne : poids finaux du VB à $K_{\max} = 6$, nombre de composantes éteintes et actives, ellipses comparées à celles de l'EM (tableau **??**, figure 3.2).

Un éventuel élagage ne libère pas le VB du choix de K : il dépend de $K_{\max}$ et des priors, ce que mesurent les sections suivantes.

À compléter depuis les sorties de la nouvelle chaîne : effet des priors diffus ($\beta_0 = 10^{-3}$, $W_0 = I$) sur les composantes actives, l'ARI et le nombre d'itérations (tableau **??**).

La section 3.2 mesure la dépendance aux priors sur des jeux répliqués d'un même générateur, et la section 3.2.5 par un plan factoriel sur les priors.

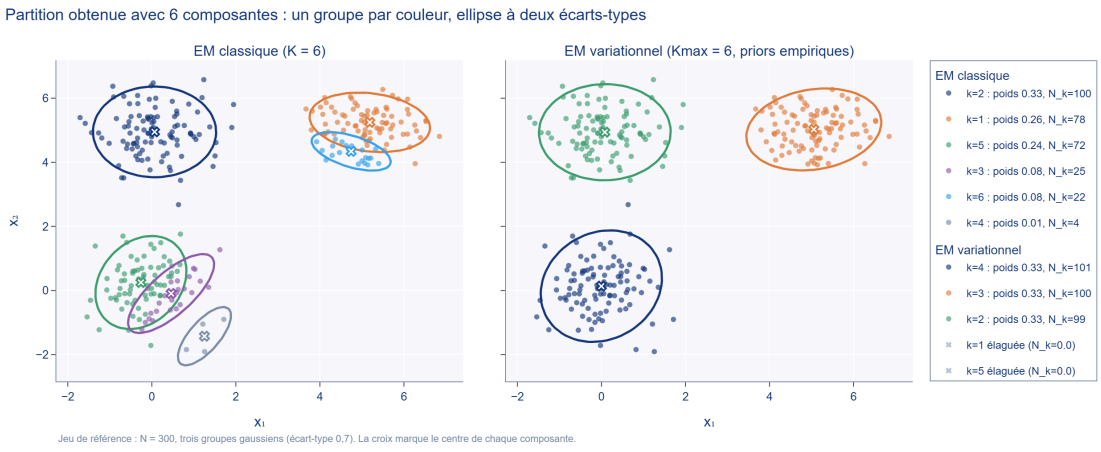


Figure 3.2: Partition obtenue avec six composantes : une couleur par composante, ellipses de covariance à deux écarts-types, croix aux centres. À gauche, l'EM classique conserve ses six composantes ; à droite, l'EM variationnel n'en retient que trois (les composantes élaguées figurent en gris dans la légende).

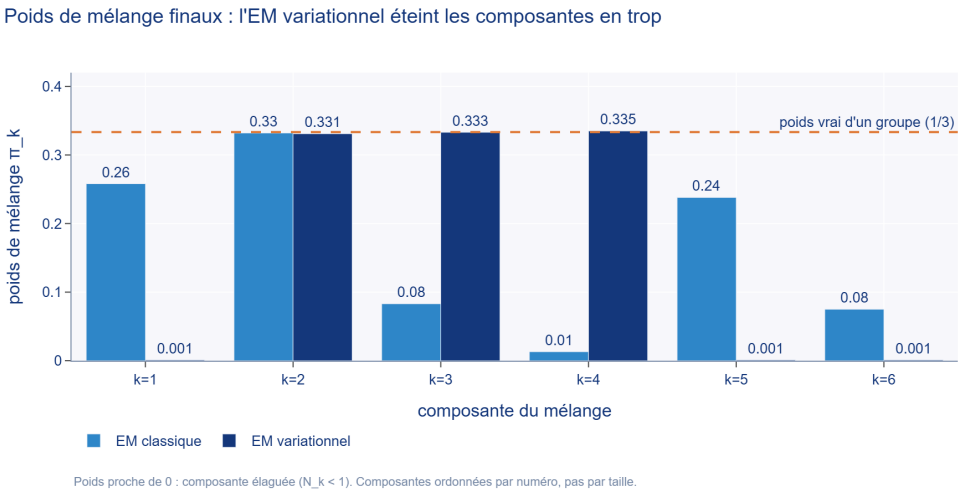


Figure 3.3: Poids de mélange π_k finaux pour les six composantes : EM classique et EM variationnel. Le contraste traduit le mécanisme d'élagage bayésien décrit à la section 1.7.4.

3.1.4 Comparaison visuelle et qualité de partition

Au-delà des poids de mélange, la qualité des partitions obtenues par les deux algorithmes peut être évaluée à l'aide de métriques externes de clustering, en comparant les affectations produites aux véritables étiquettes de groupe. Le tableau **??** présente les résultats obtenus pour l'indice de Rand ajusté (ARI) et le score de silhouette, calculés sur les affectations dures obtenues en prenant, pour chaque observation, la composante de responsabilité maximale.

Source : implémentation PyTorch (graine 42). Les temps sont ceux de cette exécution unique ; le coût est jugé par l'étape de chronométrage (HP4).

Ces résultats appellent quatre commentaires (tableau **??**). Premièrement, l'ARI du VB à priors empiriques est supérieur à celui de l'EM à $K = 6$: la partition du VB est proche des trois groupes générateurs, celle de l'EM à $K = 6$ est fragmentée. Cette comparaison est toutefois défavorable à l'EM par construction ($K = 6$ imposé) ; la comparaison pertinente est avec EM-BIC et EM-ICL (section 3.2.1). Deuxièmement, la silhouette n'est pas comparable entre des solutions de nombres de composantes différents : elle mesure surtout ce nombre, et n'est donc pas utilisée comme preuve. Troisièmement, avec le *même* critère d'arrêt, le nombre d'itérations du VB à priors empiriques n'est pas supérieur à celui de l'EM à $K = 6$; le constat antérieur d'un VB environ trois fois plus long provenait d'une asymétrie de normalisation du critère (par observation pour l'EM, totale pour le VB), et non d'une propriété des algorithmes. L'EM à composantes fragmentées et fortement chevauchantes converge lentement (taux linéaire proche de 1, section 1.6.3.b), ce que le tableau est compatible avec, sans l'établir. Quatrièmement, le temps total dépend aussi du nombre d'initialisations et de

l'implémentation : il n'est comparé qu'à critère et machine communs (sections 3.1.6 et 3.2.5).

3.1.5 Sensibilité au choix du prior de Dirichlet (α_0)

La section 1.7.4 a montré que la concentration α_0 du prior de Dirichlet contrôle l'élagage. Pour le vérifier, l'expérience de la section 3.1.3 est répétée en faisant varier α_0 sur la grille $\{0{,}001;\ 0{,}01;\ 0{,}1;\ 1;\ 10\}$, toutes choses égales par ailleurs ($K_{\max} = 6$, mêmes données, dix initialisations), pour les deux jeux de priors (tableau **??**, figure 3.4). Cette grille est grossière autour de la zone de transition : la section 3.1.13 la complète.

Tableau « ill_alpha0 » à générer : exécuter le code, puis `python tex_tables.py`.

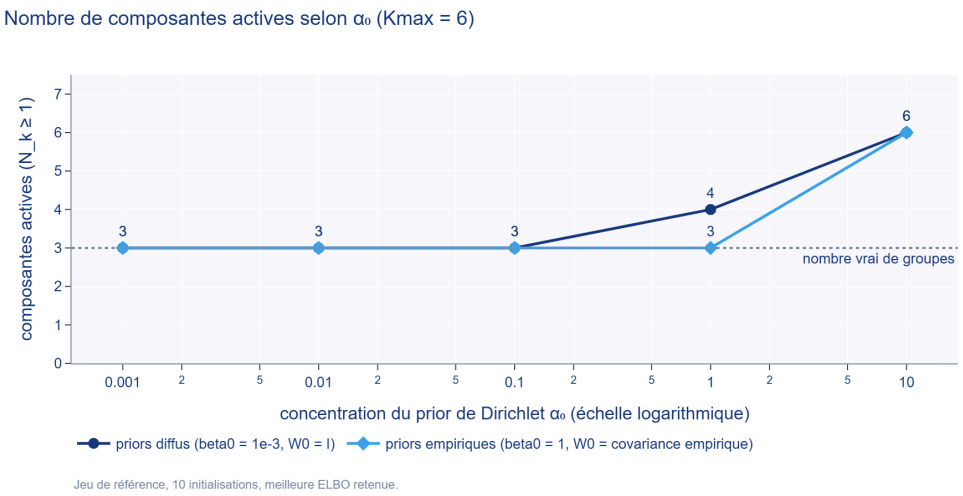


Figure 3.4: Nombre de composantes actives en fonction de la concentration α_0 du prior de Dirichlet (échelle logarithmique), pour les deux jeux de priors. Le mécanisme d'élagage disparaît lorsque α_0 devient grand.

À compléter depuis les sorties de la nouvelle chaîne : nombre de composantes actives et ARI en fonction de α_0, pour les deux jeux de priors (tableau **??**).

Le seuil théorique $d/2 = 2{,}5$ de Rousseau et Mengersen (2011), pour une covariance pleine en dimension 2, porte sur le posterior exact et non sur le champ moyen : toute concordance observée reste une hypothèse, que la grille de la section 3.1.13 teste autour du seuil. Le nombre de composantes actives dépend du seuil d'activité et n'est pas, à lui seul, une mesure de la qualité de la partition.

3.1.6 Étude de la scalabilité computationnelle

Pour quantifier le surcoût de l'EM variationnel identifié à la section 2.2.1, le temps d'exécution des deux algorithmes est mesuré en faisant varier le nombre d'observations

N (à $D = 2$) et la dimension D (à $N = 2000$). Chaque configuration est répétée vingt fois (registre `repetitions_chronometrage`, médiane), avec une initialisation et le critère d'arrêt commun ; le tableau **??** sépare le temps jusqu'au modèle final, le nombre d'itérations et le coût par itération. Tableau et figure 3.5 sortent du même run.

Tableau « chronometrage » à générer : exécuter le code, puis `python tex_tables.py`.

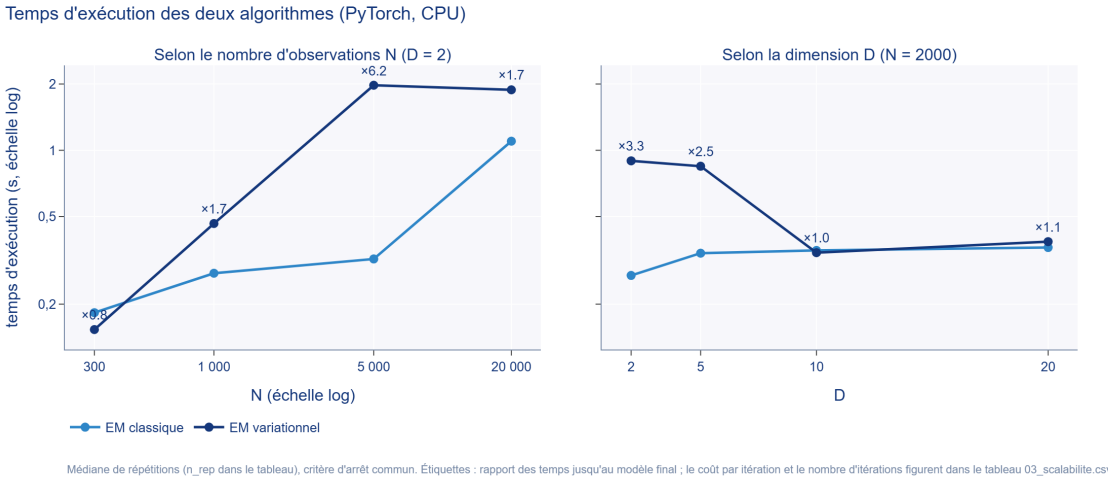


Figure 3.5: Temps d'exécution des deux algorithmes en fonction du nombre d'observations N (à gauche, échelles logarithmiques) et de la dimension D (à droite). Les étiquettes donnent le rapport du temps variationnel au temps classique.

Source : implémentation PyTorch (CPU, machine unique, graine 42).

Les deux grandeurs doivent être lues séparément. Le *coût par itération* du VB est supérieur à celui de l'EM d'un facteur de l'ordre de l'unité à quelques unités, sans tendance monotone nette en N ni en D (colonne « Ratio coût/itér. »). Le *temps jusqu'au modèle final* est le produit de ce coût par le nombre d'itérations, qui varie d'une configuration à l'autre et dans un sens ou dans l'autre (colonnes « Itér. EM » et « Itér. VB ») : le ratio global ne se réduit donc ni à un facteur multiplicatif stable ni à l'analyse de complexité de la section 2.2.1, qui porte sur le coût par itération. Les mesures sont des médianes de dix répétitions, mais restent propres à une machine, à une implémentation et à des données synthétiques de $D \leq 20$. La conclusion « le VB est x fois plus lent » n'est donc pas retenue ; la question utile, le temps total d'un pipeline EM-BIC contre un VB, est traitée à la section 3.2.5.

3.1.7 Cas de référence : nombre de composantes correctement spécifié (K = 3)

Les résultats précédents portent sur le cas, volontairement défavorable à l'EM classique, où le nombre de composantes est surestimé. Pour vérifier que les deux algorithmes se

comportent de façon comparable en l'absence de cette surestimation, l'expérience est répétée avec $K = 3$, le nombre exact de groupes (tableau **??**).

Tableau « ill_k3 » à générer : exécuter le code, puis `python tex_tables.py`.

À compléter depuis les sorties de la nouvelle chaîne : comparaison de l'EM et du VB à $K = 3$: ARI, silhouette et nombre d'itérations (tableau **??**).

Le nombre d'itérations dépend de la tolérance relative commune appliquée à des critères d'échelles différentes (log-vraisemblance et ELBO) et ne se compare pas comme une propriété intrinsèque. Le choix entre les deux algorithmes ne peut pas s'appuyer sur le seul contraste à K surestimé : il dépend de la confiance dans K, du besoin d'incertitude et du budget de calcul (grille du tableau 3.1).

3.1.8 Convergence de l'ELBO

La section 1.7.6 a établi que l'ELBO constitue, pour l'EM variationnel, un critère de convergence croissant et borné. La figure 3.6 retrace l'évolution de l'ELBO, calculée exactement à chaque itération (équation 1.31) pour le modèle à $K_{\max} = 6$ de la section 3.1.3 (même appel, donc même nombre d'itérations que le tableau **??** : un seul décompte dans tout le mémoire), ainsi que la log-vraisemblance de l'EM classique à $K = 6$.

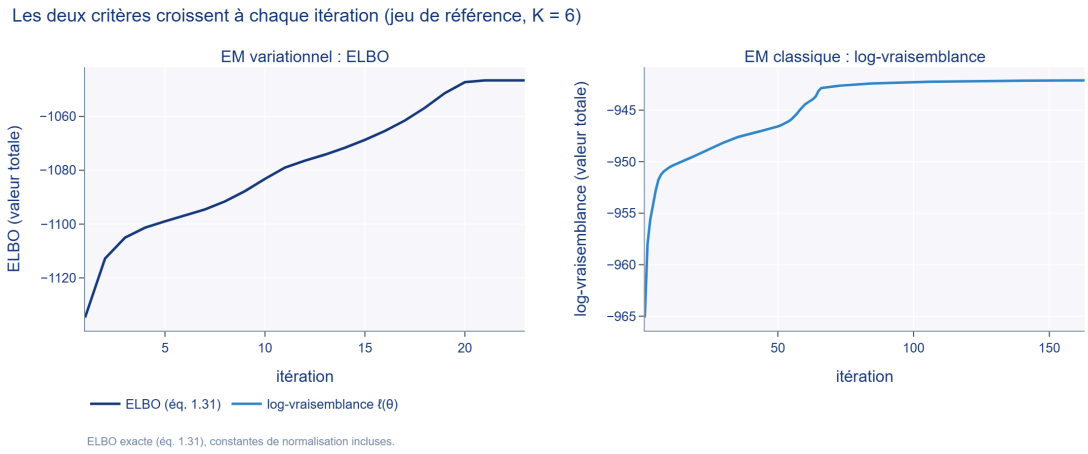


Figure 3.6: Évolution de l'ELBO (EM variationnel, à gauche) et de la log-vraisemblance (EM classique, à droite) en fonction du nombre d'itérations. Les deux courbes sont croissantes, conformément aux garanties théoriques des sections 1.6.2.f et 1.7.6.

L'ELBO croît strictement à chaque itération, conformément à la garantie de la section 1.7.6 ; cette monotonie, l'inégalité ELBO $\leq \log p(X) \leq \ell(\hat{\theta})$ et l'égalité de Neal et Hinton, $F(q^*, \theta) = \ell(\theta)$ après l'étape E, sont vérifiées numériquement par le code (journal d'exécution) et par des tests unitaires. L'ELBO gagne l'essentiel de son gain

dans les premières itérations puis se stabilise. La courbe de log-vraisemblance de l'EM est tracée jusqu'à son critère d'arrêt, identique à celui du VB.

3.1.9 Robustesse à l'initialisation

Les résultats précédents ont été obtenus avec dix initialisations indépendantes, dont la meilleure est conservée (sections 1.6.3.a et 1.7.9). Pour mesurer la sensibilité propre de chaque algorithme, l'expérience de la section 2.4.1 est répétée avec une seule initialisation par exécution, pour 20 graines et deux stratégies : initialisation par k-means et initialisation aléatoire (K points de données tirés au hasard, sections 1.6.2.a et 1.7.3.d).

Tableau « ill_initialisation » à générer : exécuter le code, puis `python tex_tables.py`.

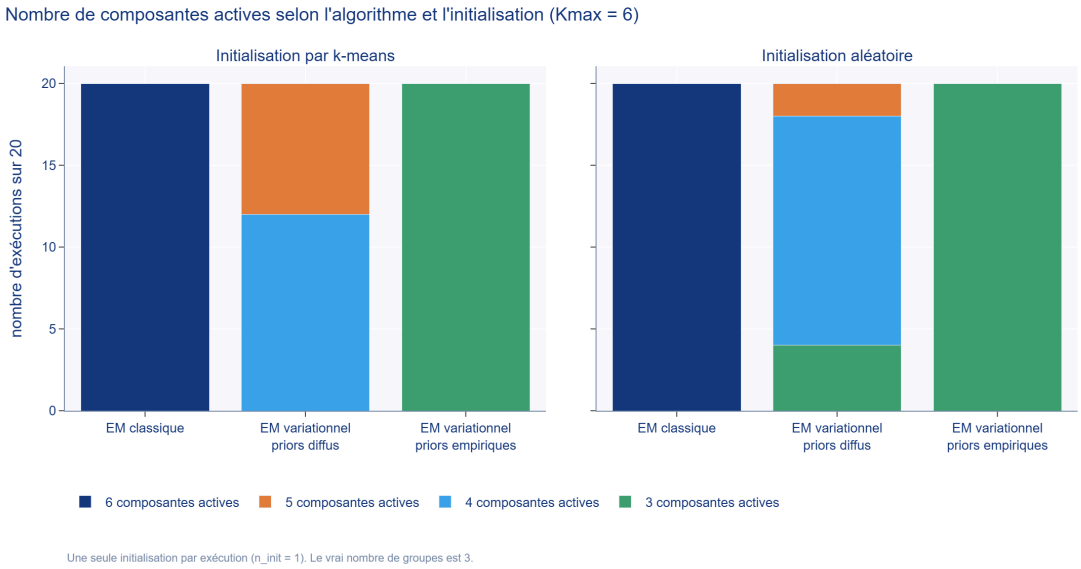


Figure 3.7: Répartition du nombre de composantes actives selon l'algorithme et la stratégie d'initialisation (20 exécutions chacune, une initialisation par exécution).

À compléter depuis les sorties de la nouvelle chaîne : nombre de composantes actives du VB selon l'initialisation, pour les priors empiriques et diffus (tableau **??**).

À K fixé à 6, l'EM classique conserve par construction ses six composantes, puisque rien n'en élimine : le seul résultat informatif de cette expérience est celui du VB.

3.1.10 Sensibilité au type de covariance

L'ensemble des expériences précédentes ont été conduites avec des matrices de covariance pleines (full), c'est-à-dire sans contrainte sur la forme des ellipses de covariance de chaque composante. En pratique, il est fréquent de contraindre cette forme, tant pour réduire le nombre de paramètres libres et le risque de surapprentissage que pour

accélérer les calculs. Les quatre contraintes les plus courantes, par ordre décroissant de flexibilité, sont : full (une matrice pleine par composante), tied (une unique matrice pleine partagée par toutes les composantes), diag (une matrice diagonale par composante) et spherical (une variance scalaire par composante). Pour l'EM variationnel, les variantes tied, diag et spherical ne sont pas dérivées au chapitre 1 ; elles utilisent un prior de Wishart partagé (tied) ou des priors Gamma sur les précisions (diag, spherical), également conjugués. Le tableau **??** reproduit l'expérience de la section 3.1.4 pour chacune de ces contraintes.

Tableau « ill_covariance » à générer : exécuter le code, puis `python tex_tables.py`.

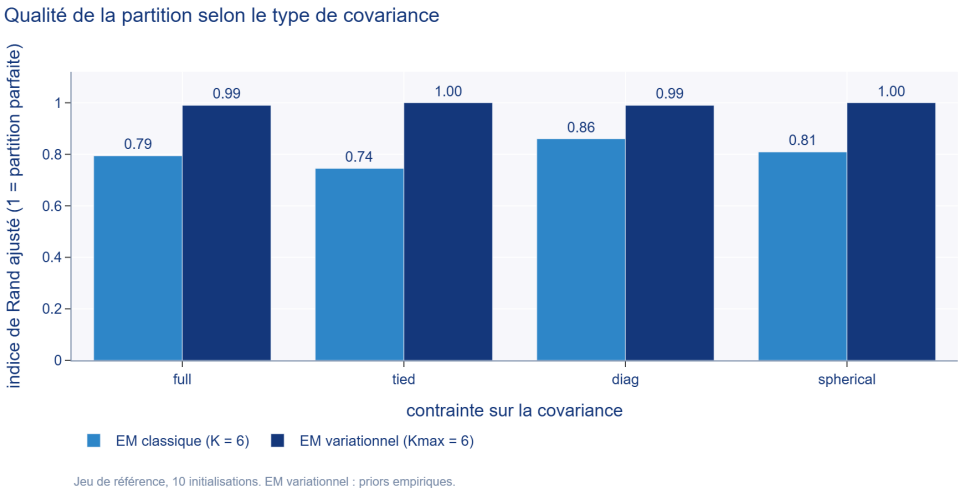


Figure 3.8: Indice de Rand ajusté selon la contrainte imposée sur la covariance (K = 6 imposé).

À compléter depuis les sorties de la nouvelle chaîne : composantes actives et ARI du VB et de l'EM à $K = 6$ selon la forme de covariance (tableau **??**).

Pour tied, diag et spherical, le VB utilise un critère d'arrêt approché (somme des log-normalisations de l'étape E, ELBO privé du terme KL sur θ, non nécessairement monotone) et l'ELBO de ces variantes n'est pas dérivé : un élagage éventuel est donc observé *avec une approximation*, et son extension à ces formes reste à valider en dérivant l'ELBO de chaque variante (section 2.7.2).

3.1.11 Validation sur un jeu de données réel (Iris)

Les résultats précédents ont été obtenus sur un jeu synthétique de trois groupes gaussiens séparés. Pour sortir de ce cadre idéalisé, l'expérience centrale est reproduite sur le jeu Iris de Fisher (1936) : $N = 150$ observations en dimension $D = 4$, trois espèces,

mesures brutes en centimètres (non standardisées), avec $K = 6$ imposé, puis $K = 3$ (tableau **??**).

Tableau « ill_iris » à générer : exécuter le code, puis `python tex_tables.py`.

Source : Iris de Fisher (1936), fichier UCI Machine Learning Repository ; calculs de l'auteur.

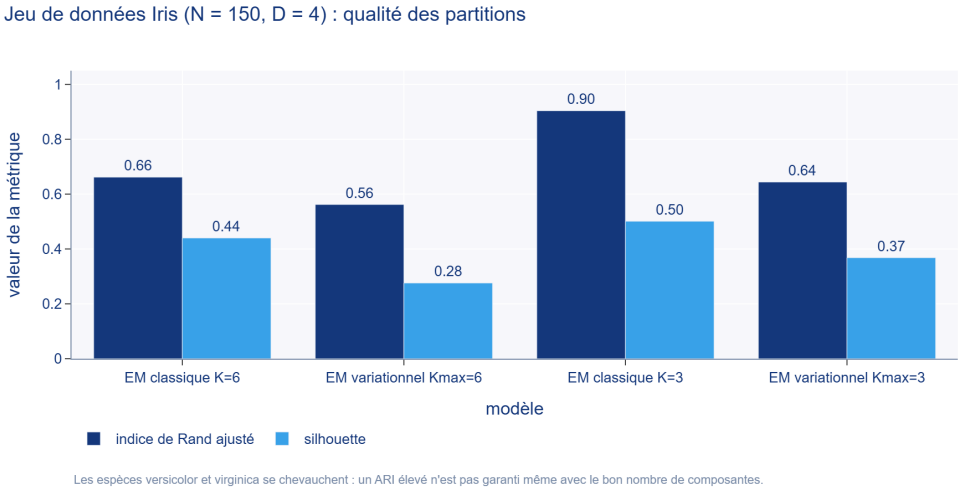


Figure 3.9: Indice de Rand ajusté et silhouette sur le jeu Iris, selon l'algorithme et le nombre de composantes.

À compléter depuis les sorties de la nouvelle chaîne : composantes actives, poids finaux et ARI du VB à $K_{\max} = 6$ et de l'EM à $K = 6$ sur Iris (tableau **??**), et indicateur de dégénérescence.

Un point de méthode : avec $N = 150$, $D = 4$ et $K = 6$ en covariance pleine, l'EM compte 89 paramètres libres pour 150 points (6×4 moyennes, 6×10 termes de covariance, 5 poids), cas typique de singularité. L'ARI suppose que les étiquettes définissent les groupes à retrouver ; si deux espèces se chevauchent, la log-vraisemblance hors échantillon et la comparaison avec EM-BIC sont plus informatives.

À compléter depuis les sorties de la nouvelle chaîne : ARI et poids du VB à $K_{\max} = 3$ comparés à $K_{\max} = 6$ et à l'EM à $K = 3$ sur Iris (tableau **??**) ; dépendance du résultat du VB à $K_{\max}$.

3.1.12 Sensibilité aux valeurs aberrantes

Une dernière expérience examine le comportement des deux algorithmes en présence de valeurs aberrantes, situation fréquente en pratique et distincte de la simple surestimation de K. Dix points, tirés uniformément dans le carré $[-10; 15]^2$ (graine 7), ont été

ajoutés au jeu de données de la section 2.4.1, puis les deux algorithmes ont été ajustés avec K = 6 sur ce jeu augmenté (N = 310).

Tableau « ill_aberrantes » à générer : exécuter le code, puis `python tex_tables.py`.

Cette expérience, fondée sur un seul tirage (graine 7), n'est pas un test de robustesse : elle illustre le comportement des composantes en présence d'aberrations.

À compléter depuis les sorties de la nouvelle chaîne : ARI hors aberrations de l'EM à $K = 6$ et du VB, avec et sans aberrations, et rôle des composantes excédentaires (tableau **??**).

Un test de robustesse exige au moins 30 tirages, des proportions et des amplitudes d'aberrations variées, et une comparaison avec la baseline EM-BIC (et, idéalement, une composante uniforme de fond) : c'est le scénario S7 de la section 3.2.3.

3.1.13 Grille de α_0 autour du seuil $d/2$ (S8, descriptif)

La grille du tableau **??** (0,001 à 10) saute la zone de transition. La grille $\alpha_0 \in \{1; 1{,}5; 2; 2{,}5; 3; 5; 10\}$ est donc évaluée pour les trois types de covariance, dont les seuils théoriques de Rousseau et Mengersen (2011) sont $d/2 = 2{,}5$ (pleine), 2 (diagonale) et 1,5 (sphérique) en dimension 2. L'hypothèse testée est que le nombre de composantes actives change de régime autour de ces seuils ; la théorie portant sur le posterior exact, l'observation d'un seuil ailleurs n'est pas une réfutation de la théorie mais une propriété du champ moyen. Résultats : tableau **??**. Le tableau indique la part d'exécutions non convergées, et pour les covariances non pleines le critère est une approximation (section 2.7.1).

Tableau « S8_alpha0 » à générer : exécuter le code, puis `python tex_tables.py`.

Lecture.

À compléter depuis les sorties de la nouvelle chaîne : nombre de composantes actives en fonction de α_0 pour les trois types de covariance (scénario S8), et position des transitions par rapport aux seuils $d/2$.

Quel que soit ce résultat, il ne peut ni confirmer ni réfuter la théorie de Rousseau et Mengersen (2011), qui porte sur le posterior exact : il situe seulement, pour le champ moyen, la zone où α_0 pilote $\hat{K}$.

3.2 Scénarios confirmatoires S1 à S10

Cette section présente les résultats des scénarios dont le plan est décrit à la section 2.4.2. Pour chaque point du plan, les tableaux donnent les moyennes par bras sur les réplications ; les décisions des tests déclarés (TOST ou Wilcoxon exact, correction de Holm

sur la famille des scénarios) figurent au tableau **??** et à la figure 3.10, et leur lecture, rattachée aux hypothèses de recherche, suit.

3.2.1 Chevauchement, déséquilibre et sous-estimation de K (S1 à S3)

Tableau « scenario_S1 » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « scenario_S2 » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « scenario_S3 » à générer : exécuter le code, puis `python tex_tables.py`.

3.2.2 Queues épaisses, dimension et petit effectif (S4 à S6)

Tableau « scenario_S4 » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « scenario_S5 » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « scenario_S6 » à générer : exécuter le code, puis `python tex_tables.py`.

Le taux d'ajustements dégénérés de S6 est celui de l'EM *régularisé* par εI (section 2.7.1) ; il ne dit rien de l'EM non régularisé.

3.2.3 Aberrations (S7)

Tableau « scenario_S7 » à générer : exécuter le code, puis `python tex_tables.py`.

3.2.4 Décisions et lecture

Tableau « decisions_scenarios » à générer : exécuter le code, puis `python tex_tables.py`.

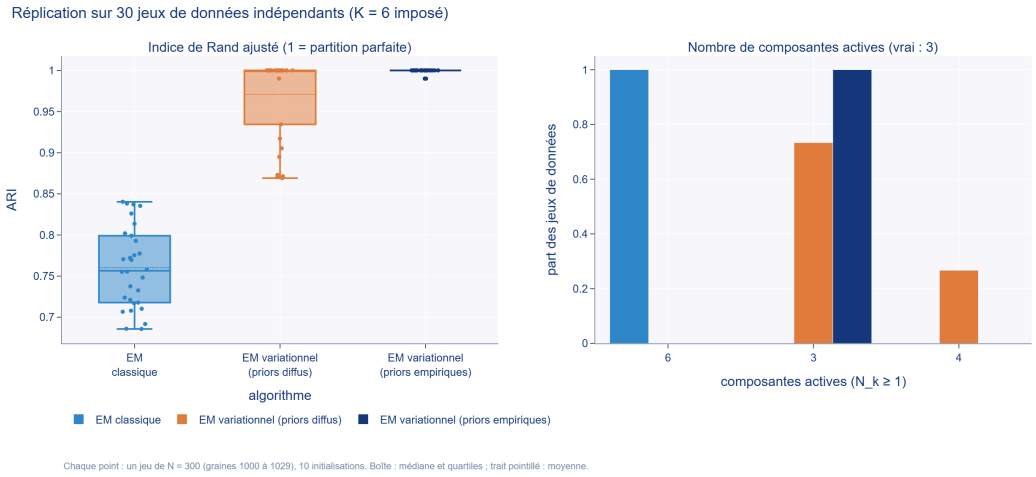


Figure 3.10: Décisions de la famille des scénarios : différence moyenne appariée (VB moins EM) et intervalle bootstrap à 95 %, marge d'équivalence en gris.

3.2.5 Plan factoriel sur les priors et seuil d'activité (S9 et S10, descriptifs)

Le plan factoriel fait varier α_0, β_0, ν_0 et l'échelle de W_0 ; la part de variance du nombre de composantes actives expliquée par chaque facteur est rapportée (tableau **??**). Le scénario S10 montre la sensibilité du nombre de composantes actives au seuil (0,5 %, 1 %, 5 % de N, et $N_k \geq 1$) : tant que ce nombre dépend du seuil, il ne constitue pas une mesure fiable de $\hat{K}$.

Tableau « S9_variance » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « S10_seuil » à générer : exécuter le code, puis `python tex_tables.py`.

Lecture (S9 et S10).

À compléter depuis les sorties de la nouvelle chaîne : part de la variance du nombre de composantes actives attribuée à α_0, β_0, l'échelle de W_0 et ν_0 (tableau **??**) ; effet du seuil d'activité (tableau **??**).

3.2.6 Coût de la sélection de K en temps total

Tableau « cout_selection » à générer : exécuter le code, puis `python tex_tables.py`.

Le rapport des temps médians entre le pipeline EM-BIC complet et un ajustement VB, à relances égales, est mesuré dans un seul processus sur les données de prix ; la décision HP4 (hypothèse RH5) est lue à la section 3.3. Le coût par itération (tableau **??**) et le temps total jusqu'au modèle final ne se confondent pas : seul le second compare des pipelines.

3.3 Cas pratique : régimes de tension des prix alimentaires au Cameroun

Le cas, ses données et son plan sont décrits à la section 2.4.4. Les résultats sont produits par le code depuis le magasin d'artefacts : modèle de référence (tableau **??**), moyennes par plan, effectif et bras (tableau **??**), décisions (tableau **??** et figure 3.14), ajustements sur toute la période d'apprentissage (tableau **??**), comparaisons de prévision (tableau **??**), régime de tension et probabilités d'alerte (tableau **??**, figures 3.12 et 3.13).

Tableau « prix_reference » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « prix_resume » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « decisions_prix » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « prix_complet » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « prix_dm » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « prix_alerte » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « prix_ecartes » à générer : exécuter le code, puis `python tex_tables.py`.

figure à générer (`python run.py -figures`)

Figure 3.11: Sélection du nombre de régimes sur toute la période d'apprentissage : BIC de l'EM selon K (gauche) et poids des composantes du VB à priors empiriques avec $K_{\max} = 8$ (droite).

figure à générer (`python run.py -figures`)

Figure 3.12: Trois marchés les plus suivis pendant la période de test. En haut : écart du prix du maïs à son niveau des douze mois précédents. En bas : probabilité du régime de tension selon EM-BIC (bande : bootstrap à 90 %) et selon le VB à priors empiriques (bande : crédibilité à 90 %). Trait pointillé vertical : fin de l'apprentissage.

figure à générer (`python run.py -figures`)

Figure 3.13: Part mensuelle des observations dont la probabilité de tension dépasse 0,5, tous marchés confondus, selon EM-BIC et le VB à priors empiriques.

figure à générer (`python run.py -figures`)

Figure 3.14: Décisions de la famille « prix » : différence moyenne appariée (VB moins EM) et intervalle bootstrap à 95 % ; bande grise : marge d'équivalence.

Lecture des résultats du cas

La confrontation des épisodes d'alerte aux épisodes datés par les bulletins du PAM et de FEWS NET (août 2023 dans l'Extrême-Nord, baisse des céréales en 2026) se lit sur les figures 3.12 et 3.13 ; elle est qualitative et ne constitue pas une validation statistique.

Limites. (1) *Changement de distribution* : l'écart moyen du maïs passe de +0,04 à l'apprentissage à −0,12 au test (tableau **??**), conformément à la baisse des céréales signalée par FEWS NET ; la période de test ne ressemble donc pas à l'apprentissage, et les log-scores de test mesurent aussi ce changement. (2) *Couverture géographique* : le test ne couvre que trois régions, surtout l'Extrême-Nord ; les conclusions ne s'étendent pas aux autres régions sans nouvelle analyse. (3) *Dépendance* : les observations d'un même marché sont corrélées dans le temps et celles d'un même mois partagent des chocs communs, ce qui viole l'hypothèse i.i.d. du mélange ; la moyenne par mois des comparaisons de prévision l'atténue sans la supprimer. Le modèle de Markov caché (section 1.6.6), qui modéliserait la persistance des régimes, n'est pas utilisé : le noyau du code ne traite que des émissions scalaires et les séries sont trouées (prolongement). (4) *Absence de vérité terrain* : un « régime de tension » est une composante du mélange, non un état observé ; seule la confrontation qualitative aux bulletins le relie à la réalité. (5) *Prix nominaux* : l'écart au niveau des douze derniers mois retire la dérive lente, mais pas un choc d'inflation générale. (6) *Accès à la nourriture* : FEWS NET souligne qu'en 2026 des prix bas ne signifient pas une amélioration de l'accès dans les zones de conflit ; l'indicateur décrit les prix, non l'insécurité alimentaire elle-même.

3.4 Comparaison pLSA contre LDA

Le corpus et le protocole sont décrits à la section 2.4.5.

Tableau « texte_resume » à générer : exécuter le code, puis `python tex_tables.py`.

Tableau « decisions_texte » à générer : exécuter le code, puis `python tex_tables.py`.

Deux réserves s'appliquent à cette lecture. D'abord, la LDA du code lisse β (pseudo-compte calibré) et le pLSA ne le fait pas : une partie de l'écart aux petits effectifs peut venir des probabilités nulles du pLSA (colonne « Mots nuls ») et non seulement du prior sur θ_d. Ensuite, les exécutions non convergées au plafond d'étapes M sont signalées, et les résultats dépendent du prétraitement et du nombre de thèmes ($K = 4$, égal au nombre de groupes).

3.5 Bilan des hypothèses de recherche

Tableau « bilan_recherche » à générer : exécuter le code, puis `python tex_tables.py`.

Le verdict de chaque décision suit la règle déclarée à la section 2.5.3 (conforme, contraire, non tranché). La lecture d'ensemble ne désigne pas un meilleur algorithme : elle décrit des déplacements. Le VB transfère la sélection de K vers le choix de $K_{\max}$, des hyperparamètres et du seuil d'activité ; il fournit une incertitude approchée dont la couverture est mesurée ; il coûte plus par ajustement que l'EM, ce qui n'établit pas un coût plus élevé que le pipeline EM-BIC en temps total. Les décisions d'équivalence (RH1) indiquent dans quelles conditions les deux algorithmes sont de qualité comparable. La comparaison à $K = 6$ imposé est défavorable à l'EM par construction et ne sert que d'illustration du mécanisme d'élagage.

Le tableau 3.1 remplace les anciennes listes d'avantages et d'inconvénients par une grille « axe × preuve » : chaque ligne renvoie à une expérience, à un théorème, ou porte la mention « non testé ».

Tableau 3.1: Grille « axe × preuve » : chaque affirmation renvoie à un théorème, une expérience ou la mention « non testé »

Axe	Affirmation	Preuve (décision lue dans le fichier de résultats)	Niveau de preuve	Section
Sélection de K	VB comparé à EM-BIC sur des groupes séparés	*non encore généré*	non testé (résultats non générés)	§2.3.16
Composante minoritaire	Le VB perd la composante à 5 % à une fréquence différente de EM-BIC	*non encore généré*	non testé (résultats non générés)	§2.3.16
Sous-estimation de K	Avec $K_{\max} = K$ choisi $< K$ vrai, le VB ne corrige pas l'erreur	*non encore généré*	non testé (résultats non générés)	§2.3.16
Queues épaisses	Composantes de Student : VB comparé à EM-BIC	*non encore généré*	non testé (résultats non générés)	§2.3.17
Dimension	Dimension croissante $D \in \{2, 5, 10, 20\}$	*non encore généré*	non testé (résultats non générés)	§2.3.17
Singularités, petit N	Taux d'ajustements dégénérés selon N	*non encore généré*	non testé (résultats non générés)	§2.3.17
Valeurs aberrantes	Proportion et amplitude variées	*non encore généré*	non testé (résultats non générés)	§2.3.18
Sélection de K (prix)	Erreur sur K du VB et de EM-BIC (semi-synthétique)	*non encore généré*	non testé (résultats non générés)	§3.1
Qualité prédictive (prix)	Log-vraisemblance de test 2024-2026, VB contre EM-BIC	*non encore généré*	non testé (résultats non générés)	§3.1

Axe	**Affirmation**	**Preuve (décision lue dans le fichier de résultats)**	**Niveau de preuve**	**Section**
Singularités, petit N (prix)	VB contre EM-Kmax, $N \leq 120$	*non encore généré*	non testé (résultats non générés)	§3.1
Coût de calcul	Pipeline EM-BIC contre un VB, temps total	*non encore généré*	non testé (résultats non générés)	§2.3.20
Sensibilité aux priors	Variance de $\hat{K}$ due aux priors contre due à l'initialisation	*non encore généré*	non testé (résultats non générés)	§2.3.19
Incertitude	Couverture des intervalles à 90 % (VB et bootstrap EM)	*non encore généré*	non testé (résultats non générés)	§2.3.15
Prévision (prix)	Log-score des mélanges et de la gaussienne, 2024-2026 (Diebold-Mariano par mois, Holm)	*non encore généré*	non testé (résultats non générés)	§3.1
Surapprentissage (texte)	Écart test/apprentissage de pLSA contre LDA	*non encore généré*	non testé (résultats non générés)	§3.2
Seuil d'élagage	Seuil de α_0 transféré au champ moyen	*non encore généré*	non testé (résultats non générés)	§1.7.4, §2.3.14
Seuil d'activité	Le nombre de composantes actives dépend du seuil	*non encore généré*	non testé (résultats non générés)	§2.3.19
Dépendance à $K_{\max}$	Résultat de l'élagage dépendant de $K_{\max}$ (Iris)	*non encore généré*	non testé (résultats non générés)	§2.3.11
Initialisation	Composantes actives selon l'initialisation	*non encore généré*	non testé (résultats non générés)	§2.3.9
Biais d'approximation	Variance sous-estimée par le champ moyen	référence théorique	théorème	§1.5.4 (Bishop 2006) ; couverture : HP6
Monotonie du critère	Croissance de la log-vraisemblance (EM) et de l'ELBO (VB, covariance pleine)	référence théorique	théorème	§1.6.3, §1.7.6 ; vérification numérique (validation)
Convergence de l'EM pour le GMM	Le théorème de Wu (1983) ne s'applique pas tel quel (vraisemblance non bornée)	référence théorique	théorème	§1.6.3 ; régularisation εI
Consistance de la sélection de K	Garantie de consistance du champ moyen pour K	aucune	non testé	§1.7.9
Taux de l'EM en sur-spécification	Précision $(d/n)^{1/4}$ dans le cas équilibré (Dwivedi et al., 2020)	aucune	non testé	§1.6.3.d
Cible de l'EM en sous-spécification	Convergence vers la projection de Kullback-Leibler (Dwivedi et al., 2018)	aucune	non testé	§1.6.3.d
Consistance des paramètres du VB	Moyenne variationnelle consistante, covariance trop petite (Wang et Titterington, cités)	aucune	non testé	§1.7.9
Optima locaux de l'ELBO	Fréquence des optima locaux du VB	voir l'annexe	mesuré au calibrage	annexe (calibrage n_init)

Axe	Affirmation	Preuve (décision lue dans le fichier de résultats)	Niveau de preuve	Section
Irréversibilité de l'élagage	Une composante éteinte ne revient pas	aucune	non testé	§1.7.4
Double usage des données	Effet des priors empiriques sur l'ELBO et les intervalles	aucune	non testé	§2.3.1
Vitesse de VAE, flux normalisants, gradient naturel	Affirmations de vitesse des variantes avancées	aucune	non testé	§1.7.7
Vision, bio-informatique, recommandation	Choix d'algorithme par domaine	aucune	non testé	revue

Niveaux : théorème ; expérience répliquée (nombre de réplications fixé par le calcul de puissance) ; expérience unique ; non testé. Aucune ligne n'autorise à parler de supériorité d'un algorithme. Cette synthèse met en évidence que le choix entre les deux algorithmes ne doit pas être envisagé comme un choix entre une méthode « meilleure » et une méthode « moins bonne » dans l'absolu, mais comme un arbitrage dépendant du contexte applicatif arbitrage que précisent les recommandations de la section 3.7. Aucune ligne de la grille n'autorise à parler de supériorité.

3.6 Portée : domaines non testés

3.6.1 Vision et bio-informatique (revue de la littérature)

Ces deux domaines ne font l'objet d'aucune expérience dans ce mémoire. Ce qui suit est une revue : toute affirmation sans source est marquée « non testé ».

Vision par ordinateur. Les mélanges gaussiens servent à la segmentation d'images (chaque pixel est décrit par sa couleur ou une texture, $D = 3$ ou davantage) ; le nombre N de pixels peut dépasser le million, ce qui replace la scalabilité au centre du choix de l'algorithme. Dans l'algorithme de soustraction de fond de Stauffer et Grimson (1999), chaque pixel est modélisé par un petit mélange de gaussiennes mis à jour de façon incrémentale par une heuristique inspirée de l'EM online (et non exactement l'EM online) : le taux d'apprentissage ρ est fixé et les composantes de poids élevé et de faible variance sont classées comme fond. Cette règle utilise l'interprétation des poids comme fréquences d'occurrence (section 1.6.2.c). L'affirmation que l'EM classique convient mieux au temps réel et l'EM variationnel à la segmentation hors ligne n'a pas été testée ici : *non testé*.

Bio-informatique. Les modèles de mélange servent à identifier des sous-populations dans des données d'expression génique (cellule unique), pour lesquelles le nombre de sous-populations est souvent l'objet de l'étude. La dimension (D de l'ordre du millier de gènes) rend la covariance pleine impraticable pour les deux algorithmes

: le coût est en KD^3 et les effectifs $N_k < D + 1$ conduisent à des covariances singulières (section 2.8). En pratique la dimension est réduite au préalable ou les covariances sont contraintes (diagonales). Les mélanges infinis (processus de Dirichlet, Rasmussen, 2000) constituent un mécanisme différent du VB à $K_{\max}$ fini étudié ici. L'affirmation selon laquelle l'EM variationnel serait « largement préféré » dans ce domaine n'est ni sourcée ni testée ici : *non testé*. Les modèles de Markov cachés ajustés par Baum-Welch (section 1.6.6) restent une référence pour l'annotation de séquences, sans que ce mémoire en mesure les délais pour des génomes entiers : *non testé*.

3.6.2 Systèmes de recommandation (revue de la littérature)

Dans les systèmes de recommandation, la factorisation matricielle probabiliste place des priors gaussiens sur les vecteurs latents d'utilisateurs et d'articles, et l'inférence variationnelle donne une loi a posteriori exploitable pour l'exploration (échantillonnage de Thompson). L'intérêt de cette incertitude pour le démarrage à froid est une hypothèse de la littérature : *non testé* ici, aucune expérience de recommandation n'ayant été conduite.

Domaine	**Usage décrit**	**Statut de la preuve dans ce mémoire**
Prix alimentaires (cas pratique)	Régimes de tension des prix, probabilité d'alerte	Expériences répliquées et une période de test (section 3.3)
Texte	Modèles de thèmes (pLSA, LDA)	Expérience répliquée sur corpus réel
Vision	Segmentation, soustraction de fond	Revue : non testé
Bio-informatique	Sous-populations cellulaires, annotation de séquences	Revue : non testé
Recommandation	Factorisation matricielle probabiliste, démarrage à froid	Revue : non testé

Tableau 3.2: Statut de la preuve par domaine d'application

3.7 Recommandations pratiques

À l'issue de l'ensemble des analyses théoriques, expérimentales et applicatives conduites dans ce mémoire, cette section propose une synthèse opérationnelle, destinée à guider le choix entre EM classique et EM variationnel face à une situation pratique concrète.

Tableau 3.3: Guide de décision avec niveau de preuve (aucune ligne n'est une recommandation absolue)

Situation	Recommandation prudente	Niveau de preuve
K connu avec confiance	EM classique ou VB peuvent convenir ; confirmer l'équivalence	expérience répliquée (HS1, HS3)
K inconnu	EM-BIC/ICL ou VB : choix selon le coût total et le besoin d'incertitude	expérience répliquée (HP1, HP4)
Besoin d'une incertitude en aval (alerte)	VB (approchée) ; vérifier la couverture ; bootstrap pour l'EM	expérience répliquée (HP6)
Petit effectif	Comparer les taux de dégénérescence ; régulariser l'EM	expérience répliquée (HS6, HP3)
Grande dimension ($D > 20$)	Non testé	non testé
Très grand N	EM online ou SVI pour les deux familles	non testé (références)
Sensibilité aux priors acceptable	VB avec priors fixés avant les données ; plan factoriel	expérience répliquée, descriptive (HP5, S9)

Ce guide ne recommande pas un algorithme dans l'absolu : chaque ligne indique le niveau de preuve disponible (théorème, expérience répliquée, expérience unique ou non testé). Il est complété par trois bonnes pratiques indépendantes de l'algorithme. Premièrement, standardiser les données avant l'ajustement, les deux algorithmes étant sensibles à l'échelle relative des dimensions. Deuxièmement, multiplier les initialisations (`n_init` > 1) pour l'EM comme pour le VB. Troisièmement, utiliser un critère d'arrêt commun lorsque l'on compare des nombres d'itérations ou des temps, et rapporter les exécutions non convergées.

3.8 Conclusion du chapitre 3

Ce chapitre a présenté les résultats dans l'ordre de la preuve : illustrations exploratoires du mécanisme d'élagage, scénarios confirmatoires répliqués, cas pratique sur un problème réel du Cameroun et comparaison pLSA contre LDA. Le bilan des hypothèses de recherche (tableau **??**) et la grille « axe × preuve » (tableau 3.1) rattachent chaque conclusion à une décision lue dans un fichier de résultats, à un théorème ou à la mention « non testé ». Les conditions de validité de ces conclusions sont celles de la section 2.8 : l'élagage dépend des priors, de $K_{\max}$ et du seuil d'activité ; les variantes de covariance non pleines utilisent un critère approché ; le cas des prix repose sur une période de test qui diffère de l'apprentissage et sur des régimes reliés à la réalité par une confrontation qualitative aux bulletins d'alerte.

Conclusion générale

Ce mémoire a comparé, sur trois niveaux d'inférence (EM classique, EM variationnel à θ ponctuel, Bayes variationnel à θ aléatoire), l'EM classique et l'EM variationnel pour les modèles de mélange, en reliant chaque avantage et chaque inconvénient à une preuve : un théorème, une expérience répliquée, une expérience unique, ou la mention « non testé » (grille du tableau 3.1).

Synthèse des contributions

Ce travail apporte les éléments suivants, sans prétention de nouveauté théorique :

- une présentation unifiée des fondements communs (inégalité de Jensen, ELBO, divergence de Kullback-Leibler) et des mises à jour de chaque algorithme, avec une distinction explicite de trois niveaux d'inférence ;
- une reformulation didactique et rigoureuse (passage à la limite d'une famille de lois) de l'équivalence de Neal et Hinton (1998) entre EM classique et EM variationnel (section 2.1.2) ; il ne s'agit pas d'une contribution originale ;
- un comparateur MAP-EM, qui isole l'effet du prior de celui de l'inférence bayésienne complète ;
- un protocole de comparaison à critère d'arrêt commun, avec baseline EM-BIC et EM-ICL, tests appariés, tests d'équivalence et correction de Holm, appliqué à dix scénarios synthétiques (S1 à S10) et à un jeu semi-synthétique ;
- un cas pratique sur un problème réel du Cameroun, l'alerte sur les prix des denrées de base (données publiques du PAM, 2021-2026), avec hypothèses déclarées avant tout ajustement, validation temporelle, probabilité d'alerte munie d'un intervalle et comparaisons de prévision par le test de Diebold–Mariano, ainsi qu'une comparaison pLSA contre LDA ;
- une implémentation en PyTorch de l'ensemble, avec tests unitaires, dont le code, les graines et les tableaux sont archivés pour que chaque tableau soit regénéré par le code.

Limites du travail

Ce travail présente des limites, discutées à la section 2.8. (1) Les scénarios synthétiques reposent sur des mélanges gaussiens (ou de Student) simples ; leur dimension reste modeste (jusqu'à $D = 20$ pour la scalabilité, $D = 3$ pour le cas pratique). (2) Les priors empiriques réutilisent les données (Bayes empirique) ; un jeu de priors fixés avant les données est comparé dans le plan factoriel, mais n'épuise pas la question. (3) Les variantes tied, diag et sphérique du VB n'ont pas d'ELBO dérivé : leur critère est une approximation. (4) Le seuil théorique $d/2$ pour α_0 concerne le posterior exact : son transfert au champ moyen est testé, non démontré. (5) L'irréversibilité de l'élagage, la dépendance à $K_{\max}$ et l'absence de garantie de consistance restent « non testées » ou partiellement testées. (6) Le cas des prix alimentaires porte sur trois denrées, des séries courtes et trouées, une période de test (2024-2026) dont la distribution diffère de l'apprentissage et qui ne couvre que trois régions ; les observations d'un même marché ou d'un même mois ne sont pas indépendantes ; les modèles ne sont pas réestimés en fenêtre glissante ; et le « régime de tension » n'a pas de vérité terrain. (7) La comparaison pLSA contre LDA porte sur un corpus de quatre groupes, la LDA du code étant un EM variationnel à β ponctuel et non un VB complet. (8) Les temps de calcul dépendent d'une machine et d'une implémentation (annexe D). (9) Vision, bio-informatique et recommandation ne sont pas testées.

Perspectives

Plusieurs prolongements se dégagent. Sur le plan expérimental : étendre la comparaison à des dimensions plus grandes avec des covariances structurées, évaluer l'irréversibilité de l'élagage par des initialisations adverses, réestimer les modèles de prix en fenêtre glissante et modéliser la persistance des régimes par un modèle de Markov caché à émissions multivariées tolérant les mois manquants. Sur le plan méthodologique : dériver l'ELBO des variantes de covariance, comparer le champ moyen à des familles variationnelles plus riches (flux normalisants) ou à des divergences autres que la KL inverse, et confronter les seuils de type $d/2$ à un posterior approché par MCMC. Sur le plan applicatif : étendre le cas des prix aux autres pays de la CEMAC et du bassin du lac Tchad couverts par la base du PAM (une généralisation à tester, non un acquis), et confronter les alertes aux phases du Cadre Harmonisé avec les analystes de la sécurité alimentaire.

En définitive, le VB ne « bat » pas l'EM : il déplace la sélection de K vers le choix des hyperparamètres, apporte une incertitude approchée, au prix d'un coût et d'une sensibilité aux priors. Chaque terme de cette phrase est soutenu, ou explicitement non soutenu, par une ligne de la grille du tableau 3.1.

Bibliographie

Références numérotées dans l'ordre alphabétique des premiers auteurs (format IEEE).

[1] H. Attias, « A variational Bayesian framework for graphical models », in Advances in Neural Information Processing Systems 12 (NIPS 1999), MIT Press, 2000, p. 209-215.

[2] S. Balakrishnan, M. J. Wainwright et B. Yu, « Statistical guarantees for the EM algorithm: From population to sample-based analysis », The Annals of Statistics, vol. 45, n° 1, p. 77-120, 2017 (cité d'après Dwivedi et al., 2020 ; non consulté).

[3] L. E. Baum, T. Petrie, G. Soules et N. Weiss, « A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains », The Annals of Mathematical Statistics, vol. 41, n° 1, p. 164-171, 1970.

[4] J. Bergstra et Y. Bengio, « Random search for hyper-parameter optimization », Journal of Machine Learning Research, vol. 13, p. 281-305, 2012.

[5] C. Biernacki, G. Celeux et G. Govaert, « Assessing a mixture model for clustering with the integrated completed likelihood », IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 22, n° 7, p. 719-725, 2000.

[6] C. Biernacki, G. Celeux et G. Govaert, « Choosing starting values for the EM algorithm for getting the highest likelihood in multivariate Gaussian mixture models », Computational Statistics & Data Analysis, vol. 41, n° 3-4, p. 561-575, 2003.

[7] C. M. Bishop, Pattern Recognition and Machine Learning. New York : Springer, 2006.

[8] D. M. Blei et M. I. Jordan, « Variational inference for Dirichlet process mixtures », Bayesian Analysis, vol. 1, n° 1, p. 121-143, 2006.

[9] D. M. Blei, A. Kucukelbir et J. D. McAuliffe, « Variational inference: A review for statisticians », Journal of the American Statistical Association, vol. 112, n° 518, p. 859-877, 2017.

[10] D. M. Blei, A. Y. Ng et M. I. Jordan, « Latent Dirichlet Allocation », Journal of Machine Learning Research, vol. 3, p. 993-1022, 2003.

[11] R. A. Boyles, « On the convergence of the EM algorithm », Journal of the Royal Statistical Society: Series B, vol. 45, n° 1, p. 47-50, 1983.

[12] O. Cappé et E. Moulines, « On-line expectation-maximization algorithm for latent data models », Journal of the Royal Statistical Society: Series B, vol. 71, n° 3, p. 593-613, 2009.

[13] G. Celeux et J. Diebolt, « The SEM algorithm: A probabilistic teacher algorithm derived from the EM algorithm for the mixture problem », Computational Statistics Quarterly, vol. 2, n° 1, p. 73-82, 1985.

[14] J. H. Chen, « Optimal rate of convergence for finite mixture models », The Annals of Statistics, vol. 23, n° 1, p. 221-233, 1995 (cité d'après Dwivedi et al., 2020 ; non consulté).

[15] A. Corduneanu et C. M. Bishop, « Variational Bayesian model selection for mixture distributions », in Artificial Intelligence and Statistics 2001 (AISTATS), Morgan Kaufmann, 2001, p. 27-34.

[16] A. P. Dempster, N. M. Laird et D. B. Rubin, « Maximum likelihood from incomplete data via the EM algorithm », Journal of the Royal Statistical Society: Series B, vol. 39, n° 1, p. 1-38, 1977.

[17] F. X. Diebold et R. S. Mariano, « Comparing predictive accuracy », Journal of Business & Economic Statistics, vol. 13, n° 3, p. 253-263, 1995.

[18] R. Dwivedi, N. Ho, K. Khamaru, M. J. Wainwright et M. I. Jordan, « Theoretical guarantees for the EM algorithm when applied to mis-specified Gaussian mixture models », in Advances in Neural Information Processing Systems 31 (NeurIPS 2018), 2018.

[19] R. Dwivedi, N. Ho, K. Khamaru, M. J. Wainwright, M. I. Jordan et B. Yu, « Singularity, misspecification and the convergence rate of EM », The Annals of Statistics, vol. 48, n° 6, p. 3161-3182, 2020.

[20] FAO GIEWS, « Country Brief : Cameroon », Système mondial d'information et d'alerte rapide sur l'alimentation et l'agriculture, FAO, 2026. [En ligne]. Disponible : https://www.fao.org/giews/countrybrief/country/CMR/pdf/CMR.pdf

[21] FEWS NET, « Cameroon : Area-level Crisis (IPC Phase 3) will persist in conflict areas during harvest », Food Security Outlook Update, avril 2026, et « Conflict and high food prices sustain Crisis (IPC Phase 3) outcomes despite harvest », Food Security Outlook, juin 2026. [En ligne]. Disponible : https://fews.net/west-africa/cameroon

[22] R. A. Fisher, « The use of multiple measurements in taxonomic problems », Annals of Eugenics, vol. 7, n° 2, p. 179-188, 1936.

[23] S. Frühwirth-Schnatter, Finite Mixture and Markov Switching Models. New York : Springer, 2006.

[24] H. O. Hartley, « Maximum likelihood estimation from incomplete data », Biometrics, vol. 14, n° 2, p. 174-194, 1958.

[25] D. Harvey, S. Leybourne et P. Newbold, « Testing the equality of prediction mean squared errors », International Journal of Forecasting, vol. 13, n° 2, p. 281-291, 1997.

[26] G. E. Hinton et D. van Camp, « Keeping the neural networks simple by minimizing the description length of the weights », in Proceedings of the 6th Annual Conference on Computational Learning Theory (COLT), 1993, p. 5-13.

[27] J. L. Hodges Jr. et E. L. Lehmann, « Estimates of location based on rank tests

», Annals of Mathematical Statistics, vol. 34, n° 2, p. 598-611, 1963.

[28] M. D. Hoffman, D. M. Blei, C. Wang et J. Paisley, « Stochastic variational inference », Journal of Machine Learning Research, vol. 14, n° 1, p. 1303-1347, 2013.

[29] T. Hofmann, « Probabilistic latent semantic indexing », in Proceedings of the 22nd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, 1999, p. 50-57.

[30] S. Holm, « A simple sequentially rejective multiple test procedure », Scandinavian Journal of Statistics, vol. 6, n° 2, p. 65-70, 1979.

[31] K. Jamieson et A. Talwalkar, « Non-stochastic best arm identification and hyperparameter optimization », in Proceedings of the 19th International Conference on Artificial Intelligence and Statistics (AISTATS), PMLR 51, p. 240-248, 2016.

[32] M. I. Jordan, Z. Ghahramani, T. S. Jaakkola et L. K. Saul, « An introduction to variational methods for graphical models », Machine Learning, vol. 37, n° 2, p. 183-233, 1999.

[33] D. P. Kingma et M. Welling, « Auto-encoding variational Bayes », in Proceedings of the 2nd International Conference on Learning Representations (ICLR), 2014 ; arXiv:1312.6114.

[34] D. Lakens, « Equivalence tests: A practical primer for t tests, correlations, and meta-analyses », Social Psychological and Personality Science, vol. 8, n° 4, p. 355-362, 2017.

[35] D. Lakens, A. M. Scheel et P. M. Isager, « Equivalence testing for psychological research: A tutorial », Advances in Methods and Practices in Psychological Science, vol. 1, n° 2, p. 259-269, 2018.

[36] K. Lang, « NewsWeeder: Learning to filter netnews », in Proceedings of the 12th International Conference on Machine Learning, 1995, p. 331-339.

[37] T. A. Louis, « Finding the observed information matrix when using the EM algorithm », Journal of the Royal Statistical Society: Series B, vol. 44, n° 2, p. 226-233, 1982.

[38] G. J. McLachlan et D. Peel, Finite Mixture Models. New York : Wiley, 2000.

[39] G. J. McLachlan et T. Krishnan, The EM Algorithm and Extensions, 2e éd. Hoboken : Wiley, 2008.

[40] X.-L. Meng et D. B. Rubin, « Using EM to obtain asymptotic variance-covariance matrices: The SEM algorithm », Journal of the American Statistical Association, vol. 86, n° 416, p. 899-909, 1991.

[41] R. M. Neal et G. E. Hinton, « A view of the EM algorithm that justifies incremental, sparse, and other variants », in Learning in Graphical Models, M. I. Jordan, Éd. Dordrecht : Springer, 1998, p. 355-368.

[42] T. Orchard et M. A. Woodbury, « A missing information principle: Theory and applications », in Proceedings of the 6th Berkeley Symposium on Mathematical

Statistics and Probability, vol. 1, 1972, p. 697-715.

[43] A. Paszke et al., « PyTorch: An imperative style, high-performance deep learning library », in Advances in Neural Information Processing Systems 32 (NeurIPS 2019), 2019, p. 8024-8035.

[44] C. Peterson et J. R. Anderson, « A mean field theory learning algorithm for neural networks », Complex Systems, vol. 1, n° 5, p. 995-1019, 1987.

[45] Programme alimentaire mondial (PAM), « Cameroon – Food Prices », Humanitarian Data Exchange (HDX), données de janvier 2005 à août 2026, version du 4 octobre 2026, licence CC BY-IGO. [En ligne]. Disponible : https://data.humdata.org/dataset/wfp-food-prices-for-cameroon

[46] Programme alimentaire mondial (PAM), « Technical Guidance Note : Calculation and Use of the Alert for Price Spikes (ALPS) Indicator », Rome, avril 2014. [En ligne]. Disponible : https://reliefweb.int/report/world/technical-guidance-note-calculation-and-use-alert-price-spikes-alps-indicator-april

[47] Programme alimentaire mondial (PAM), « WFP Cameroon : Monthly Market Monitoring Bulletin, August 2023 », ReliefWeb, 2023. [En ligne]. Disponible : https://reliefweb.int/report/cameroon/wfp-cameroon-monthly-market-monitoring-bulletin-august-2023

[48] C. E. Rasmussen, « The infinite Gaussian mixture model », in Advances in Neural Information Processing Systems 12 (NIPS 1999), MIT Press, 2000, p. 554-560.

[49] D. J. Rezende et S. Mohamed, « Variational inference with normalizing flows », in Proceedings of the 32nd International Conference on Machine Learning (ICML), 2015, p. 1530-1538.

[50] D. R. Roberts et al., « Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure », Ecography, vol. 40, n° 8, p. 913-929, 2017.

[51] J. Rousseau et K. Mengersen, « Asymptotic behaviour of the posterior distribution in overfitted mixture models », Journal of the Royal Statistical Society: Series B, vol. 73, n° 5, p. 689-710, 2011.

[52] M. Sato et S. Ishii, « On-line EM algorithm for the normalized Gaussian network », Neural Computation, vol. 12, n° 2, p. 407-432, 2000.

[53] D. J. Schuirmann, « A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability », Journal of Pharmacokinetics and Biopharmaceutics, vol. 15, n° 6, p. 657-680, 1987.

[54] C. Stauffer et W. E. L. Grimson, « Adaptive background mixture models for real-time tracking », in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), vol. 2, 1999, p. 246-252.

[55] D. Steinley, « Properties of the Hubert-Arabie adjusted Rand index », Psychological Methods, vol. 9, n° 3, p. 386-396, 2004.

[56] Y. Wang et D. M. Blei, « Frequentist consistency of variational Bayes », Journal of the American Statistical Association, vol. 114, p. 1147-1161, 2019 (cité d'après Zhang et Gao, 2020 ; non consulté).

[57] B. Wang et D. M. Titterington, « Convergence properties of a general algorithm for calculating variational Bayesian estimates for a normal mixture model », Bayesian Analysis, vol. 1, p. 625-650, 2006 (cité d'après Blei et al., 2017 ; non consulté).

[58] B. Wang et D. M. Titterington, « Inadequacy of interval estimates corresponding to variational Bayesian approximations », in Proceedings of the 10th International Workshop on Artificial Intelligence and Statistics (AISTATS), 2005 (cité d'après Blei et al., 2017 ; non consulté).

[59] C. F. J. Wu, « On the convergence properties of the EM algorithm », The Annals of Statistics, vol. 11, n° 1, p. 95-103, 1983.

[60] F. Zhang et C. Gao, « Convergence rates of variational posterior distributions », The Annals of Statistics, vol. 48, n° 4, p. 2180-2207, 2020.

Annexes

Annexe A : Code source

Les résultats de ce mémoire sont produits par les fichiers Python suivants : `algorithmes.py` (EM classique, MAP-EM, EM variationnel, ELBO, variantes, Baum-Welch, LDA, pLSA, métriques), `risque.py` (loi prédictive du VB, test de Diebold–Mariano), `statistique.py` (Wilcoxon exact, TOST, Holm, bootstrap), `comparaison.py` (protocole des bras, statistiques de comparaison), `hypotheses.py` (hypothèses déclarées), `parametres.py` et `calibrage.py` (registre et calibrage des paramètres), `scenarios.py` (scénarios synthétiques S1 à S10), `etape_validation.py`, `etape_illustrations.py` et `etape_chronometrage.py` (validations du chapitre 1 et expériences du chapitre 2), `donnees.py` et `etape_prix.py` (cas pratique des prix alimentaires), `etape_texte.py` (comparaison pLSA contre LDA), `figures.py` et `tex_tables.py` (figures et tableaux LaTeX produits depuis les résultats), enfin `run.py`, `persistance.py` et `superviseur.py` (orchestration reprenable après interruption). Le dépôt complet, avec son jeu de tests (`tests/`), est publié sur GitHub (section A.1) ; l'étiquette Git et le DOI Zenodo de la version définitive restent à créer au moment de l'archivage. Le tableau suivant indique, pour chaque fonction de la bibliothèque, la section et l'équation correspondantes.

Fonction	**Section**	**Équations**
em_classique	1.6	(1.15), (1.16), (1.18)
em_stochastique, em_online	1.6.5	Celeux et Diebolt, Cappé et Moulines
forward_backward, baum_welch	1.6.6	forward et backward, tableau 1.4
em_variationnel	1.7	(1.26) à (1.30)
elbo_gmm_bayesien	1.7.6	(1.31)
svi_gmm	1.7.7	Hoffman et al.
lda_variationnel	3.1.1	(3.1), (3.2)
bic, aic	2.2.3	(2.4), (2.5)

Tableau 3.4: Correspondance entre fonctions du code, sections et équations

A.1 Accès au code complet

Le code complet (environ 1 400 lignes pour `algorithmes.py`, 250 pour `risque.py`, plus les scripts d'expériences et les tests) n'est pas reproduit ici. Il est disponible dans le dépôt public `github.com/Kanaicare8/em-classique-vs-variationnel`. Chaque QR code ci-dessous ouvre le fichier correspondant sur la branche `main`.

Dépôt complet
em-classique-vs-variationnel

Algorithmes
algorithmes.py

Gestion du risque
risque.py

Protocole « 5 EM + VB »
comparaison.py

Scénarios S1 à S10
scenarios.py

Lancement des étapes
run.py

A.2 Extraits commentés

Les trois extraits suivants sont copiés sans modification du code exécuté. Ils montrent la traduction directe des équations en calcul tensoriel : toutes les relances (dimension `B`) sont traitées en un seul lot, et les responsabilités sont normalisées en log-espace (équation 1.18).

Étape E de l'EM classique (`algorithmes.py`, équation 1.15).

```
def _etape_e_lot(dp: "_Prep", pi: Tensor, mu: Tensor, cov: Tensor):
    """Étape E (1.15) en log-espace pour toutes les relances : (r (B,N,K), log p(x_n | theta) (B,N),
    ↪ ok (B,))."""
    B, K, D = mu.shape
    N = dp.N
    r = dp.X.new_empty(B, N, K)
    ln = dp.X.new_empty(B, N)
    ok = torch.empty(B, dtype=torch.bool)
    for sl in _tranches(B, K, N):
        lp, ok[sl] = _log_gauss_lot(dp, mu[sl], cov[sl])
        log_r = (torch.log(pi[sl] + 1e-300)[:, :, None] + lp).transpose(1, 2)    # (b,N,K)
        ln[sl] = torch.logsumexp(log_r, dim=2)
        r[sl] = torch.exp(log_r - ln[sl][..., None])
    return r, ln, ok
```

Étape E de l'EM variationnel (`algorithmes.py`, équations 1.27 et 1.30). Le terme $\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi(\sum_j \alpha_j)$ porte le mécanisme d'élagage de la section 1.7.4.

```
def _etape_e_var_lot(dp, P):
```

```
    """Étape E variationnelle, équation (1.27), avec la forme quadratique (1.30), en lot : (r (B,N,K),
    ↪  log_norm (B,N))."""
    N, D = dp.N, dp.D
    B, K = P["alpha"].shape
    Elogpi = torch.special.digamma(P["alpha"]) - torch.special.digamma(P["alpha"].sum(-1, keepdim=True
    ↪ ))
    Elogdet, Elam = _attendus_lot(P, D)
    r = dp.X.new_empty(B, N, K)
    ln = dp.X.new_empty(B, N)
    for sl in _tranches(B, K, N):
        quad = D / P["beta"][sl][..., None] + _forme_quadratique(dp, Elam[sl], P["m"][sl])
        log_rho = (Elogpi[sl][..., None] + 0.5 * Elogdet[sl][..., None] - 0.5 * D * LOG2PI - 0.5 *
    ↪ quad).transpose(1, 2)
        ln[sl] = torch.logsumexp(log_rho, dim=2)
        r[sl] = torch.exp(log_rho - ln[sl][..., None])
    return r, ln
```

Variable du cas pratique (`donnees.py`, écart causal du log-prix à son niveau des douze mois précédents, section 3.1.1).

```
def ecart(m, c, t):
    s = serie.get((m, c), {})
    if t not in s:
        return None
    passe = [s[u] for u in range(t - fenetre, t) if u in s]
    return s[t] - sum(passe) / len(passe) if len(passe) >= releves_min else None
```

Seuls les relevés antérieurs au mois t entrent dans le niveau de référence ; un test unitaire recalcule une observation à la main pour le vérifier.

A.3 Expériences et cas pratique

L'orchestrateur `run.py` enchaîne les étapes (calibrage, validation, illustrations, chronométrage, scénarios, prix, texte) ; chaque étape est une liste d'unités indépendantes, exécutées en parallèle et écrites atomiquement dans un magasin d'artefacts, de sorte qu'un calcul interrompu (erreur, coupure de courant, arrêt volontaire) reprend exactement où il s'était arrêté lorsqu'on relance la même commande ; `superviseur.py` relance automatiquement le calcul après un arrêt non voulu. L'option `-rapide` exécute une version réduite dans un magasin séparé. Les tableaux (`python tex_tables.py`) et les figures (`python run.py -figures`) sont produits depuis le magasin, sans recalcul ; aucun nombre des tableaux n'est saisi à la main.

A.4 Corpus et résultats de la comparaison pLSA contre LDA

Le corpus (sous-ensemble de 20 Newsgroups), le prétraitement et les résultats détaillés sont produits par `texte_plsa_lda.py` et écrits dans `resultats/texte_plsa_lda_brut.csv` (une ligne par modèle, par taille N et par réplication). La démonstration sur douze phrases des versions précédentes est supprimée.

Annexe B : Détail du calcul de l'ELBO pour le GMM bayésien

Cette annexe donne l'implémentation, en PyTorch, du calcul exact de l'ELBO de l'équation (1.31) (Bishop, 2006, éq. 10.70 à 10.77). Les sept termes sont : $\mathbb{E}[\log p(X|Z,\mu,\Lambda)]$, $\mathbb{E}[\log p(Z|\pi)]$, $\mathbb{E}[\log p(\pi)]$ et $\mathbb{E}[\log p(\mu,\Lambda)]$ (partie vraisemblance et priors), puis $-\mathbb{E}[\log q(Z)]$, $-\mathbb{E}[\log q(\pi)]$ et $-\mathbb{E}[\log q(\mu,\Lambda)]$ (entropies des facteurs variationnels). La fonction `_ln_B` calcule la constante de normalisation de la loi de Wishart ; `_attendus` calcule $\mathbb{E}[\log|\Lambda_k|]$ (équation 1.29).

```
def _ln_B(W, nu, D):
    """log de la constante de normalisation de la Wishart, ln B(W, nu)."""
    i = torch.arange(1, D + 1, dtype=torch.float64)
    lg = torch.lgamma((nu[..., None] + 1 - i) / 2).sum(-1)
    return -0.5 * nu * torch.logdet(W) - (0.5 * nu * D * LN2 + D * (D - 1) / 4 * LNPI + lg)

def _attendus(P, D):
    """E[ln|Lambda_k|] (1.29) et E[Lambda_k] pour chaque composante."""
    if P["cov_type"] in ("full", "tied"):
        i = torch.arange(1, D + 1, dtype=torch.float64)
        Elogdet = (torch.special.digamma((P["nu"][:, None] + 1 - i) / 2).sum(-1)
                   + D * LN2 + torch.logdet(P["W"]))
        Elam = P["nu"][:, None, None] * P["W"]
    else:
        psi = torch.special.digamma(P["a"]) - torch.log(P["b"])
        Elogdet = psi.sum(-1)
        Elam = torch.diag_embed(P["a"] / P["b"])
    return Elogdet, Elam

def elbo_gmm_bayesien(r, Nk, xbar, Sk, P, pr: PrioriNW):
    """
    ELBO du GMM bayésien (équation 1.31, détail dans Bishop 2006, éq. 10.70 à 10.77).
    Disponible pour la covariance pleine.
    """
    K, D = xbar.shape
    alpha, beta, m, nu, W = P["alpha"], P["beta"], P["m"], P["nu"], P["W"]
    Elogpi = torch.special.digamma(alpha) - torch.special.digamma(alpha.sum())
    Elogdet, _ = _attendus(P, D)
    dm = xbar - m
    t_trace = torch.einsum("kde,ked->k", Sk, W)
    t_quad = torch.einsum("kd,kde,ke->k", dm, W, dm)
    e_x = 0.5 * (Nk * (Elogdet - D / beta - nu * t_trace - nu * t_quad - D * LOG2PI)).sum()
    e_z = (Nk * Elogpi).sum()
    a0 = pr.alpha0
    ln_c0 = math.lgamma(K * a0) - K * math.lgamma(a0)
    e_pi = ln_c0 + (a0 - 1.0) * Elogpi.sum()
    W0 = torch.linalg.inv(pr.W0inv)
    d0 = m - pr.m0
    quad_m = torch.einsum("kd,kde,ke->k", d0, W, d0)
    nu0_t = torch.tensor(pr.nu0)
    lnB0 = _ln_B(W0, nu0_t, D)
    e_muLam = (0.5 * (D * math.log(pr.beta0 / (2 * math.pi)) + Elogdet - D * pr.beta0 / beta
                      - pr.beta0 * nu * quad_m).sum()
               + K * lnB0 + 0.5 * (pr.nu0 - D - 1) * Elogdet.sum()
```

```
            - 0.5 * (nu * torch.einsum("de,ked->k", pr.W0inv, W)).sum())
    q_z = torch.xlogy(r, r).sum()
    ln_c = torch.lgamma(alpha.sum()) - torch.lgamma(alpha).sum()
    q_pi = ((alpha - 1.0) * Elogpi).sum() + ln_c
    H = -_ln_B(W, nu, D) - 0.5 * (nu - D - 1) * Elogdet + 0.5 * nu * D
    q_muLam = (0.5 * Elogdet + 0.5 * D * torch.log(beta / (2 * math.pi)) - 0.5 * D - H).sum()
    return float(e_x + e_z + e_pi + e_muLam - q_z - q_pi - q_muLam)
```

Extrait de code : calcul de l'ELBO du GMM bayésien (équation 1.31)

Annexe C : Table de correspondance des symboles mathématiques

Le tableau ci-dessous rappelle la signification des principaux symboles mathématiques employés dans ce mémoire, à des fins de référence rapide.

Symbole	**Signification**
X = $\{x_1$,. . . ,x_N$\}$	Observations (données)
Z = $\{z_1$,. . . ,z_N$\}$	Variables latentes
θ	Paramètres du modèle
K	Nombre de composantes du mélange
π_k	Poids de la composante k
μ_k, Σ_k	Moyenne et covariance de la composante k
r_{ik}	Responsabilité de la composante k pour l'observation i
$\ell(\theta)$	Log-vraisemblance incomplète
Q(θ|θ^t)	Espérance de la log-vraisemblance complète
ELBO(q,θ)	Borne inférieure de l'évidence
KL[$q\|\|p$]	Divergence de Kullback-Leibler
q(θ,Z)	Distribution variationnelle
α_0, m_0, β_0, W_0, ν_0	Hyperparamètres des priors (Dirichlet, Normal-Wishart)
$\psi(\cdot)$	Fonction digamma
N_k	Nombre effectif de points assignés à la composante k

Annexe D : Environnement logiciel et reproductibilité

Toutes les expériences ont été exécutées sur une machine unique, avec l'environnement suivant, enregistré automatiquement dans le fichier `environnement.json` :

Composant	**Version utilisée**
Python	3.10.0
PyTorch (CPU, précision double)	2.4.1
Pandas	2.1.4
Plotly	6.8.0
Système et processeur	Windows 10 ; Intel Core i7-1165G7 à 2,8 GHz (4 coeurs, 8 fils logiques) ; un fil de calcul par processus (`OMP_NUM_THREADS=1`), jusqu'à 8 processus simultanés pour les scénarios et le cas des prix ; le chronométrage s'exécute toujours dans un seul processus. Les temps de ces calculs parallèles sont mesurés sous charge : ils se comparent entre bras d'un même run, non entre runs. Le tableau de scalabilité (section 2.3.6) a été mesuré avec, pour seule autre activité, un téléchargement de fichiers.

Les graines suivantes sont fixées explicitement : 42 pour le jeu de référence, 1000 à 1029 pour la réplication de la section 2.3.13, 7 pour les valeurs aberrantes, 0 à 19 pour la robustesse à l'initialisation (section 2.3.9). Chaque ajustement utilise la graine du jeu de données augmentée de l'indice de relance. Avec ces graines et la précision double, deux exécutions successives donnent des résultats identiques ; des différences minimes peuvent apparaître avec une autre version de PyTorch ou un autre processeur, en raison de l'ordre des opérations en virgule flottante. Les graines des scénarios, du cas des prix et de la comparaison de texte sont dérivées de façon déterministe du rôle de chaque tirage (empreinte SHA-256 du rôle, fonction `persistance.graine`), ce qui donne une graine indépendante par tirage. La machine d'exécution (modèle de processeur, nombre de coeurs et de fils effectifs, mémoire) est enregistrée dans `environnement.json`, et les versions exactes des bibliothèques dans `requirements.txt` (verrouillé par `pip freeze`) : les temps de calcul ne sont comparables qu'à ces conditions.

Le protocole est entièrement scripté : `python run.py` réalise les expériences, écrit les tableaux (fichiers `.csv`) et les figures (`.html` interactifs et `.png`) ; la marche à suivre figure dans `LANCEMENT.md`.

Annexe F : Registre des paramètres

Chaque paramètre utilisé par le code, avec sa valeur, son statut, sa justification, ses références et l'étude de calibrage qui le fixe (section 2.6).

Tableau 3.5: Registre des paramètres

Paramètre	Valeur	Statut	Justification	Références	Calibrage
tol_rel	0,000001	benchmark	Plus grande tolérance relative pour laquelle les résultats (critère final, $\hat{K}$, ARI) ne diffèrent pas de ceux obtenus avec une tolérance 100 fois plus stricte, au-delà de l'écart observé entre deux relances convergeant vers le même optimum. Grille 1e-3 à 1e-10 sur les jeux du protocole.		tolerance
n_iter_max	500	benchmark	Plafond d'étapes M tel que, avec tol_rel calibrée, moins de 1 % des ajustements du pilote l'atteignent ; les ajustements plafonnés sont marqués non convergés.		tolerance
reg_covariance	0,000001	recherche	Régularisation + reg I des covariances (EM, MAP-EM). Choisie sur une grille logarithmique 0 et 1e-10 à 1e-1 en maximisant la log-vraisemblance moyenne hors échantillon (validation croisée sur les jeux d'apprentissage).		regularisation
kmeans_n_iter_max	100	benchmark	Plafond des itérations de Lloyd pour l'initialisation : la part des initialisations qui l'atteignent est mesurée sur les jeux du protocole ; le plafond est relevé (par pas de 100) tant qu'elle dépasse 1 %.		kmeans
n_init	'synthetique': 10, 'iris': 10, 'prix': 10, 'texte': 10	benchmark	Par famille de données : nombre de relances tel que la probabilité qu'au moins une relance atteigne le meilleur optimum (à 10 fois la tolérance d'arrêt près) soit au moins 0,99, soit ceil(ln 0,01 / ln(1 - p)) où p est estimé par 200 relances pilotes, pour le plus difficile des algorithmes comparés ; plafonné à la taille du pilote (200), la probabilité résiduelle étant alors rapportée.	biernacki2003	n_init
seuil_actif	0,010000	plan	Composante active si N_k / N >= 1 % (plan de recherche) ; sensibilité aux seuils 0,5 %, 5 % et N_k >= 1 rapportée (scénario S10).		

Paramètre	Valeur	Statut	Justification	Références	Calibrage
k_max	'synthetique': 6, 'prix': 8	plan	Nombre maximal de composantes du plan (au moins deux fois le K de référence ; prix : 8, soit le double des quatre régimes que distinguent les phases usuelles d'alerte sur les prix, normal, stress, alerte et crise) ; la dépendance à Kmax est un objet d'étude (Iris, sections 2.3.11), non un réglage.		
alpha0_map	1,000000	mathematique	MAP-EM : plus petite concentration de Dirichlet pour laquelle le mode existe à l'intérieur du simplexe (alpha0 >= 1) ; alpha0 = 1 n'ajoute aucun pseudo-compte, le mode en pi coïncide avec l'estimateur du maximum de vraisemblance.		
priors_reference	emp,diff	source	Deux jeux de référence comparés tels quels : « empiriques » (beta0 = 1, nu0 = D, W0^-1 = covariance empirique, m0 = moyenne, alpha0 = 1/Kmax : valeurs par défaut documentées de BayesianGaussianMixture) et « diffus » (beta0 = 1e-3, W0 = I, nu0 = D). Ils ne sont pas présentés comme optimaux : le bras calibré est VB-cal.	pedregosa2011	
espace_priors	'alpha0': (0.001, 10.0), 'beta0': (0.0001, 100.0), 'nu0_plus': (0.0, 50.0), 'echelle_w0': (0.01, 100.0)	plan	Espace de recherche des hyperparamètres Normal-Wishart et Dirichlet (bornes, échelle logarithmique sauf nu0 - D) : il contient les deux jeux de référence (alpha0 = 1/Kmax, beta0 = 1e-3 ou 1, nu0 = D, W0 = I ou covariance empirique) et s'étend de deux ordres de grandeur au moins de part et d'autre ; nu0 > D - 1 garantit une loi de Wishart propre (Bishop 2006, section 2.3.6). Les illustrations de sensibilité parcourent les mêmes bornes.	bishop2006	

Paramètre	Valeur	Statut	Justification	Références	Calibrage
priors_vb_calibres	'synthetique': 'alpha0': 0.1, 'beta0': 1.0, 'nu0_plus': 0.0, 'echelle_w0': 1.0, 'prix': 'alpha0': 0.1, 'beta0': 1.0, 'nu0_plus': 0.0, 'echelle_w0': 1.0	recherche	Bras VB-cal et MAP-cal : hyperparamètres choisis par recherche aléatoire puis divisions successives (successive halving) sur l'espace « espace_priors », en maximisant la log-vraisemblance prédictive moyenne en validation croisée sur les données d'apprentissage, séparément pour chaque famille de données (plis temporels par blocs d'années pour les prix). Toutes les évaluations sont conservées pour l'analyse de sensibilité (configurations plausibles).	bergstra2012, jamieson2016	priors
alpha_test	0,050000	plan	Niveau des tests, déclaré dans le plan ; contrôle du risque familial par la procédure de Holm.	holm1979	
marges_equivalence	'ARI': 0.03, 'LL': 0.02	donnees	Plus petite différence d'intérêt (Lakens 2017) : quantile à 95 % de l'écart absolu entre deux ajustements de la MÊME méthode avec des graines différentes sur les mêmes données (plancher de bruit d'optimisation), avec un plancher de 0,001 ; un écart inférieur n'est pas attribuable à la méthode.	lakens2017, schuirmann1987	marges
marge_k	0,500000	mathematique	Marge d'équivalence sur l'erreur moyenne de K : K est entier, un écart moyen inférieur à 0,5 signifie que la majorité des réplications ne diffèrent pas d'une composante entière.		
n_bootstrap_ic	2000	benchmark	Nombre de rééchantillonnages des intervalles bootstrap : erreur Monte Carlo des bornes inférieure à la moitié de la dernière décimale affichée (3 décimales), estimée par répétition du bootstrap.		monte_carlo
n_bootstrap_modele	1000	benchmark	Nombre de réplicats bootstrap des intervalles de paramètres (couverture) et de la probabilité d'alerte : même règle de précision Monte Carlo.		monte_carlo
n_tirages_posterieur	4000	benchmark	Tirages a posteriori pour les intervalles de crédibilité : même règle de précision Monte Carlo.		monte_carlo

Paramètre	Valeur	Statut	Justification	Références	Calibrage
effet_standardise	0,500000	source	Hypothèses de différence sans marge naturelle (taux d'ajustements dégénérés, écart relatif de perplexité) : la puissance est calculée pour un écart vrai égal à 0,5 écart-type des différences appariées du pilote (effet « moyen » de Cohen) ; pour les métriques munies d'une marge (ARI, log-vraisemblance, K), l'écart vrai est la marge.	cohen1988	
taille_pilote	10	plan	Réplications pilotes servant à estimer la variance des différences appariées avant le calcul de puissance ; les données du pilote ne sont pas réutilisées dans les tests confirmatoires (graines disjointes).	lakens2017	
replications	'scenarios': 30, 'prix_sous': 40, 'prix_semi': 60, 'prix_sensibilite': 20, 'texte': 10	benchmark	Nombre de réplications : puissance d'au moins 0,8 du test déclaré (TOST à la marge calibrée, ou Wilcoxon pour un écart égal à la marge) au niveau corrigé, d'après la variance des différences observée dans le pilote (Lakens 2017).	lakens2017	puissance
repetitions_chronometrage	20	plan	Répétitions de chaque mesure de temps (un seul processus, un seul fil) : avec 20 mesures, l'intervalle entre les 6e et 15e statistiques d'ordre contient la médiane avec une probabilité 1 - 2 P(Bin(20 ; 0,5) <= 5) = 0,959, sans hypothèse de loi ; l'intervalle bootstrap de la médiane du rapport des temps est rapporté.		
prix_fenetre_mois	12	plan	Fenêtre du niveau de référence de chaque prix : les douze mois précédents (une année complète, ce qui neutralise la saisonnalité agricole moyenne) ; la variable est l'écart du log-prix du mois à la moyenne des log-prix relevés dans la fenêtre.		

Paramètre	Valeur	Statut	Justification	Références	Calibrage
prix_releves_min	3	plan	Nombre minimal de relevés dans la fenêtre pour définir l'écart (un trimestre de relevés sur douze mois) : règle fixée avant toute estimation, d'après la seule couverture des séries (relevés manquants fréquents).		
prix_facteur_pic	3,000000	plan	Nettoyage des erreurs de saisie : un relevé est écarté s'il diffère d'un facteur au moins 3, dans le même sens, du relevé du mois précédent ET de celui du mois suivant (pic isolé d'un mois, aller-retour, typique d'une virgule décalée). Un triplement suivi d'un retour en un mois n'est pas plausible pour une denrée de base au détail (la plus forte hausse mensuelle citée par les bulletins du PAM pour le maïs de l'Extrême-Nord est de 24 %, août 2023). Règle fixée avant tout ajustement ; les relevés écartés sont listés (tableau prix_releves_ecartes).		
prix_fin_apprentissage	2023-12	plan	Validation temporelle : apprentissage jusqu'à décembre 2023 inclus, test de janvier 2024 à la fin de l'extrait. Date choisie avant toute estimation, d'après le seul nombre d'observations (environ moitié-moitié), pour que l'évaluation porte sur des mois postérieurs à tout l'apprentissage (Roberts et al. 2017).	roberts2017	
n_plis	5	plan	Nombre de plis de la validation croisée par blocs (plan) ; l'affectation des blocs aux plis est tirée au hasard.		
espace_lda	'alpha': (0.001, 10.0), 'lissage': (0.0001, 1.0)	plan	Espace de recherche de la LDA (échelle logarithmique) : concentration de Dirichlet sur theta_d sur les mêmes bornes que alpha0 (« espace_priors ») ; lissage des distributions de mots d'un pseudo-compte négligeable (1e-4) à un pseudo-compte par mot et par thème (1).	blei2003	

Paramètre	Valeur	Statut	Justification	Références	Calibrage
lda_hyper	'alpha': 0.1, 'lissage': 0.001	recherche	Hyperparamètres de la LDA : recherche aléatoire puis divisions successives sur « espace_lda », en minimisant la perplexité par complétion de documents de validation tirés du réservoir d'apprentissage (jamais des documents de test).	bergstra2012, jamieson2016	texte
vocabulaire	'taille': 1500, 'df_min': 5, 'df_max': 0.5, 'longueur_min_mot': 3, 'longueur_min_doc': 20, 'sensibilite': (500, 3000)	plan	Prétraitement fixé avant l'analyse et identique pour pLSA et LDA : mots présents dans au moins 5 documents et au plus la moitié d'entre eux (les mots vides sont écartés par cette fréquence documentaire, sans liste externe), mots d'au moins 3 lettres après racinisation de Porter (1980), documents d'au moins 20 mots retenus. Ce n'est pas un réglage optimisé : la sensibilité des conclusions à la taille du vocabulaire (500 et 3000 mots) est mesurée.	porter1980	
espace_variantes	'kappa': (0.5, 1.0), 't0': (1.0, 1000.0), 'lot': (10, 150), 'epoques': (1, 50), 'sem_n_iter': (50, 1000), 'sem_part_burn': (0.0, 0.9), 'tau': (1.0, 1000.0)	plan	Espace de recherche des variantes stochastiques : kappa dans]0,5 ; 1] (conditions de Robbins et Monro sur les pas) ; décalages t0 et tau, tailles de lot (de 10 à la moitié du jeu de 300 points) et nombres d'époques en échelle logarithmique ; SEM : nombre d'itérations et part de chauffe.	robbins1951, cappe2009, hoffman2013	
variantes_stochastiques	'sem_burn': 50, 'sem_n_iter': 150, 'online_kappa': 0.6, 'online_t0': 10.0, 'online_lot': 30, 'svi_kappa': 0.7, 'svi_tau': 1.0, 'svi_lot': 30, 'epoques': 15	recherche	Pas et tailles de lot de la SVI et de l'EM online, burn-in du SEM : recherche sur la log-vraisemblance de validation, kappa contraint à]0,5 ; 1] (conditions de Robbins et Monro).	robbins1951, cappe2009, hoffman2013	variantes
elements_lot_max	30000000	performance	Taille maximale d'un tenseur (b, K, N) traité d'un coup : borne mémoire, sans effet sur les résultats (tests d'équivalence).		

Annexe E : Rappels mathématiques utilisés dans les dérivations

Cette dernière annexe rassemble, à des fins de référence, les principales définitions et identités de calcul matriciel et de statistique bayésienne mobilisées dans les dérivations du chapitre 1 (sections 1.6.2.d et 1.7.3.c) et de la section 2.1.1, afin que le mémoire reste autonome et ne nécessite pas de recherche bibliographique complémentaire pour en suivre le détail des calculs.

E.1 Identités de calcul matriciel

Dérivée du logarithme d'un déterminant. Pour une matrice symétrique définie positive A, on a $\partial/\partial A \log|\mathrm{A}| = (A^{-1})^T = A^{-1}$ (la dernière égalité utilisant la symétrie de A). Cette identité est utilisée à la section 1.6.2.d pour dériver la mise à jour de la covariance Σ_k.

Dérivée d'une forme quadratique. Pour un vecteur x et une matrice symétrique A, on a $\partial/\partial A\ (x^T Ax) = xx^T$. Combinée à l'identité précédente, cette formule permet d'annuler le gradient de la fonction Q par rapport à la matrice de précision Σ_k^{-1}, comme détaillé à la section 1.6.2.d.

Trace et forme quadratique. Pour tout vecteur x et toute matrice A, la forme quadratique $x^T Ax$ peut se réécrire comme une trace : $x^T Ax = \mathrm{tr}(Axx^T) = \mathrm{tr}(\mathrm{A}\ xx^T)$, ce qui permet de faire commuter certains calculs d'espérance avec l'opérateur trace une manipulation fréquente, bien que non utilisée explicitement dans les dérivations du chapitre 1, mais standard dans la littérature de l'inférence variationnelle pour les modèles gaussiens.

E.2 La distribution de Wishart

La distribution de Wishart $\mathcal{W}(\mathrm{W}, \nu)$, utilisée à la section 1.7.3 comme composante du prior Normal-Wishart sur la matrice de précision Λ_k, généralise la distribution du χ^2 à des matrices. Sa densité, pour une matrice symétrique définie positive Λ de dimension $D \times D$, est proportionnelle à :

$$\mathcal{W}(\Lambda|W,\nu) \propto |\Lambda|^{(\nu-D-1)/2} \exp[-\tfrac{1}{2}\,\mathrm{tr}(W^{-1}\Lambda)] \tag{E.1}$$

où W est la matrice d'échelle ($D \times D$, symétrique définie positive) et $\nu >$ D - 1 le nombre de degrés de liberté. L'espérance de cette distribution vaut $\mathbb{E}[\Lambda] = \nu W$, et l'espérance de son logarithme de déterminant, utilisée à l'équation de la section 1.7.3.e, s'exprime au moyen de la fonction digamma multivariée : $\mathbb{E}[\log|\Lambda|] = \Sigma_{j=1}^{D}\ \psi[(\nu$+1-j$)/2]$

+ D log 2 + log|W|, formule qui se déduit de la fonction génératrice des moments de la distribution de Wishart.

E.3 La distribution de Dirichlet

La distribution de Dirichlet Dir($\alpha_1, \ldots, \alpha K$), utilisée à la section 1.4.2 comme prior sur les poids de mélange, est la généralisation multivariée de la distribution Bêta au simplexe de dimension K-1. Sa densité s'écrit p($\pi \mid \alpha$) $\propto \prod_k \pi_k$^{α_k-1}, sous la contrainte $\Sigma_k \pi_k = 1$, $\pi_k \geq 0$. Son espérance vaut :

$$\mathbb{E}[\pi_k] = \alpha_k / \Sigma_j \alpha_j \tag{E.2}$$

et l'espérance de son logarithme utilisée à l'équation de la section 1.7.3.e s'exprime, comme pour la Wishart, au moyen de la fonction digamma : $\mathbb{E}[\log \pi_k] = \psi(\alpha_k)$ - $\psi(\Sigma_j \alpha_j)$. Cette formule intervient dans l'étape E variationnelle (équation 1.27) ; l'exemple de la section 1.4.4, avec $\alpha = (8, 5, 2)$, n'en utilise que l'espérance $\mathbb{E}[\pi_k] = \alpha_k \,/\, \Sigma_j \alpha_j$.

E.4 La fonction digamma

La fonction digamma ψ(x) = d/dx log Γ(x), dérivée logarithmique de la fonction Gamma, apparaît systématiquement dans les espérances de logarithmes de variables aléatoires des familles Dirichlet, Wishart et Gamma, en raison de la forme exponentielle de la famille exponentielle sous-jacente à ces distributions. Elle ne possède pas de forme fermée élémentaire, mais admet le développement asymptotique ψ(x) $\approx$ log(x) - 1/(2x) pour x grand, et est implémentée numériquement dans torch.special.digamma, utilisée dans les implémentations du chapitre 3 (sections 3.2.1 et 3.3.1) : le code n'utilise ni SciPy ni NumPy.